Yukio Professional Research Knowledge Base

AI Agent观察与解释的专业研究知识库

版本：1.0
资料核查日期：2026-10-17 UTC
主要语言：中文；保留英文术语、研究问题ID与来源ID
研究范围：01、02、03、04、06、07
定位：独立研究参考资料；项目适用性另行评估

这份知识库研究怎样观察AI Agent的可获得活动、重建执行状态、生成可以核对的解释、帮助用户理解，并评价何时值得请求人类参与。Yukio决定这些问题为何重要，但不决定答案。本文比较合作式插桩、协议接口、日志、系统层观察、形式化监测、概率推断和人因研究等路线，不为Yukio指定唯一技术方案。

本次研究支持的总体判断是：有活动记录、能重建状态、解释被证据支持、用户实际理解、提醒具有净价值，是需要分别证明的能力。 它们之间存在依赖，但不能相互代替。知识库将直接来源证据、作者解释和本研究综合分开标记；研究空白及无法充分核实的资料也属于交付内容。

阅读导航

目的	建议阅读位置
第一次接手研究	第1章方法与边界、第2章知识地图、第5章关键发现
理解某项技术原理及其前提	第3章对应领域，再查第4章方法比较
判断某条结论是否可靠	追踪C主张ID及其S来源ID，阅读第8章的核查深度和限制
继续研究	第6章开放问题、第9章继续研究指南与覆盖清单
统一用语	第10章术语表；客户端实际字段以版本化官方文档为准

目录

1. Research Scope & Methodology 研究范围与方法
2. Knowledge Map 系统知识地图
3. Domain Research Chapters 六个领域研究
4. Comparative Technical Analysis 技术路线比较
5. Critical Findings 关键发现与争议
6. Open Research Questions 开放研究问题
7. Cross-Domain Synthesis 跨领域综合
8. Research Source Library 带注释的来源库
9. Research Continuation Guide 继续研究指南
10. Technical Glossary 专业术语表

带页码目录

正文保留原有阅读导航；以下目录提供章节页码与可点击跳转。

1 Research Scope and Methodology 研究范围与方法 . . . 3

2 Knowledge Map 系统知识地图 . . . 6

3 Domain Research Chapters 六个领域研究 . . . 9

3.01 领域01 - Agent Observability . . . 9

3.02 领域02 - Event Tracing & State Reconstruction . . . 15

3.03 领域 03 - Evidence-Grounded AI Explanation . . . 23

3.04 领域04 - Human-AI Interaction & Visualization . . . 28

3.06 领域06 - Human-in-the-Loop & Intervention Detection . . . 35

3.07 领域 07 - Evaluation & Reliability . . . 41

4 Comparative Technical Analysis 技术路线比较 . . . 48

5 Critical Findings 关键发现与争议 . . . 51

6 Open Research Questions 开放研究问题 . . . 53

7 Cross-Domain Synthesis 跨领域综合 . . . 55

8 Research Source Library 带注释的来源库 . . . 58

8.1 资料构成与使用规则 . . . 58

8.2 可观测性、事件与状态 . . . 58

8.3 证据解释与评价 . . . 68

8.4 人类理解与介入 . . . 81

8.5 当前官方接口、协议与平台 . . . 91

8.6 近期相关前沿研究 . . . 95

8.7 概率推断基础 . . . 95

9 Research Continuation Guide 继续研究指南 . . . 97

10 Technical Glossary 专业术语表 . . . 103

1 Research Scope and Methodology 研究范围与方法

1.1 核心对象与研究边界

研究对象是观察者系统（Observer）：它取得其他系统可公开或经授权获取的活动信息，并据此形成记录、状态、解释、界面或参与请求。被观察的Agent是Actor。二者可能共享部分基础设施，但必须分开评价。本文中的Agent既包括编程Agent，也包括足以帮助理解问题的工具使用、工作流和多Agent系统。

六个领域沿用用户编号。没有第05领域；多Agent的身份关联、委派、交接及接收侧上下文纳入01、02、03和06，不另设Multi-Agent Coordination领域。安全、隐私和可访问性仅在影响观察、证据、介入或评价时讨论，不扩展成独立安全合规研究。

本文不决定产品架构，不指定数据库或模型，不编排开发任务，不作选型排名，也不把任何研究中的延迟、准确率或用户研究结果称为Yukio实测值。全文的构造例子仅用于解释原理。

1.2 研究形式与五阶段流程

本研究采用问题导向的范围调查与批判性综合（scoping investigation and critical synthesis）。它覆盖六域的代表性理论、原始实证研究、规范与实现资料，但不是预注册系统综述，也没有声称检索了全部数据库或穷尽全部论文。工程文档的高更新频率与不同学科的术语差异，使“来源可追溯及边界明确”比未经证实的穷尽性声明更重要。

阶段	本次实际工作	形成的研究对象
Stage 1 Knowledge Mapping	读取三份附件；拆解六域概念、可回答问题与依赖	领域知识地图、初始覆盖清单
Stage 2 Literature Investigation	主要以英文检索；打开原始论文、标准、官方接口页；沿参考文献和反例补查	带URL、时间、核查深度的来源记录
Stage 3 Method Comparison	按输入、前提、机制、输出语义、无法解决的问题比较	跨路线比较表；不合并不可比性能数字
Stage 4 Critical Investigation	核查小样本、模拟真值、评价器误差、版本变迁、负向结果及推广限制	有条件结论、反证与未完成核查
Stage 5 Cross-Disciplinary Synthesis	连接观察、状态、解释、理解、介入和评价	明确标为综合推论的理论关系与后续问题

研究以相互独立的领域调查和主研究线程复核交叉进行。所有关键结论的引用均指向外部原始来源，而不是只引用本报告另一节。重复来源可以支撑不同命题，但同一团队、同一数据集或同一模型系列不能被当作独立复制。

1.3 检索与纳入策略

英文检索围绕概念族组合，而非仅搜索Yukio、Claude或Codex。例如：observability instrumentation distributed tracing blind spots；event sourcing partial observability causal ordering failure detector；faithful explanation attribution citation evaluation；mental model situation awareness explanation overreliance；mixed initiative value of information interruption cost；observer evaluation fault injection trace replay calibration。

先定位原始论文和规范，再核对当前接口与实现。常规检索与较强覆盖的权威复核相互补充；无法取得正文时保留摘要级来源或继续寻找作者稿。来源库说明真正读到的部分，绝不把搜索摘要等同全文阅读。

纳入标准： 与六域的至少一个研究问题有直接关系；原理、实验设计、规范条款或实现说明可定位；结论可写明成立条件；必要时可作为反证或限制案例。成熟基础理论允许早期文献，前沿系统保留明确的预印本或草案标记。

不作为核心证据： 无方法说明的平台排名；只罗列功能和宣传性能的营销页；无法回到原始实验的二手摘要；把产品名词当统一规范的文章；与六域无直接联系的泛AI综述。它们可以提供检索线索，但不能独立支撑重要研究结论。

1.4 证据类别与核查深度

K/E/P/M/H/O是命题的性质，不是简单的质量排名。同一篇论文可以包含E实证、M方法和H作者解释；官方工程文档可以证明P能力，但不能据此证明E用户收益。

代码	名称	本库的使用方式	常见误用
K	Established Knowledge	在明确模型、定义或规范条件下成立的基础知识	把有假设的定理扩展成任意系统保证
E	Empirical Findings	已在特定样本、任务、模型和程序中观察到的结果	把单次实验或单领域基准写成普遍规律
P	Engineering Practices	已实现、已使用或由官方合同描述的工程机制	把功能存在写成实际部署效果已验证
M	Proposed Methods	论文、草案或研究系统提出的方法	把提出的方法写成已成熟且广泛验证
H	Hypotheses	待检验解释、本文综合推断或预测	把逻辑上合理直接写成经验成立
O	Open Research Questions	证据不足、尚未解决或需限定后再研究的问题	因为本文没找到就声称整个学界完全没有答案

深度	实际核查内容	允许支持的结论
A0	检索元数据或目录	来源存在的线索；不支撑核心技术结论
A1	摘要、出版元数据	作者公开声称研究了什么；不能完整核实实验方法
A2	相关正文、官方说明或实现文档	已读段落直接描述的定义、机制和限制
A3	相关方法与结果，或关键规范条款	可结合样本、设计、对照、结果及限制进行判断
A4	本地复现或实际系统验证	仅当真正复现、并记录环境和结果时使用

A3不等于逐页通读，更不等于A4。 本研究没有运行被评价的Agent、复现论文模型实验或测量Yukio，来源库不将报告生成、文件提取或PDF检查计为A4。对于同一来源“论文只拿到摘要、仓库读到正文”的情况，分别标明访问深度，不能用仓库说明补写成已核实论文全文。

1.5 主张记录与三层归属

重要命题采用C-领域-序号，如C-02-001。研究问题采用RQ-领域-序号；跨域开放问题另用ORQ-序号；跨域综合用C-SYN-序号；来源采用稳定的S-OT、S-GE、S-HI、S-IF、S-FR、S-MT前缀。这些前缀便于管理来源，不代表新的研究领域。

每项重要结论都应回答：具体说了什么；哪份来源的哪部分支持；在什么条件下成立；实际核查多深；不能推出什么。 来源库保存这些字段；正文将引用放在相应命题旁边。

必须区分三层归属：

1. 来源直接支持： 规范定义、方法设置或实验中确实报告的观察。
2. 作者解释： 作者对结果的机制、原因或未来用途的解释；除非另有识别设计，不升级为已证明因果。
3. 本研究综合： 将多个领域连接起来的推论、操作性定义或研究建议，明确使用“研究综合”“假设”或H标记。

同样，“观察事实”指在特定来源和观察边界内记录到的事件，不是不受攻击、伪造或测量错误影响的绝对真相。Agent自述是它发表过该声明的证据；声明所描述的事实仍需独立支持。

1.6 当前来源、版本与证据新鲜度

经典理论的发表年份与官方文档的核查日期分开保存。动态文档若未固定commit、release或归档，就只代表查证时的公开页面，不代表永久合同。来源URL可能重定向；文件路径中的版本名也可能与正文封面不一致，因此以实际文件内容和明确版本为准。

引用全文可得性单列。来源无法取得全文，并不意味着其结论错误；意味着本次只能给予有限核查。搜索未返回某接口，也不证明接口不存在。对于Claude、Codex、MCP、A2A及GenAI语义约定，续研应重新确认规范版本、SDK/客户端版本、配置和实际能力，不依赖旧知识直接套用。

1.7 附件使用与本次限制

已读取《搜索大纲》《我计划对现有桌面助手的AI活动检测能力进行升级》及15页Phase 1技术报告，提取了报告中的来源链接。第04领域以本次明确任务为准固定为Human-AI Interaction & Visualization。附件中的产品偏好、代码风险和实施目标没有被当成外部领域事实。

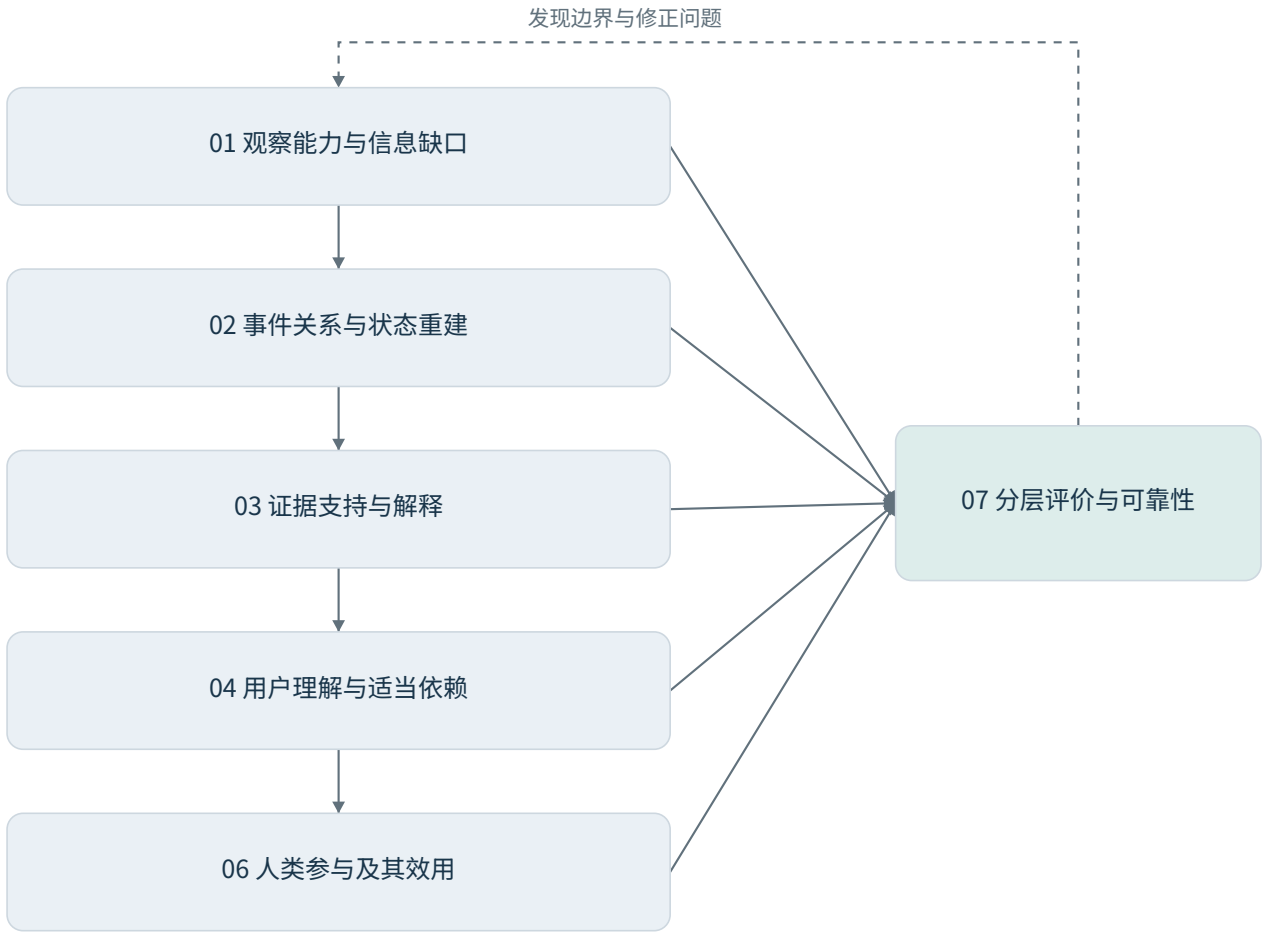
本次的限制包括：公开网络资料可得性不均；部分出版页面或PDF受访问限制；英文检索偏重英语学术与工程生态；前沿研究独立重复不足；没有真实用户设备、日志覆盖率和运行时数据；没有对各工程平台做统一负载比较。结论需在这些边界内使用。

2 Knowledge Map 系统知识地图

2.1 六域的问题结构

领域	首要研究问题	理论基础	主要分支	向后续研究提供什么
01 Agent Observability	能够观察哪些行为，缺口在哪里	可观测性、软件诊断、instrumentation、测量边界	logs/metrics/traces；接口与hook；OS观察；采样；观测扰动	证据类型、可见范围、时间与完整性条件
02 Event Tracing & State Reconstruction	零散证据支持什么执行关系和状态	happens-before、分布式快照、故障检测、状态机、部分可观测系统	trace correlation；event sourcing；process mining；runtime verification；概率状态	有范围限定的执行结构、状态与未知
03 Evidence-Grounded AI Explanation	一句解释为何得到证据支持	provenance、attribution、faithfulness、证据时效	事实分解、检索与引用、蕴含和矛盾、弃答、自述与推测	可追溯的陈述及其证据边界
04 HAI & Visualization	人是否形成准确的执行理解	mental models、situation awareness、trust calibration、认知负担	时间线、任务图、证据展开、可访问性、真实理解实验	人类理解、依赖行为与中断成本
06 HITL & Intervention	何时请求人类参与有净价值	automation levels、mixed initiative、决策效用、注意与中断	明确请求、偏好询问、异常分流、选择性预测、提醒时机	有条件的参与策略与行动成本
07 Evaluation & Reliability	怎样知道观察者可靠且有用	独立真值、测量有效性、calibration、分布式测试	事件/状态/陈述评价；replay；fault injection；live tests；用户研究	可复核的可靠性与适用范围

2.2 依赖关系



图中的连线是研究问题之间的依赖，不是软件组件部署图。07贯穿各层；观察者自身的采集质量也需要成为评价对象。自然语言解释可以改善理解，但也可以制造无依据的确信；提醒可能帮助纠正，也可能造成打断或不必要的拒绝。因此依赖链不是“能力逐层相加必然改善”的保证。

2.3 应贯穿六域的概念区分

需要区分的概念	研究意义
真实世界执行 / 来源记录 / 观察器采集 / 界面呈现	同一缺口可能出现在四个不同位置，评价分母与修复问题不同
身份关系 / 时间关系 / 因果关系	同一会话或时间邻近不能单独证明动作之间的因果依赖
运行状态 / 产物验证状态 / 用户目标状态	进程退出、测试通过与用户任务完成回答不同问题
来源完整性 / 来源真实性 / 陈述支持度	证据未被修改不等于记录真实；引用存在不等于支持陈述
模型表达的置信度 / 经验校准 / 可回答范围	自报高分不等于正确概率；缺少关键证据不由分数补齐
可理解 / 感觉可信 / 实际理解 / 适当依赖	流畅解释或高满意度不能单独证明判断能力提高
异常 / 错误 / 风险 / 值得参与	偏离常态未必错误；即使有风险，人也未必能采取有效行动
历史回放 / Agent重新执行 / 线上实时观察	三者能验证的可靠性范围不同

这些区分由后续章节逐项给出来源与条件。它们也是跨领域研究中最容易被术语复用掩盖的错误来源。

3 Domain Research Chapters 六个领域研究

本章采用六个固定领域编号。各域首先回答概念与理论问题，再比较方法和直接证据，最后说明限制。详细正文提供来源支持；第8章含114条来源记录（85条A3、20条A2、9条A1），没有A4。来源记录数不等于独立实验数。

研究问题ID在续研中应保持稳定；修改问题含义时建立新ID并保留旧ID的关系。

3.01 领域01 - Agent Observability

3.01.1 知识地图与研究问题

本领域研究的是“观察者凭什么能够知道系统发生了什么”。首先要区分观测对象、可用信号、采集过程和待回答的问题，然后才能讨论信息是否充分。将工具接入一个日志端点，仅证明建立了一条数据通路。

研究问题 ID	核心问题	理论与方法分支	直接依赖
RQ-01-01	“可观测”是模型性质、工程能力，还是营销描述?	状态空间、可区分性、Instrumentation、问题驱动观测	明确状态及问题语义
RQ-01-02	不同信号能支持哪些陈述?	Logs、Metrics、Spans、Traces、Profiles、上下文传播	信号生成规范与采集范围
RQ-01-03	第三方如何取得活动证据?	原生 API、Hooks、SDK、运行时探针、OS 监测、网络边界、制品比较	权限、接口版本、进程与资源身份
RQ-01-04	怎样知道观察有缺口?	Sampling、队列溢出、过滤、截断、断连、采集健康	观测通道本身的遥测
RQ-01-05	低层活动与高层 Agent 行为如何关联?	分布式追踪、请求提取、系统 Provenance、语义约定	领域 02 身份与关系建模
RQ-01-06	观察会怎样改变被观察系统?	开销、阻塞、反压、探针选择、同步授权、缓存	环境及负载实验
RQ-01-07	现有证据能推广到哪些客户端与任务?	版本固定、可移植性、部署覆盖、外部有效性	领域 07 的测试与抽样设计

分支间有两种依赖：Instrumentation 决定“什么有机会被记录”，采集健康决定“本来会记录的东西有多少到达观察者”。二者共同约束后续状态重建。事件内容丰富却缺失严重，与事件完整但语义粗糙，是不同问题，不能用一个总分遮蔽。

3.01.2 两种 Observability：数学定义与软件工程目标

C-01-001｜K：控制理论中的 observability 是相对于给定系统模型和观测关系的可区分性性质。 对已知、无噪声的有限维连续时间 LTI 系统

$$\dot{x} = Ax + Bu, \qquad y = Cx + Du,$$

观测输入和输出能否唯一确定初始状态，可由可观测矩阵

O=[C; CA; ⋮ ; CA^(n-1)],
rank(O)=n

判定。若某非零状态方向落在该矩阵零空间中，不同内部状态可以产生相同输出。MIT 原始课程讲义给出定义、不可观测状态例子及秩条件推导；Åström 与 Murray 的教材是进一步系统学习的权威入口，但本次未成功取得其第 7 章全文。S-OT33 S-OT01

软件运维中的 Observability 则通常表示利用外部可得的遥测探索系统行为、定位问题的能力。OpenTelemetry 的工程性表述强调适当的 Instrumentation，使问题调查不必每次重新增加探针；它并未把所有软件系统化约为上述线性模型。S-OT02

研究者综合推论：“拥有 Logs、Metrics、Traces”不是全状态可重建性的充分条件。工程研究更应问：对于“哪些文件被某次工具调用修改”“这个测试是否针对当前提交”“任务是否仍有未结束子工作”等具体问题，是否存在两个与现有证据同样相容、答案却不同的执行过程？若存在，该问题在当前观察条件下尚不可辨识。这个判断框架借用了可区分性的思想，不宣称给通用 Agent 建立了已验证的控制模型。

还应区分 observability 与 controllability：看见一个操作，不意味着有权阻止、暂停或恢复它；能发出取消请求，也不意味着能观察到所有后续副作用。两种能力需要分别核查。

3.01.3 遥测信号与概念边界

概念	准确定义与主要作用	不能自动推出的结论
Telemetry	系统或观察组件产生并传输的行为、资源及运行信息的总称	数据来自系统不等于内容真实、完整或足以回答任意问题
Log / Log Record	对某项活动或状态的记录；可结构化，也可为文本。一个事实可能产生多条日志	有日志不等于有完整请求链；文本中的计划不等于发生的操作
Metric	数值测量及其按时间、属性等维度的聚合；Counter、Gauge、Histogram 表达不同量	总调用次数或平均延迟无法恢复每次调用的输入、顺序和原因
Span	有身份和起止时间的操作区间，可携带属性、事件、状态及链接	Span 结束不等于其子 Span 都结束；状态不是用户目标正确性的统一证明
Trace	围绕传播的 Trace Context 关联起来的 Spans 集合	一个 Trace 不必等于一个用户任务，也不保证跨所有组件完整
Span Event	Span 内某个有时间标记的记录点	它不是一个独立运行的子操作，也不一定拥有自己的生命周期
Span Link	与同一或其他 Trace 中 Span 的关系，适合批处理、扇入等多来源关系	Link 的存在不说明关系属于数据依赖、调度依赖还是解释者推断
Instrumentation	在应用、库、运行时或系统边界设置产生观测信号的机制	“Zero-code”通常指不改应用源码，不代表没有探针、前置条件或开销

上表综合 OpenTelemetry 的概念和数据模型。其规范把 Metrics 的测量、聚合与属性过滤区分开；Trace 模型支持 Links，因而不应把所有工作流强塞进单一父子树。S-OT02 S-OT03

C-01-002｜K / P：Span 状态和生命周期具有明确且有限的规范含义。 OpenTelemetry 中初始状态是 Unset；Ok 表示该操作被应用开发者或操作者标为成功，Error 表示发生错误。End 的规范明确要求不能改变子 Span 的结束状态。因此，Unset 不能解读为成功，父 Span 结束也不能用来证明聚合任务全部完成。S-OT04

日志至少还要区分两个时间：源头报告的 Timestamp 与观察组件收到记录时的 ObservedTimestamp。前者可能缺失，后者可能使用另一台机器的时钟；把缺失的事件时间静默替换为到达时间，会把网络或采集延迟误画成执行顺序。S-OT18

3.01.4 Agent 与传统软件：连续性和新增困难

异步执行、重试、并发、外部依赖、非确定性和部分日志，均早已存在于传统分布式系统。不能以“Agent 是非确定性的”为理由忽略分布式追踪、事件处理和形式化验证的既有成果。

Agent 观察中需要额外显式处理的，是多层语义之间的距离：

1. 用户目标可能只以自然语言给出，缺少完整可执行的成功判据。
2. 计划、工具请求、工具实际执行、外部效果、结果验证分别处于不同层。
3. 模型输出可能是计划、自述、解释或工具参数，不能仅凭文本形式判断其证据类别。
4. 会话、子 Agent、压缩后的上下文、重试和重新规划，未必拥有统一且稳定的任务身份。
5. 模型推理内部状态与云端服务内部执行通常超出第三方观察者的直接可见范围。

以上是针对研究对象的概念分解，不是本次获得的客户端普遍实测事实。AgentOps 提供目标、规划、工作流、任务和工具等观测点的分类，但其研究主要是从 GitHub、Google 及工具资料收集和分析 17 个代表性工具；这不能证明上述语义均可被可靠采集，更不能直接证明能保证 Agent 安全。S-OT14

3.01.5 观察技术路线比较

下表比较的是信息来源及前提，不规定产品应采用哪种组合。

路线	工作机制与输入	擅长回答的问题	前提、盲区与失效方式
客户端原生 API / 事件流	客户端发布结构化生命周期、请求或制品信息	客户端定义的会话、工具及结果状态	接口可能是读取、订阅或控制之一；版本、授权和公开支持范围不同
Hooks / 回调	在定义的生命周期位置调用外部处理器	到达某个客户端检查点、某类工具的请求或结果	Hook 名称不保证覆盖所有同类行为；同步 Hook 可能影响执行
SDK / 库自动 Instrumentation	在已支持的模型 SDK、RPC、HTTP、线程或框架边界产生 Span	上下文传播、请求耗时、调用层级	未支持库、异常控制流、手写网络栈或上下文丢失会断链
应用日志 / Transcript 解析	读取程序留下的记录，按格式识别内容	历史动作、输出、自述、诊断信息	内部格式变化、截断、轮转、源头遗漏；自述与动作容易混同
文件系统事件 / 制品差分	监控文件变化或比较两个版本的内容	哪些可见制品发生变化	变化未必能归因给某个 Agent；最终差分丢失中间过程和未落盘活动
系统级事件 / eBPF / ETW / Endpoint Security	在内核、运行时或安全事件边界观测进程、文件和网络活动	外部效果、进程谱系、资源消耗	受 OS、探针、权限、过滤和队列限制；低层行为没有天然用户目标语义
网络与受支持 TLS 库边界	观察请求、响应及可用明文边界	受支持通信中的工具或模型交互	密文捕获不等于明文可见；边界兼容性和跨进程关联需核查
屏幕 / UI 观察	从界面文字、视觉变化和交互反馈取得证据	用户实际能看到的状态与反馈	UI 可能省略、延迟或概括；不可见动作与隐藏窗口不能被排除

原生接口的当日事实由本知识库接口核查专节单独维护，不应由上表倒推出某个产品已有相应能力。例如 Claude Code 的 Hook 覆盖与 Monitoring 字段、Codex 的读取与订阅语义都应按版本核查。S-IF01 S-IF02 S-IF03

3.01.6 三条历史路线及其证据边界

C-01-003｜P：协作式 Trace 依赖 Instrumentation 与 Context Propagation，部署广泛也不等于观测完整。Dapper 通过常用线程、控制流和 RPC 库传递上下文，以抽样限制生产开销。论文直接承认：完全不产生 Trace 的进程对系统不可见；非标准控制流可能漏掉关联或造成错误关联。因此其 Google 生产部署经验支持一种可扩展工程路线，不支持“任何第三方都能看到全链路”的结论。S-OT06

X-Trace 将任务元数据传播到多个协议层，目标是连接跨层执行信息。其前提包括相关组件遵循传播规则，协议、客户端或设备可能需要修改；部分部署和跨管理域的数据共享政策限制所能重建的路径。它说明跨层观测可以被系统设计支持，也说明这种支持不是旁观者无条件拥有的能力。S-OT07

C-01-004｜M / E：不传播全局请求 ID，也可以在有明确事件语义时重建请求。 Magpie 使用应用特定的 Event Schema，对 ETW 事件中的线程、请求等属性执行带有效区间的 Temporal Join，再构建请求描述与工作负载模型。其替代意义在于“关联不只有全局 ID 传播一种方法”；限制在于语义由 Schema 提供，不能把“无需全局 ID”误说成“无需了解应用”。论文包括合成数据与现实工作负载验证，未验证自然语言 Agent 目标推断。S-OT08

C-01-005｜M / E：系统 Provenance 的依赖边也可能是保守近似。 CamFlow 在系统层采集信息流并使用对象版本避免循环。论文明确讨论共享内存：缺乏应用内部观测时，不能知道具体何时、是否通过映射传播数据，因此采用保守关联。可达路径表达潜在信息流，不自动证明应用实际上读取、采用或因某信息作出决策。S-OT13

这三条路线分别依赖主动传递上下文、利用既有事件及领域 Schema 关联、系统层保守信息流采集。其误差来源不同，不能只比较信号数量。

3.01.7 系统级监测不是无损的全知视角

原始资料	可以确认的机制	对第三方观察的限制
Linux BPF Ring Buffer	多生产者单消费者缓冲区可跨 CPU 共享；保留成功预留记录的顺序	满缓冲区预留失败且不阻塞；NMI 环境还可能因锁竞争失败。传输机制不保证源头事件完整。S-OT09
Windows ETW	由系统或应用 Provider 发事件，经会话写日志或送实时消费者	EVENT_TRACE_PROPERTIES 分别记录 EventsLost、LogBuffersLost、RealTimeBuffersLost；没有丢失计数核查就不能假定无损。S-OT10
macOS Endpoint Security	客户端订阅特定事件；NOTIFY 通知操作，AUTH 可能等待响应后才继续	Muting、缓存、订阅选择影响覆盖；耗时处理使队列积压并可能丢消息。AUTH 是参与控制，观察者可能改变运行时序。S-OT11
Linux inotify	按监控对象报告文件系统变化	相邻相同未读事件可合并，队列可溢出；事件不提供发起用户或进程，因此不能可靠计数，也不能单独归因 Agent。S-OT12

这些限制是所列机制的文档事实，并非对所有 OS 监测方案的统一性能判断。没有 root / 管理员权限、相应授权或受支持运行时的环境，能观测的事件种类需要另行核查；本次没有安装或运行这些机制。

重要反例：“文件最终变了”可能对应多个中间写入、替换、回滚和其他进程操作；“记录到 open”不证明完整内容被模型读取，更不证明该内容影响了输出；“未见文件事件”也可能源于合并、过滤或缺口。把这些层次分开，是事实解释准确性的前置条件。

3.01.8 Agent 专门系统：前沿结果如何阅读

C-01-006｜M / E：AgentSight 展示了用 eBPF 将模型通信与系统效果结合的可行性，但证据范围很窄。 2025 年 v1 论文使用受支持 TLS 边界、系统活动和进程关联，再交由模型分析高层行为。性能实验固定于 Ubuntu 22.04、Linux 6.14.0、Claude Code 1.0.62 与一个教程仓库，三类工作流各重复三次。表中开销为 3.4%、4.9%、0.4%，均值 2.9%；摘要的“低于 3%”不能转述为所有场景均低于 3%。其案例分析未给出通用错误识别的 Precision / Recall。S-OT15

其价值是提供一条无需修改应用源码的候选观测路线。对跨平台兼容性、不同 TLS 实现、漏采、关联误差和复杂 Agent 任务的推广，仍需独立验证。论文中的“因果”“reasoning”或“完整”措辞应逐项还原为实际采集对象，不能替代证据检查。

OpenTelemetry GenAI Agent 约定则是一条标准化语义路线。当日原网站的 Agent Spans 页面明确提示内容已迁移且不再维护；新的专门仓库将该约定标为 Development，包含 Agent、工作流与工具操作等语义。它定义的是如何表达信息，不保证所有框架均已实现这些字段，更不保证字段覆盖模型内部推理。S-OT16

3.01.9 完整性、Sampling 与观察者效应

C-01-007｜K / P：未观察到事件，只有在明确的封闭覆盖条件下才能作为“未发生”的证据。 至少需核查：

- 该类型活动必定触发所用事件，且相关执行范围均在监控内。
- 采集已启用，权限、过滤、采样与版本条件满足。
- 该时间范围已足够收敛，没有未决延迟、断连或队列溢出。
- 重启、轮转和身份复用不会把记录归到别处。
- 事件的声明语义确实对应所讨论的动作，而非计划或授权请求。

这是依据 Dapper、OS 队列及流处理限制形成的研究者综合规则，不是任何单篇论文给第三方工具作出的保证。S-OT06 S-OT09 S-OT10 S-OT25

缺失机制应分开记录：源头根本不生成、选择性关闭或脱敏、抽样丢弃、收集器过载、导出失败、传输延迟、解析失败、存储截断、观察窗口外发生。前几种属于结构性盲区；即使导出通道没有报告丢包，也无法排除它们。事件序号有缺口可以揭示某种丢失；没有缺口只在该计数器覆盖的范围内有意义。

Head Sampling 在早期作决定，难以保证保留之后才表现为错误的所有 Trace；Tail Sampling 可以依赖已收集的更多 Span，但增加缓冲、等待与运行成本，也受晚到 Span 和自身资源限制。先在源头被 Head Sampling 丢弃的信息，之后的 Tail Sampling 无法恢复。S-OT17

W3C Trace Context 规范自身说明 Sampled 标志是组件间的建议，受信任、负载及实现决策影响；它既不是存储成功回执，也不是全链路完整性证明。S-OT05

C-01-008｜H：对用户解释而言，覆盖信息与活动信息可能具有同等重要性。 如果不能区分“当前无活动”与“观察通道中断”，语言解释再流畅也无法补足证据。这个假设应在领域 07 通过有已知缺口的任务和理解实验检验，不能仅凭工程直觉宣称用户价值。

观察者效应也应纳入研究：同步回调改变时延，授权组件会阻塞操作，导出和探针消耗资源，观察工具自己的文件访问可能混入目标活动。评价“低开销”需要指定基线、负载、硬件、采集种类和尾延迟；某篇论文的平均值不等于长期运行或最坏条件保证。

3.01.10 本领域开放问题与研究边界

优先级	问题	为什么未解决	前置知识
P0 / RQ-01-04	能否形成可机器检查的 Coverage Contract?	缺失计数不覆盖“从未 Instrument”的活动；接口语义会漂移	数据模型、源头保证、真实故障测试
P0 / RQ-01-05	多来源关联如何报告关联证据和备选解释?	时间接近、进程关系与真实任务边界可能冲突	领域 02 关系图与不确定性
P1 / RQ-01-03	系统层与原生事件能否互相揭示盲区?	两者可能共享上游盲区，不能默认独立	漏采机制、Ground Truth、依赖分析
P1 / RQ-01-06	观测预算怎样分配才能保留用户问题所需证据?	常规 Trace Sampling 常服务于运维统计，未必服务于单任务解释	领域 03 事实支持与领域 07 价值评价
P2 / RQ-01-07	Receipts、签名及可验证执行证据能增加多少可信性?	完整性、来源认证、事实真值、语义正确性是不同性质	Provenance 与威胁模型；需继续读原始协议和论文

3.01.90 当前接口核查与观察路线边界

本节是2026-10-17 UTC的文档核查快照。资料证明的是接口设计及其条件；本研究没有运行Yukio、连接用户设备、订阅真实会话或调用任何模型API。以下方案是研究比较对象，不构成产品架构推荐。相关概念应先阅读本章的observability、instrumentation与覆盖范围定义。

观察路线	已由原始资料确认的机制	前置条件与关键限制	证据
客户端Hooks	特定生命周期回调可给出调用身份、参数、结果或失败信息	必须确认事件触发语义；执行前回调不证明副作用完成；同步hook会参与执行时序	S-IF01
客户端OpenTelemetry	Claude提供metrics、events及需启用的beta tracing	内容可能默认省略或截断；详细beta与普通telemetry不是同一能力集合	S-IF02
运行协议接口	Codex App Server有thread、turn、item与生命周期通知	读取历史和启动/恢复/订阅语义不同；接口版本、线程归属与连接方式需要分别确认	S-IF03
由调用方管理的CLI运行	Claude的stream-json与Codex exec的JSONL可作为结构化输出	这是管理某次运行的入口；不能由此推定可旁听任意已运行GUI会话，两者schema也不同	S-IF04、S-IF05
Agent框架原生追踪	Agents SDK正常服务端路径可记录模型、工具、handoff等	需要工作流处于该SDK的观察范围；框架追踪不等于任何客户端都可取得相同记录	S-IF07
可观测性后端与instrumentors	Langfuse组织observation；Phoenix接收OpenInference等发出的spans	后端的查询与展示能力不能补出未instrument的活动；“自动插桩”也有支持范围	S-IF11、S-IF12
Agent通信协议	MCP扩展与A2A为参与通信的端点提供任务/结果语义	不是桌面全局事件总线，也不保证看到Agent全部内部上下文	S-IF08、S-IF09、S-IF10

C-01-901〔P〕观察端拿到的工具输出，未必就是Agent实际看到的输出。 Claude的PostToolUse文档允许执行后替换送给Agent的结果，而相应telemetry可已记录原始结果。这是区分“工具原始输出”“Agent可见输入”“观察器取得的副本”的直接实例；不能仅凭同名output字段认定三者等同。S-IF01

C-01-902〔P〕转录身份与顺序不能依靠字段名称猜测。 Claude明确说明event.sequence按进程计数，恢复会话后可以重复或变小；其转录连接格式为内部格式。研究综合：稳定关联需要知道ID的命名空间、生命周期和生成者，仅存一个看似唯一的数值不够。S-IF02

C-01-903〔P〕执行信息可以扩展，但不能据此承诺全量可见。 例如Claude的PreToolUse只在相应工具调用时触发，提示中直接加入的文件内容可能绕过该类Read回调。该反例反驳“Read hook完整记录所有模型已获得的文件内容”，并不意味着其他来源绝不可能补足信息。S-IF01

3.01.90.1 同一状态名称并不意味着同一结果

原始表达	在所核查接口中的含义	不能直接推导的结论
Codex App Server turn/completed	一个turn到达终点，必须继续看status；可为completed、failed、interrupted	用户任务已经正确完成并得到验收
MCP Tasks扩展draft中的completed	协议请求有可取得结果；其工具结果仍允许isError: true	工具业务操作成功
A2A v1.0.1终态Task	该协议工作单位终结，后续细化另起Task	整个context中的后续工作完成、产物版本链已完整保存

C-02-901〔P/M〕状态归一化必须保留原始协议层级。 上表分别有官方协议资料支持，但MCP条目来自明确标示draft的扩展，不能称为普遍稳定接口。这些实例共同支持研究综合：传输完成、调用返回、工具成功、测试通过、Agent宣称完成和用户目标达成是不同命题。S-IF03、S-IF09、S-IF10

3.01.90.2 标准与实现需要分别定位

MCP的2026-07-28变更说明已将Tasks移到扩展，并弃用原有Logging等特性；它还说明了OTel上下文传播约定。这不是所有现有MCP客户端都已经升级的证据。协议版本、SDK版本、客户端版本和实际协商能力是四个需要分别核查的对象。S-IF08

SDK的handoff也不能只按自然语言“交给另一个Agent”理解。官方资料区分控制权交接和把Agent作为工具调用，并允许部分handoff经过历史过滤。研究综合：委派正文、接收侧上下文和接收后使用的证据都可能不同；跨Agent关联应保留这种可见范围的不确定性。S-IF06

3.01.90.3 本轮明确未核实的项目事项

Phase 1中的Yukio源代码风险、窗口复用方案、SQLite选择、具体模型型号及账号可用性、延迟目标和阶段安排，本研究均不将其转写为专业领域共识。它们属于另行进行的Application Analysis或系统验证。附件对观察事实、自述与推断的区分可作为研究问题，但其合理性须由本知识库各域的独立证据支持。

3.02 领域02 - Event Tracing & State Reconstruction

3.02.1 知识地图与核心问题

研究问题 ID	研究分支	主要问题
RQ-02-01	事件与对象语义	Event、Task、Session、Run、Tool Call 分别指什么，粒度是否一致?
RQ-02-02	身份与关联	相同 ID 的作用域、重试、恢复、进程重启如何处理?
RQ-02-03	时间与因果	哪些顺序由协议保证，哪些只是显示排序或推断?

研究问题 ID	研究分支	主要问题
RQ-02-04	模型重建	State Machine、Event Sourcing、Petri Net、Process Mining 如何比较?
RQ-02-05	不完整事件流	乱序、重复、丢失与迟到如何改变状态结论?
RQ-02-06	状态与终态	正在执行、等待、失败、结束、已验证、未知能否被分别证明?
RQ-02-07	部分可观测推断	多个相容执行过程如何表示，何时应该拒绝作唯一判断?
RQ-02-08	属性监测	显式规范的运行时验证能保证什么，何时只能给出尚不可判?

概念依赖顺序是：事件语义 → 身份和对象 → 有依据的顺序与关系 → 可用模型 → 状态判断。不能先画一棵任务树，再把所有记录强行解释成该树的证据。

3.02.2 Event、State 与执行容器的定义

C-02-001｜K / P：事件记录、事件所指的发生事实和系统状态应分开。 CloudEvents 明确区分 Occurrence 与 Event：后者是表达前者及其上下文的数据记录，同一次 Occurrence 可以生成多个 Event。由此，合并“记录副本”与合并“重复动作”是两件事。S-OT26

术语	本研究使用的定义	常见混淆
Event	在给定事件模型中表达发生、观察或生命周期变化的记录	命令提出、授权通过、开始执行、效果出现是不同事件
State	相对于某模型、范围和时刻的状态描述；观察者状态可能只是一组候选状态	数据库里的最后一行不一定是系统当前状态
Execution	系统在所定义语义下产生的运行过程，可含并发关系	显示为顺序列表不等于真实过程完全串行
Task	带目标和完成标准的工作单元；也可能是厂商协议定义的对象	自然语言用户目标与协议 Task 可能粒度不同
Session	一种上下文或交互容器，常用于连续对话或认证、运行关联	会话内可有多任务；一个任务也可跨会话或恢复
Run / Attempt	按具体系统定义的一次运行或尝试	重试可以新建 Attempt，也可能复用上层 Run
Tool Call	对某工具的一次调用请求及其生命周期，含参数、调用身份、响应与可能副作用	收到响应不等于业务成功，更不等于上层任务成功
Artifact	产物或外部对象，常需携带版本、生成/修改关系和验证对象	文件路径相同不等于内容版本相同

除 Event 的引用定义外，上表是为跨客户端研究建立的分析词汇，不是假定厂商共享同一对象模型。接入资料应保留厂商原词及其定义，并明确映射损失。

3.02.3 身份关联：名称、相同记录与同一动作

身份至少可能属于源系统、进程实例、会话、运行、尝试、调用、对象版本、记录这几个层次。一个 PID、文件路径或会话编号不足以跨时间唯一标识所有对象；范围和有效期与值本身同样重要。

CloudEvents 固定版 1.0.2 要求 source 与 id 的组合区分不同事件，并允许消费者用相同组合识别重复投递。这约束事件标识，不提供自动的任务因果、全局顺序或 Exactly-once 执行保证。S-OT26

研究者综合的关联强度分层：

1. 显式协议关系：调用响应引用请求 ID、parent / link、制品明确指向某操作。
2. 有领域依据的结构关系：在有效时间范围内的线程、进程、文件版本或句柄关联。
3. 统计关联：时间窗口、文本相似度、相邻输出及聚类。
4. 语言模型推断：根据叙事相容性提出某些记录可能属于同一子任务。

较后层级可以补充候选关系，但不能抹去较早层级缺失或冲突的事实。Magpie 的有效区间关联尤其说明：相同线程 ID 在不同时段可以服务不同请求，关系需要时间和 Schema 共同约束。S-OT08

错误去重会把“再次运行测试”误删成旧事件重发；不去重又会夸大动作次数。若源头没有足够标识，只能报告候选重复关系及不确定性。不能用观察者生成的 UUID 把未知源身份包装成已确认身份。

3.02.4 时间顺序、Happens-before 与因果解释

C-02-002｜K：时间戳排序不能替代因果顺序。 Lamport 的 happens-before 关系由进程内先后、消息发送先于接收及传递性构成。其逻辑时钟保证

$$a \to b \;\Rightarrow\; L(a) < L(b),$$

反向不成立。使用进程编号打破平局所形成的全序，是对偏序的一种扩展，不是唯一客观执行序列。S-OT19

Vector Clocks 让参与进程传播各自已知的时间向量，通过逐分量最大值合并信息。在对应模型和完整传播前提下，可以由分量偏序区分 happens-before 与并发。Mattern 也明确说明，这里的“因果”表示可能影响，不等于模态意义上已经导致。Fidge 是另一项重要的同期原始线索，但本次未获得可读全文，不能据其摘要声称核查证明。S-OT20 S-OT21

C-02-003｜研究者综合推论： Trace parent、消息边或信息流路径能支持“存在传播关系 / 可能影响”；它们通常不能独立支持“Agent 因看见这个错误而决定改这行代码”。后一句涉及决策理由，需要额外的时间匹配、版本、内容支持或可验证机制。即使 Agent 自述了原因，也仍应标为自述。

不同时间有不同用途：

时间 / 顺序	可用目的	主要风险
源头 Wall-clock	与真实世界时间对齐、展示日期	时钟偏差、跳变、时区与精度
同进程 Monotonic clock / Sequence	计算局部耗时、局部先后	不能默认跨进程可比较，重启后范围可能改变
观察到达时间	判断采集延迟与观察者所知的时点	到达先后可能与发生先后相反
逻辑时钟 / 显式消息边	表达有协议依据的因果偏序	缺少参与方或传播信息时不能补齐未知关系
显示排序键	稳定排版和检索	稳定排序只是界面选择，不是新增事实

3.02.5 Global State 与 Consistent Cut

C-02-004｜K：全局状态包括进程状态及在途消息，不能只拼接各组件“最近状态”。 Chandy-Lamport Snapshot 使用 Marker 建立相容的全局记录；核心思想是不允许在观察切面里已经包含某次接收，却没有包含相应发送。论文模型要求可靠、FIFO 的通道和有限但不固定的延迟，且参与者执行 Marker 协议；被动读取任意日志不会自动满足这些前提。S-OT22

该理论解释两个容易忽略的问题：某个子过程安静下来不等于整个分布式计算终止；某阶段结束也不等于整个任务结束。对于动态 Agent，是否允许外部输入再次激活、是否包含在途调用、子工作是否还可能产生效果，都属于“完成”判据的一部分。

推论的适用边界： Yukio 情境不一定允许注入 Marker，也未必知道所有参与进程，因此该理论首先用于识别错误推理和设计研究问题，而不是宣布可以直接运行一个分布式快照算法。

3.02.6 状态重建技术路线

方法	机制与所需输入	可以解决的问题	不适用或需要额外条件的情况
显式 State Machine	给定状态集合、事件类型、转移规则与作用域	生命周期合法性、当前可达状态、异常转移	未建模工具或动态目标；丢事件时单一状态可能过度确定
Event Sourcing	领域状态变化以事件作为权威历史，投影器重算状态	从已定义起点重建领域状态，修正投影	普通日志遗漏了必要变化；外部副作用及历史查询不可重现
Distributed Tracing	Span、Context、父子和链接表达操作关系	延迟、嵌套操作、跨服务调用结构	用户任务和成功标准未必在 Trace 里；一个任务可有多个 Trace
Petri Nets	Token / Marking 表示状态，Transition 的启用和触发表达并发与同步	分支、并行、扇入、死锁和可达性分析	真实行为未被模型覆盖；状态空间可能很大
Process Discovery	从多个执行记录学习模型	发现常见路径和结构、比较流程变体	稀有路径缺失、噪声、Case 划分不稳、非平稳任务
Conformance Checking	比较事件记录与预先给定模型的匹配和偏离	找出不符合显式流程约束的位置	模型本身错误；符合流程不等于满足自然语言目标
概率状态估计	状态转移模型、观测似然与历史数据更新概率	在噪声及部分观测下进行有条件预测	没有可信观测模型或分布改变；概率不是确定性证据
Runtime Verification	监测有限执行前缀是否满足显式逻辑属性	可判定的局部属性、时序约束、尽早发现违反	未形式化的目标；只监测选定运行和可得命题

这些方法的输出对象不同：发现模型、检查模型、还原一次运行、预测未来状态不能当成同一任务评测。方法之间可以结合，但结合后的正确性需要重新检查输入假设。

3.02.7 Event Sourcing 不等于“有日志即可回放”

Fowler 的 Event Sourcing 描述要求状态变化以事件序列保留，事件能够用于重建投影。作者专门讨论 Replay 与外部系统：重放不应重新发送付款、邮件等外部副作用；历史外部查询若当时未记录，今天查询到的值可能与当时不同。S-OT24

C-02-005｜P 与研究者推论： 一个任意调试日志只有在包含相关状态变化、已知初始条件且具有可解释顺序时，才可能承担某种范围内的重建。确定性投影还依赖固定或可追溯的转移语义、Schema 和配置版本。日志中缺少的动作，不能靠“重新执行一遍 Agent”无条件恢复：模型输出、文件状态、网络结果、权限和时间都可能改变。

需要区分三种 Replay：

- 观察者 Replay：输入固定历史证据，检查解析、关联、状态与解释是否稳定。
- 模型 Replay：在显式流程或状态模型中匹配事件，寻找相容执行。
- 被观察系统 Re-execution：重新执行工具和模型，可能产生新的外部事实。

前两种主要检验观察系统或模型；第三种产生新的实验运行。三者不能共享“已复现原过程”的结论。

3.02.8 乱序、迟到、重复和丢失

C-02-006｜P / M：流处理中的 Watermark 是依赖来源与策略的进度判断，不是所有环境中的完成证明。Dataflow 区分 Event Time 与 Processing Time，并用窗口、触发和更新表达正确性、延迟与成本的取舍；论文明确讨论启发式 Watermark 无法排除无限期离线来源迟到的数据。S-OT25

问题	错误处理方式	研究上应保留的信息
乱序	按到达顺序直接驱动严格串行状态机	源头顺序、偏序、暂缓区间与后续修订
重复投递	每条都算新动作	原始事件身份及投递身份
相同动作重试	按文本相同全部去重	Attempt、调用和上层目标的区别
丢失开始事件	看见结束就虚构一个已知开始时间	“结束已见、开始未知”的证据形态
丢失结束事件	超时后写成已失败	失联、仍运行、已结束但未收到等相容可能
迟到事件	重写历史而不标记修订	当时所知、现在所知与修订依据
时钟偏差	负耗时自动改成零	原值、时钟范围及无法直接比较的原因
解析失败	忽略后仍报告覆盖完整	原记录存在但无法解释的缺口

表中原则是综合方法论建议，并非要求某一种具体队列或数据库。尤其要避免“清洗”过程中删除无法解释的记录却提高确定性：数据质量报告和业务状态报告应保持独立。

3.02.9 Process Mining、Petri Nets 与对象中心日志

Petri Net 通过 Places、Transitions 和 Tokens 描述状态与动作；多个 Transition 同时可启用，有助于表达并发。经典 α-algorithm 从事件间的直接跟随关系推导流程结构，但其可重发现证明依赖指定的工作流网类别及完整、无噪声的日志。它不能证明任意 Agent Trace 产生的流程图就是原有真实过程。S-OT29

Process Mining Manifesto 区分发现、符合性与增强，并强调事件语义、数据质量、问题驱动提取和模型作为目的相关抽象。其 2011 年形成、2012 年出版的领域判断应按历史语境阅读，不能把当年工具成熟度陈述当作 2026 年市场事实。S-OT30

C-02-007｜P：Case Notion 是分析假设。 XES 的常见层次是 Log → Trace → Event，扩展赋予属性语义。本次核查了官方介绍而非付费 IEEE 规范全文；不能把页面概述当作完整规范验证。S-OT27

OCEL 2.0 则允许事件关联多个不同类型对象，并提供 E2O / O2O 关系限定词和随时间变化的对象属性。这适合研究同一次工具动作涉及调用、文件、任务等多个对象的情况，减少强行选择唯一 Case 导致的重复或关系损失。但规范只是表达关系的格式，不自动判断关系是真实因果，也不证明重建更准确。S-OT28

版本核查实例：本次读取的固定 arXiv 2403.01975v1 是 2024-03-04 提交、正文封面日期 2023-10-16 的 2.0 规范；其指向的原站“2.0”PDF 路径在核查日却返回 2.1.0pre5、2026-10-01 封面。未来研究应核查内容版本，不能仅以 URL 路径判断版本。

对 AI 编程任务，Case 划分还可能随问题变化：“一次用户请求”“一次测试调用”“某文件版本的生成与验证”都是合理视角。一个漂亮的任务树未必能同时表达它们，应在领域 04 检验何种投影帮助用户理解，而不是先认定树结构具有唯一真实性。

3.02.10 部分可观测重建：从单一答案退回相容状态集合

可把观察问题写成一个简单的分析模型。设 X 是允许的执行历史集合，E 是现有证据，Γ(E)⊆ X 是在明确采集及系统假设下与证据相容的历史。对属性 q：

∀ x∈Γ(E), q(x)=1 ⇒ 在这些假设下支持 q,

∀ x∈Γ(E), q(x)=0 ⇒ 在这些假设下反驳 q,

∃ x,y∈Γ(E), q(x)≠ q(y) ⇒ 尚不可唯一判定.

这是研究者用于组织证据边界的综合模型，不是宣称已实现可枚举所有 Agent 历史的算法。当证据矛盾导致 $\Gamma(E) = \emptyset$ 时，不能利用全称命题的空真值同时宣布支持和反驳；应报告模型、关联或证据存在冲突。

该模型揭示四类不同未知：未来尚未发生、过去发生但漏采、身份或关系不确定、证据版本过时。不同未知需要不同补充信息，不能统一输出“置信度 60%”来掩盖来源。

Pegoraro、Uysal 与 van der Aalst 将活动候选、时间范围和事件是否存在等不确定性显式编码，计算相容 Trace 的 Conformance Cost 上下界；方法及实验显示可能展开的组合迅速增长。边界的含义依赖所提供的不确定性集合，不能把没有纳入模型的漏失也算成已覆盖，更不能将成本区间当作真实状态的概率区间。S-OT31

概率模型如 HMM、Bayesian Filtering 可以为候选状态排序，但需要转移概率、观测似然和缺失机制。本轮已补核HMM与POMDP的原始基础（3.02.90-3.02.91）；面向Agent观察者的模型辨识与共同实验比较仍列为继续研究项。语言模型给出的数字也不会因为形式为概率就自动获得 Calibration。

3.02.11 Running、Waiting、Failed、Completed 与 Unknown

C-02-008｜K 与综合推论：静默与失败不是同一事实。 Chandra 与 Toueg 的不可靠 Failure Detector 框架以 Completeness 和 Accuracy 描述可能犯错的故障怀疑机制；本次仅核查了作者机构摘要，未取得可读全文，故不据此复述其完整证明。S-OT23

对无已知延迟上界的被动观察，存在一个直接的逻辑反例：在同一静默窗口里，“工具仍在计算”“已完成但结果延迟”“进程崩溃”“采集器断连”均可产生相同观测。因此，超时可以触发有用的怀疑或求证策略，却不能仅凭静默证明任务已经失败。若有独立存活信号、协议租约或已验证时限，这个相容集合才会缩小。

判断	可支持它的证据	必须保留的范围
已请求	记录到具体调用请求	不保证已调度或实际执行
已开始 / Running	对应操作的 start、持续运行信号或足够明确的协议状态	是哪一调用、进程或任务；信号距今多久
Waiting	明确等待输入、审批、资源或依赖的状态事件	缺乏新输出本身不是等待用户的证据
操作失败	调用或组件的明确失败结果	可能被重试、恢复或是预期测试；不自动上升为任务失败
局部终止	对应 Run / Tool / Turn 的 terminal 事件	终态语义由协议决定；仍可能有子工作或在途效果

判断	可支持它的证据	必须保留的范围
目标达成	针对明确用户目标及版本的独立结果证据	不超出验证覆盖的断言
已验证	特定检查运行并对特定对象给出结果	测试集、输入、版本、时间和检查范围
Unknown / Stale	多个候选仍相容，或最新状态已过时	表达知识状态，不伪装成一种确定执行状态

C-02-009｜P：相同终态词跨协议不能直接映射成“成功”。 当前 MCP Tasks 扩展草案允许工具结果含 isError:true 时 Task 仍为 completed，而 failed 表示另一层协议错误；Codex 的完成事件也有细分结果语义。该反例说明必须读取结果类型和状态定义，而不只匹配 completed 字符串。S-IF09 S-IF03

研究者综合建议：分析时区分执行生命周期、外部效果、验证状态和观察健康四种维度。它们可以相关，却不是同一条从“开始”到“成功”的线性进度轴。这是用于避免概念混淆的研究表示，不指定 Yukio 状态模型。

3.02.12 Runtime Verification：显式性质的三值判断

C-02-010｜K：有限前缀的 LTL 监测具有“满足、违反、尚不可判”的严格条件。 Bauer、Leucker 与 Schallhart 给出的 LTL3 语义考察当前前缀的所有可能未来：所有延伸均满足属性时为 true，均不满足时为 false，两种延伸均存在时为 inconclusive。Runtime Verification 检查已观察运行的显式属性，与证明系统所有运行正确不同。S-OT32

例如，“这次执行最终出现某个结果”在结果出现之前可能仍不可判；“每次文件写入前获得有效授权”需要能观察写入和授权命题并正确关联。属性选择、状态抽象和事件覆盖都影响结论。

两点边界尤其重要：

- 有限前缀意味着未来未被观察，不等于过去中间事件丢失。把漏采序列当作完整前缀交给 Monitor，可能得出错误的确定性判断。
- 观察到相同抽象状态反复出现，不足以证明真实系统陷入无限循环；隐藏状态可能仍在变化。这也是该论文对部分状态观察的明确讨论。S-OT32

“尚不可判”因此既可能是逻辑的正常输出，也可能来自观测不足，但两者理由必须区分。显式属性监测是一条值得继续调查的成熟理论路线；把自然语言任务自动转成正确完备属性仍是独立开放问题。

3.02.13 比较后的关键发现

主张	支持程度与来源范围	不能推广成什么
身份和关系语义比单纯时间线更基础	分布式系统理论、Trace 规范、Magpie 方法共同支持	任意相邻事件都能自动建立真实任务关系
并发执行通常只有偏序	Lamport / Mattern 的明确模型结果	所有 UI 都必须呈现完整偏序图
全局完成依赖参与范围和在途工作	分布式快照与协议反例支持	某个通用 completed 事件足以完成所有判断
Event Sourcing 有严格输入前提	权威工程论述及 Replay 条件支持	任何日志文件均可无损恢复全过程
流程发现和符合性检查回答不同问题	Process Mining 文献与形式化条件支持	高频路径正确、偏离路径错误
Unknown 可以是正确且必要的输出	不可区分反例、LTL3、显式不确定 Trace 方法支持	所有问题都无法判断，或系统只能放弃解释
低层证据和高层目标之间仍有语义缺口	Provenance 近似、Agent 方法证据范围与协议差异支持	使用更大的语言模型便能消除这个缺口

3.02.14 开放问题与继续调查顺序

优先级 / ID	研究问题	依赖与进一步核查要求
P0 / RQ-02-01	能否建立保持原始语义的跨客户端概念映射?	固定接口版本；为无法等价映射的状态保留区别
P0 / RQ-02-06	如何定义可被独立验证的局部和聚合完成?	明确任务范围、动态子工作、在途效果及验证对象版本
P0 / RQ-02-05	漏采时哪些属性仍可安全判定?	研究观测契约、保守状态集与可判定性质，不能只随机删事件
P1 / RQ-02-02	多来源关联的错误怎样传递到状态与解释?	有关联 Ground Truth 的数据；区分错误边和缺失边
P1 / RQ-02-07	集合推断、概率估计和语言模型推断如何比较?	基础原始方法已补；进一步比较观测模型、校准与分布外测试
P1 / RQ-02-08	哪些用户关心的性质可写成可靠 Monitor?	形式化属性与用户目标的内容效度；过去漏采与未来未知分开
P2 / RQ-02-04	Object-centric 模型是否更利于长程 Agent 分析?	比较单一 Case、对象图与多视图；计算成本和用户理解均需评价
P2 / RQ-02-03	若无法修改参与方，能重建多少因果偏序?	比较显式 ID、Schema 关联与统计方法，不把启发式边当事实

3.02.15 与其他四领域的接口

与领域 03 的连接是支持关系：一句解释需要知道所据事件的身份、时间、版本、观测范围和是否存在相容反例。与领域 04 的连接是抽象损失：把并发图投影为时间线、任务卡或进度条，会保留或隐藏不同事实，必须测量用户实际理解。与领域 06 的连接是决策条件：故障怀疑不等于值得打断用户，需要结合可行动性、成本与后果。与领域 07 的连接是可分层评价：事件是否被观察、关联是否正确、状态是否成立、解释是否有证据，是可以分别出错的阶段。

这些连接是本次跨学科综合推论；它们尚不能代替端到端用户价值的实证研究。强观测不保证强解释，准确局部状态也不保证合适介入。

3.02.90 概率状态估计与POMDP：补充的成熟理论路线

C-02-902｜K / M：概率状态分布和最可能的单一状态不是同一对象。 Kaelbling、Littman与Cassandra的原始论文将POMDP分为状态估计和策略选择。在有限状态、给定转移模型T与观测模型O的表述中，旧信念b、已知动作a和新观测o更新为：

$$b'(s') = \eta\, O(s', a, o) \sum_{s} T(s, a, s')\, b(s).$$

其中η是归一化常数。第一部分根据动作预测状态，第二部分用观测似然修正；信念是状态上的分布。论文所述“充分统计量”依赖正确的模型和更新，不能把任意自然语言摘要称为具有该性质的belief state。S-MT01

POMDP进一步把行动对世界的影响、获得信息的作用和收益纳入策略。即使只想理解“是否值得再询问一次”，也必须知道信息可能怎样改变决策，以及等待和行动的成本。原论文明确假定可获得完整正确的世界动态与奖励模型，并讨论枚举状态及精确求解的复杂性；本轮未核验其所有算法证明或后续求解器性能。

研究者综合： 对被动观察者，估计状态不必等同于控制被观察Agent。可以只研究过滤过程；若进一步选择查询、求证或通知，则需要定义观察者自己真正可执行的行动。将“未知”编码为某个隐状态、把漏采建模成随机噪声、假定状态只依赖上一步，都是模型选择，需要数据支持。事件因故障而更易丢失时，随机独立缺失假设可能恰好在重要场景失效。

基础理论说明怎样进行有条件推断；它不保证模型参数可从现有Agent记录中辨识，也不证明POMDP或HMM优于保守集合、显式规则或语言模型。面向Agent Observer的共同数据比较仍属ORQ-07。

3.02.91 Hidden Markov Models：三种不同的推断问题

C-02-011｜K：HMM 将不可直接观察的状态，与由该状态概率性产生的观测分开。 Rabiner（1989）的标准模型用 $\lambda = (A, B, \pi)$ 表示转移、观测与初始状态分布。基础版本假定一阶 Markov 性、时间齐次转移，并在给定隐藏状态序列时将各时刻观测条件独立地生成。这些是建模假设，不能因为事件被排列成序列就认为成立。S-MT02

三类问题	对应方法	输出含义
给定模型，观测序列有多大似然?	Forward 动态规划	$P(O \mid \lambda)$，用于评价观测与模型的相容程度
给定模型和观测，如何选择状态序列?	Viterbi；或以 Forward-Backward 求逐时刻后验	前者求联合最优路径；后者支持各时刻边缘概率
如何估计模型参数?	Baum-Welch / EM	迭代改进训练数据似然，通常只保证达到局部临界点

三类问题不能混为“恢复真实状态”。逐时刻分别取最大后验，可能组合成模型禁止的状态转移；Viterbi 的最优是相对于指定模型及整条路径目标，而不是对真实过程的确定性证明。原文还指出基础自转移结构隐含几何型持续时间分布，并讨论显式时长模型扩展。S-MT02

研究者综合推论：用于事件观察时，必须先回答“隐藏状态是什么”“哪些记录是观测”“缺失是否依赖当前状态”，并核查模型外行为。将静默编码为普通观测，与因采集故障造成缺失，是不同生成过程；若两者混合，计算准确的后验仍可能回答错误的问题。训练似然提高也不保证状态标签拥有用户需要的意义，或概率已经在新任务上校准。

本轮读过原论文 §II 的定义、 §III 的三问题与关键算法、 §IV.D 的时长限制；未复核语音识别实验，也未进行 Agent 实验。HMM 是成熟的候选推断基础，是否优于规则、集合推断或其他概率模型，仍依赖具体观察条件和独立评价。

3.03 领域 03 - Evidence-Grounded AI Explanation

3.03.1 知识地图与研究问题

本领域研究的是：给定一组有限、可能延迟或矛盾的活动证据，能够合理说出什么，以及如何让读者检查这些说法。这里至少存在两种不同对象：对可见执行过程的证据解释，以及对模型内部决策机制的解释。两者共享“解释”一词，但证据和验证方法不同。

研究问题 ID	知识分支	核心方法	前置知识与边界
RQ-03-01	主张、证据与语义支持	AIS、事实分解、蕴含检验	必须明确陈述的主体、时间、对象、范围
RQ-03-02	Provenance 与证据沿革	W3C PROV、实体版本、生成与使用关系	来源关系不自动证明来源真实或存在因果影响

研究问题 ID	知识分支	核心方法	前置知识与边界
RQ-03-03	有依据的语言生成	抽取、模板、RAG、受约束生成、生成后核验	要区分检索未找到与世界中不存在
RQ-03-04	Faithfulness	因果干预、行为预测、CoT 扰动	不能用流畅度或用户赞同替代机制忠实性
RQ-03-05	不完整、冲突、过时证据	拒答、局部回答、限定性表达、主张修订	“未知”需要保留原因及适用时间
RQ-03-06	解释器自身可靠性	对抗证据、引用失效、证据污染测试	被观察材料也可能包含针对解释器的指令
RQ-03-07	解释的实际理解价值	证据定位、理解题、行为预测、错误识别	主观可信、满意度、客观理解是不同结果

依赖关系为：01 的观察能力决定可供使用的材料；02 决定记录身份和时间语义；03 对主张与证据建立关系；04 检验人是否理解这些关系；06 才能判断何时值得介入；07 则贯穿上述各层。该关系是本研究的综合框架，不是任一论文直接验证的完整因果链。

3.03.2 六个容易混淆的概念

C-03-001〔K；概念区分〕：可追溯、被来源支持、客观正确、机制忠实、易理解，不能互相替代。 Jacovi 与 Goldberg 区分解释的 plausibility 与 faithfulness：前者关注对人是否有说服力，后者关注是否反映模型产生预测的过程。他们的文章是概念与评估立场论述；它不提供一个适用于所有解释的已完成检验器。S-GE02

概念	应回答的问题	不足以证明它的证据
Evidence grounding	这句话是否由指定证据支持?	仅有相关关键词或一个可点击引用
Attribution	陈述的哪些信息可归于哪些来源?	来源恰好包含同一主题
Provenance	证据由谁、何时、经什么活动产生和变换?	单独一个无版本网页或日志路径
Factual correctness	这句话在指定现实、对象和时间下是否正确?	来源自己如此声称
Mechanistic faithfulness	解释是否反映真实决策过程或因果因素?	模型自述、事后叙事、读者认为合理
Comprehensibility	读者能否准确理解、使用或复核解释?	句子语法正确或文风简洁

这一区分可通过反例理解。日志真实记录“Agent 声称已完成全部测试”，只支持“Agent 作出了该声明”；当声明本身错误时，这仍是一条真实的观察记录。反过来，外部解释偶然说对了“测试通过”，若当时没有可用测试证据，它依然不是合格的有依据解释。这两个例子是逻辑分析，不是实验发现。

AIS 将“陈述连同语言上下文和时间”作为理解对象，并要求先明确其可解释含义，再判断是否可归于所提供的来源；轻微细节改变、遗漏关键条件也可能使输出不充分可归因。AIS 的人工研究覆盖会话问答、摘要和表格到文本，支持这种标注框架的可操作性，不能据此保证执行日志领域的准确率。S-GE03

还应避免把不同文献中的 attribution 合并。PROV 中的 attribution 是把实体归于负有责任的 agent；NLG 中的 attribution 通常指一句话受到某个来源的支持；特征归因则研究输入特征对输出的贡献。三者不是同一种关系。

3.03.3 Provenance 的能力与限度

W3C PROV-DM 以 Entity、Activity、Agent 为核心，描述使用、生成、衍生、责任、委托等关系，并允许对 provenance 本身表达 provenance。版本化文件、一次测试执行、测试报告及生成报告的工具，都可以拥有不同的身份。S-GE01

C-03-002〔K；规范边界〕：记录“活动使用了 A，又产生了 B”还不足以证明 B 派生于 A。 PROV-DM §2.1.2 明确要求实际影响，且不规定怎样发现这种影响。因而将工具调用排在读文件之后，不足以证明该文件影响了决策；日志的父子关系也不能单独替代因果验证。S-GE01

将此思想应用到活动解释，本研究提出以下证据身份维度〔研究综合，M〕：原始工具结果、经过过滤或脱敏的结果、Agent 实际可见的输入、采集器获得的记录、解释器检索到的片段、最后显示的主张，应被视为可能不同的对象。相同字段名或相同文件路径不保证内容相同。客户端可能修改、截断或替换工具结果；相应当日接口证据见本知识库 S-IF01。

需要保留的信息	为什么影响解释成立
原始记录 ID、所属运行与调用 ID	防止把不同尝试或并发任务拼接成一条故事
发生时间、接收时间、适用版本	防止把旧结果、迟到记录当成当前状态
记录产生者与观察位置	区分进程实际退出、包装器报告、Agent 自述
截断、脱敏、转换及其版本	判断未看到某内容是源中没有还是处理中被删除
证据与主张的对应片段	让支持关系可以逐项审阅
更正、撤回及替代关系	允许后续证据更新早先判断

以上是用于研究的可追溯性要求，不是数据库设计。哈希可协助核对某份已保存材料是否改变，但不能证明材料产生时为真；可追溯关系也不能弥补最初采集不到的信息。

3.03.4 观察事实、Agent 自述与外部推断

C-03-003〔研究综合，M〕：解释应保留证据类型的差异，避免从“看到了声明”跨越到“声明内容已被独立验证”。

信息类别	合理表述示例	需要额外证据才能说出的内容
直接观察的记录	“记录显示调用了测试命令”	测试实际启动、全部执行、覆盖需求
工具或环境报告	“该测试进程返回退出码 0”	所有测试通过、实现无缺陷、用户目标完成
Agent 自述	“Agent 报告已完成修复”	修复有效且已验收
外部模型综合	“这些操作可能在定位配置问题”	Agent 当时的真实动机就是该解释
独立验证结果	“指定版本在指定测试集上满足判据”	未测试环境也正确

CoT 研究提供了为何不能将自述当作内省真值的直接反例。Turpin 等通过改变选项顺序和提示性答案，发现被测模型的回答发生系统变化，但理由文本往往不提这些影响因素；结果仅对应其 2023 年模型与实验任务。S-GE04 Lanham 等通过截断、插错、改写 CoT 等干预，发现不同任务和模型的依赖程度明显变化，且明确说明单项测试并不构成忠实性的决定性证明。S-GE05

不能把反例扩大成“CoT 永远无用”。 Bentham 等复查有关量度后发现，选项偏好及准确率会混入部分忠实性分数，说明连“测量不忠实”的指标也需接受效度审查。这项研究限制了普遍尺度规律的解释，并未证明所有

CoT 都忠实。S-GE06 对观察器而言，可见推理文本是可研究的行为材料；只有通过匹配研究目标的检验，才能论证它额外提供了什么信息。

3.03.5 从活动记录生成解释的不同技术路线

下表中的适用性是机制分析与研究综合，未进行 Yukio 横向实测。真实采用和成熟程度也不相同：标准化 provenance 已有规范，RAG 指标已有论文与公开工具，但“通用活动解释正确性保证”仍不存在于这些来源的证明范围。

方法	机制与输入	可解决的问题	主要限制与适用条件
原始记录或抽取式展示	保留原句、字段、位置	降低新生成事实的机会，便于核对	读者负担高；截取可遗漏否定、上下文或版本条件
确定性模板	明确事件语义映射为有限句型	对已定义操作、退出码、状态转换给出稳定说明	模板正确依赖字段契约；不能自动解释开放任务意义
检索增强生成	先选证据，再用模型综合	从大量材料选出与问题相关的活动	检索遗漏与生成错误是两种误差；引用不能自动保证支持
先形成结构化主张再实现语言	限制可说出的主体、谓词、对象、证据	便于审查身份、时间和范围	开放活动难以穷尽；语义映射本身可能错
生成后事实分解与核验	将输出拆为主张，逐条寻找支持	定位局部无依据内容，支持修订	分解可漏掉关系、共指、因果与整体矛盾
语义蕴含模型/NLI	以证据为前提、主张为假设	区分支持、冲突、信息不足	专业日志、长上下文、数字、否定和量词需要域内验证
人工复核或选择性回答	将不可判断主张交给复核，或只回答可支持部分	限制误导，暴露信息缺口	人力与延迟成本；高拒答可能牺牲信息价值

ALCE 将引用支持和输出内容质量分开评价，说明它们可独立变化。S-GE07 FActScore 提供事实分解与逐项支持检查范式。S-GE08 本表不据此推出“复杂流水线必优于模板”：输入契约明确时，简单方法可能更可靠；开放解释中则必须单独检验增加模型后的增量价值。

结构化输出约束应与语义验证分开。OpenAI的Structured Outputs官方文档明确提醒，符合Schema的结果仍可能包含错误，输入与结构要求不相容时也可能出现编造以满足结构的情况。因此，格式合法可以支持解析和字段检查，不能单独证明某条活动解释得到证据支持。S-IF13

3.03.6 一句话怎样接受证据核验

把“已修复登录故障并通过所有测试”拆成“发生了修改”“修改解决故障”“测试执行完成”“测试全部通过”“这些测试适用于当前版本”，会暴露它实际上包含多个可独立失败的主张。拆分时又不能删除关系：某些测试通过并不意味着它们验证了该修复。

可研究的主张核验至少包含六层〔研究综合，M〕：

1. 身份对应：主张与证据指向同一 task、run、tool call、文件和版本。
2. 证据存在：引用能够解析，引用片段属于保存的原始材料。
3. 语义支持：证据足以支持陈述，而非仅与主题相关。
4. 范围一致：部分测试不被写成全部测试，一次调用不被写成整项任务。
5. 时间有效：过去成功不自动说明当前仍然成功。
6. 整体一致：逐项成立的信息不能错误拼接成同一个主体、同一次执行或同一因果过程。

第六层有直接反证。Chiang 与 Lee 在人物传记中展示了一个问题：来自多个同名人物的事实，可能逐条被检索来源支持，却组成错误的“单个人物”传记；其 D-FActScore 是针对这种错误提出的方法，不是所有一致性问题的通用解决方案。S-GE29 向 Agent 记录的迁移是本研究推论：多个同名文件、重复调用、重启后的 run 也可能出现类似拼接错误，必须另行验证。

FEVER 使用 Supported、Refuted 和 Not Enough Info 三类，并要求为部分标签提供证据集合。这为“证据不够”和“已有反证”的区分提供成熟任务范式；但百科语句验证的表现不能直接迁移成日志状态识别能力。S-GE30

3.03.7 引用评价、事实精确度与遗漏

C-03-004〔M/E；方法已发表，能力有界〕：引用存在、引用正确、内容完整至少是三个独立评价目标。

ALCE 的 citation recall 近似问“输出的陈述中，有多少被所引材料充分支持”；citation precision 关注引用是否相关，且其自动判据涉及单个引用和合并引用的蕴含关系，并不要求最小引用集。论文还明确讨论部分支持、冗余引用造成的评价边界。S-GE07

因此，活动观察器需要另一个分母：已知重要事实中有多少被准确呈现。它与“已生成陈述中有多少被支持”不同。只输出“系统正在工作”可能少犯事实错误，但完全遗漏失败、未验证版本和等待条件。以下为研究操作化建议〔M〕，不能冒称 ALCE 原始定义：

评价对象	示例指标	关键风险
主张是否成立	受支持主张数／可判定主张数	无法判定主张不能无声排除，应另报比例
引用是否指对证据	正确支持链接数／全部引用链接数	不能只检查链接存在
重要事实是否遗漏	准确呈现的重要事实数／标注的重要事实数	“重要”依赖用户问题，需要预先标注依据
是否扭曲结论	严重范围、版本、因果错误发生率	大量低风险真话不能稀释一次关键误导
是否可复核	成功定位证据的比例与耗时	客观可定位不等于用户一定理解

C-03-005〔E；防止指标误读〕：FActScore 摘要中的“小于 2% error”不能解读为逐条事实识别错误率小于 2%。原文 §4.2 的 ER 是估计系统总体 FActScore 与人工分数的差；附录 B.2 展示个体判断质量与总体分数误差可能对两个评估器给出相反排序。主实验主要是人物传记/Wikipedia，并有小规模其他内容探索，不能把该数字转成任意活动解释的性能承诺。S-GE08

RAGAs 提出无需人工参考答案的 RAG 自动评价，但它仍依赖输入问题、上下文、生成答案及模型评判，原始 WikiEval 验证并不覆盖真实 Agent 全部失效类型。S-GE09 ARES 通过合成训练数据、专门的评判器及少量人工标签进行 prediction-powered inference；它提供的是条件明确的统计评价方法，而不是免人工、免分布假设的正确性保证。S-GE10

FACTS Grounding v1 同时检查是否实质回应请求以及是否忠于给定长文档，避免空泛但“不犯错”的输出获得虚高评价；它使用多个评判模型，仍是指定任务与评判流程下的基准。S-GE11 2025 年 FACTS suite 已扩展不同事实性维度，故后续引用必须写清版本和子基准，不能把不同 leaderboard 口径混在一起。S-GE35

3.03.8 不完整、矛盾和过时材料

证据充分性不是一个固定数值，而取决于要说的具体命题。例如，调用开始记录足以支持“已请求测试”，不足以支持“测试通过”；终止记录可能足以支持“一次调用结束”，不足以支持“用户任务完成”。本知识库的接口核查还提供了协议性反例：不同系统的 completed 可能表示不同层次的结束，见 S-IF03、S-IF09。

证据问题	合理研究处理	不应进行的推断
没有终止事件	说明最近可见动作、采集健康、未知原因	静默等于完成，或静默等于卡死
时间戳冲突或迟到	保留来源时间与接收时间，允许更正	按收到顺序强行构造真实先后
自述成功而工具报错	展示冲突的来源及各自范围	自动把更流畅、更新或更权威措辞视为真
成功测试之后继续改代码	将验证归于当时对象和环境	当前版本仍然已被验证
证据被截断、脱敏	明确这是观察缺口	将看不见的内容标为不存在
多来源一致	检查是否转述自同一原始来源	把复制的同一消息计为独立佐证

这些处理是证据语义的综合要求，不预设一个统一冲突消解算法。有些矛盾来自语义范围不同，有些来自来源错误，有些来自状态真实改变；“最新覆盖旧值”不能解决所有情况。

3.03.9 解释器可能受到被观察材料影响

AgentDojo 将外部工具数据视为潜在 prompt injection 载体，并分别评价正常任务效用与攻击目标达成。其任务判定采用程序检查；论文特别指出，攻击也可能影响依赖 LLM 的评价器，因此评价器不能自动当作独立裁判。S-GE12

C-03-006〔研究综合，H/M〕：活动日志、代码注释、文件文本、搜索结果中的指令式内容，可能污染外部观察器的解释。 这是从 tool-data attack 面向观察器的威胁模型迁移，尚不是 Yukio 受攻击的实证。研究上应区分“记录确实包含该句”与“解释器应执行该句”，也应调查证据选择是否会被诱导只保留成功材料。引用链完整并不能阻止恶意来源本身制造错误事实。

3.03.10 理解性、可信感与忠实性

不存在一个由本轮证据支持的普遍定律，保证更短、更拟人或更多解释必然提高准确理解。Hase 与 Bansal 以预测模型行为的实际任务评价解释，发现有效性依方法和任务而异，主观评分没有显示可靠预测客观表现的证据；作者也说明这不等于证明二者绝无关联。S-GE26

由此提出的研究区分〔M〕是：一类实验测试“人觉得是否清楚”；另一类测试“人能否准确说出执行了什么、哪些结果已验证、哪些仍未知”；第三类测试“人能否据此作出恰当行动”。三种结果可能相关，但不能互相充当替代终点。因果机制忠实性还需要相应干预证据；不能用上述理解题直接证明。

3.04 领域04 - Human-AI Interaction & Visualization

3.04.0 Knowledge Map：从可见信息到可用理解

本领域的核心对象不是“界面显示了多少 Agent 活动”，而是人在具体目标下，是否形成足够准确、可更新、知道边界的认识。应区分六个研究分支：

分支	核心问题	主要知识与方法	外部依赖
04-A 认知表征	用户知道系统能做什么、当前发生什么、下一步可能怎样吗?	Mental Models、Situation Awareness、任务知识、工作记忆	01 的观察边界；02 的状态语义
04-B 信任与依赖	用户何时接受、核查、拒绝系统信息?	Trust Calibration、Automation Bias、客观依赖行为	07 的能力估计与基准

分支	核心问题	主要知识与方法	外部依赖
04-C 解释需求	谁在何时需要回答什么问题?	Stakeholder Knowledge、Why/Why-not/How/What-if、对比性解释	03 的事实、归因与忠实性
04-D 信息组织	如何支持总览、定位、关联与证据检查?	时间线、任务结构、关系图、摘要、差异视图、渐进披露	02 的身份与因果关系；03 的来源链接
04-E 共同活动	用户如何表达目标、分配工作、修正计划?	Mixed Initiative、Co-Planning、Steerability、直接操纵	06 的介入策略；实际控制权限
04-F 效果验证	界面是否改善实际理解，而不只是满意度?	有标准答案的问题、预测/纠错任务、行为记录、访谈、纵向研究	07 的 Ground Truth 与研究设计

这六个分支相互约束。例如，状态标签错误是 02 的问题；把正确标签显示得很清楚，不能消除该错误。反过来，即使状态重建准确，如果用户把“命令执行完毕”理解成“用户任务已经验证完成”，仍然产生 04 层面的理解失败。

3.04.1 概念边界：应分别测量什么

3.04.1.1 Situation Awareness 与 Mental Models

C-04-001 [K/M]：Endsley 将 Situation Awareness 区分为对相关要素的感知、对当前情境意义的理解、对未来状态的预测。原框架面向动态系统，并将注意、记忆、目标与经验纳入分析；它不是“只要提供完整仪表盘就能产生情境意识”的定理。S-HI01

应用这些概念时，可以提出三类不同问题：“哪一个进程还在运行？”属于当前要素识别；“测试失败意味着哪一项工作尚未验证？”要求把信息与任务目标关联；“如果继续等待，哪些状态变化会支持或推翻当前解释？”涉及预测。最后一类不要求用户猜中未知未来，而要求区分条件预测、正常预期与无法判断。

C-04-002 [K/H]：Mental Model 指对系统怎样运作的内部表征；当前情境表征则对应这一时刻发生了什么。一个熟悉测试流程的人可能因日志缺失而误判当前运行；一个能复述当前日志的人也可能不知道重试、子进程或异步测试怎样影响结果。Endsley 对心理模型支持情境理解的具体机制包含假设，不能将整套因果路径都标作已经实验确证。S-HI01

研究者综合：观察界面可能需要同时支持“正在发生什么”和“这种信息能说明什么”。后者包括来源的可见范围。例如，“没有观察到写入”能否解释成“没有写入”，依赖观察通道是否覆盖该文件系统；这不是用户阅读能力可以弥补的知识缺口。必须把观察的局限作为需要理解的对象之一。

3.04.1.2 信任、满意度、理解与依赖不是同一变量

C-04-003 [K/H]：本知识库采用以下操作性区分。Lee 与 See 的经典研究把适当依赖作为重要目标，并强调情境和自动化特征；本轮只核到其原摘要，详细理论分类需补全文。本表是结合原始实验结果提出的测量分解，不冒称为该论文逐字分类。S-HI02

构念	可操作问题	不能用什么替代
Trust，信任态度	用户认为系统有多可靠、是否愿意在不确定时依赖它?	点赞、视觉美感、单次接受结果
Reliance，实际依赖	用户何时直接采纳、独立核查、修正或拒绝?	自报“我信任”
Trustworthiness，实际值得信赖程度	在规定任务和条件下系统真实表现怎样?	自信语气、品牌、解释长度

构念	可操作问题	不能用什么替代
Comprehension，理解能力	用户能否准确回答、识别矛盾、推断证据边界？	自报“很好懂”
Simulatability，可模拟性	用户能否预测模型在一个输入上的输出?	发现输出错误的能力
Satisfaction，可接受性	使用是否顺手、舒适、符合偏好?	正确完成任务或合理依赖
Steerability，可引导性	用户能否把系统带向所需行为?	按钮存在、用户认为能控制
Verification，验证行为/结果	用户是否检查；检查是否足以支持目标主张?	打开证据、阅读时长、勾选确认

“信任校准”因而不等于让用户更信任系统。对某类任务可靠、另一类任务不可靠的系统，合理行为可能是有条件地采用。过度警惕也可能使用户放弃有用信息，增加重复劳动。评估应同时观察正确建议被合理采用、错误建议被合理质疑，以及用户判断的置信程度是否对应实际正确率。

一个容易忽视的统计问题是：只有在存在分歧机会时，才能观察有意义的依赖选择。用户与 AI 原本给出相同答案时，最终答案正确不能说明用户认真评估了 AI；用户总是独立判断也可能与 AI 高度一致。需要记录初始判断、看到建议后的变化及证据，而不能仅用最终一致率衡量依赖。

3.04.1.3 认知负担不是界面元素数量

C-04-019 [K/H]：认知负担研究关注有限资源在活动之间的竞争。Sweller 的原工作处于问题解决与学习情境，本轮仅核摘要；不能据此推导“三张卡片最佳”或“树形结构必然比文本省力”。S-HI27

研究者综合：阅读一段短摘要可能比扫描一张较长表格更困难，取决于摘要是否要求用户记住事件编号、恢复隐含因果关系或来回比对窗口。应把搜索、记忆、解释、核查、切换和操作成本分别考虑。压缩字数如果删除了状态条件，可能降低表面复杂度、增加判断成本。总信息量和单次必须处理的信息量也应分开。

3.04.2 Human-AI Interaction 的理论与设计研究

3.04.2.1 指南的证据边界

C-04-004 [M/E/P]：Amershi 等提出 18 条 Human-AI Interaction 指南，覆盖初始能力说明、运行中的相关信息与时机、错误恢复、长期反馈和控制。其四阶段研究包含 49 名从业者对 20 个产品的修改版启发式评估，主要检验指南的清晰度与适用性；这不是“执行 18 条指南后普通用户理解必然提高”的实验。S-HI03

这些指南可用来发现遗漏的问题：用户是否知道系统能观察什么；能力或可靠性改变时是否有相应认识；系统猜错后能否获得纠正；用户能否表达不感兴趣或改变目标。然而，指南符合度、可用性缺陷数量、客观理解、最终任务效果是不同结果，不能按同一分数解释。

3.04.2.2 用户需求不能只按“专家/普通用户”划分

C-04-005 [M]：Suresh 等把知识背景与解释需求分开，区分正式知识、实践操作知识、个人情境知识及其所在领域。其框架通过文献应用与研究实例评估描述能力，不是经随机实验验证的自动个性化规则。S-HI04

研究者综合：不会编程的项目负责人可能非常了解交付标准；软件工程师可能不熟悉所观察客户端的事件语义。两者都不能统一当作“低理解能力用户”。对于观察研究，至少应记录目标领域知识、软件工作流知识、该 Agent 的使用经验、观察工具经验，以及对任务结果负责的程度。技术解释所需细节与决策所需证据也可能不同。

3.04.2.3 以问题定义解释，而不只定义解释形式

C-04-006 [M/E]：Liao 等的 20 名从业者访谈形成面向用户问题的解释设计框架；Miller 的社会科学综述说明解释常具有选择性、对比性和交互性质。二者支持先识别解释目标，但不直接证明某一种自然语言解释对所有用户更有效。S-HI05 S-HI06

在 Agent 场景中，以下问题具有不同的证据需求：

用户问题	所需解释内容	无证据时不能替代的结论
“刚刚做了什么？”	可识别活动、时间范围、对象与结果	从计划文本补出未观察到的执行
“现在为什么还没完成？”	已知依赖、活动状态、等待条件	从沉默推断卡死、思考或偏题
“它说通过了，在哪里验证的？”	测试对象、执行版本、结果证据	用 Agent 自述当验证本身
“为什么改这个文件？”	可见指令/计划与实际修改的联系	在缺少记录时断言内部真实动机
“为什么没改另一个文件？”	相关预期、覆盖范围与未执行证据	用不存在的完整世界状态证明否定
“我现在应当做什么？”	可行动选项、价值与成本、权限边界	把一个异常标签自动升级为要求介入

这张表属于研究者综合：解释形式应受问题与证据约束。对比问题往往还需要一个 foil，即用户拿什么替代情形作比较。观察系统不知道用户原本预期时，解释可能很流畅却回答了错误问题。询问用户预期是一种可能的研究路线，但其打断成本属于 06，不能默认每次都值得询问。

3.04.3 反例：透明度、解释与理解为何可能分离

3.04.3.1 看到模型机制不保证善于纠错

C-04-007 [E]：Poursabzi-Sangdeh 等的预注册研究涉及 3,800 名参与者，使用公寓估价任务操纵线性模型特征数量和透明度。较简单透明模型更易被模拟，但并未相应改善各类依赖行为，透明条件还可能削弱对大错误的修正。作者提出信息过载解释，但没有直接过程测量证明这个机制。S-HI07

本研究的价值在于拆开“能够算出它会说什么”和“能够判断它是否应该这样说”。不能由此反推所有透明界面有害；任务、特征、错误类型与用户原有知识都限定结论。对于 Agent 观察，也不应把用户准确复述工具顺序直接解释为理解了任务是否成功。

3.04.3.2 促使用户思考也存在代价

C-04-008 [E]：Buçinca 等在 N=199 的营养选择实验中比较解释与多种 Cognitive Forcing Functions，例如先作判断、按需获取建议等。部分过度依赖指标改善，但完整决策与子任务指标并不一致；更强迫思考的设计也有主观偏好和认知成本权衡。S-HI08

因此，增加确认步骤需要同时回答“促进了什么思考”和“减少了什么错误”。一个让用户慢下来但没有提高鉴别能力的弹窗，不能因其增加停留时间而被称为有效监督。反过来，用户不喜欢某种检查也不能单独证明它没有价值。效益与可接受性的权衡需要明确目标后测量，而不是把满意度最大化当作所有解释研究的共同目标。

3.04.3.3 解释的流畅性与证据的充分性应分开

C-04-017 [H]：对第三方观察者而言，至少有三种可能相互独立的表现：叙事是否容易读懂、每个主张是否得到记录支持、用户是否知道叙事漏掉了什么。可能存在“事实句都正确，但整体暗示已全部完成”的解释；也可能存在忠实但难读、因而无人查看的解释。此分解是本研究跨 03/04 的推论，尚未被本轮实验直接验证。

一个研究用反例是：记录显示“文件已修改；启动了测试”，摘要写成“修改并测试了问题”。各词可能有日志依据，但读者容易把“测试了”理解为“测试通过并验证了问题”。应研究动词、时态、限定范围、未知状态如何影响判断，而不只统计摘要事实错误。

3.04.4 可视化方法比较：编码的含义必须受证据约束

C-04-009 [K/M]：Shneiderman 的任务/数据分类提供总览、定位、筛选、关系与细节等分析维度；Munzner 的嵌套模型区分领域问题、任务和数据抽象、视觉编码/交互、算法层。它们提供选择与验证方法的框架，没有给时间线、树或图一个普适排名。S-HI09 S-HI10

C-04-010 [H，技术比较综合]：以下比较基于表示所保留的信息及其逻辑前提，不是同条件用户实验得出的效果排序。

形式	适合回答的问题	所需数据/前提	容易产生的错误理解	适用边界
活动时间线	什么先后发生，哪里有等待或重试?	活动标识、时间语义、开始/结束区间	把到达顺序当执行顺序，把邻接当因果	并发宜保留重叠；无起点不能伪造持续时间
按 Session/Run 分组的列表	哪个执行属于哪个上下文?	足够可靠的身份关联	把共享目录中的其他执行合并	标识不可靠时应保留未归属活动
任务树/计划树	目标被怎样分解，哪些子项有结果?	计划来源、版本、层级与状态映射	把 Agent 自拟计划当用户目标，把勾选当验证	动态重规划会改变分母与父子关系
因果图/依赖 DAG	哪些活动依赖哪些输入/产物?	可证实的依赖边，或明确标为推断的边	有连线即有因果，未连线即独立	只有时间戳不能恢复完整因果图
解释卡片/自然语言摘要	当前最有关的情况是什么?	事实选择、归因、范围与证据链接	把信息筛选误认成完整记录	适合概括；不承担原始记录的全部信息
Diff/产物视图	什么内容或结果发生变化?	可对应的前后版本、对象和外部更改信息	把差异全归因给同一 Agent，或认为差异正确	差异是结果证据，不是动机或质量证明
状态矩阵	多任务中哪些在运行/等待/未知?	各状态定义与更新时间	一个绿色图标同时代表结束、成功、已验证	适于比较；需明确状态维度和失效条件
总览＋按需证据	快速了解后如何核查关键点?	稳定来源定位、可回到原上下文	以“可点击”替代真实证据可用性	折叠默认值可能改变哪些信息被实际看到

3.04.4.1 Progressive Disclosure 的双面性

渐进披露可以把初始关注集中到少量信息，同时保留追查入口。但“细节可以展开”并不表示用户知道何时需要展开，也不表示摘要遗漏可被察觉。对核查任务而言，需要研究用户能否知道自己尚未检查哪些内容，以及摘要不确定性是否足以触发适当检查。此处是待检验的界面假设，不是把经典 overview-first 原则升级为确定效果。

C-04-015 [H]：可以把披露成本分为发现证据入口、理解证据为何相关、定位原始上下文、评估支持关系四部分。点击次数只覆盖第一部分的一小部分。一个只有一次点击但打开巨大原始 JSON 的引用，可能比需要两次选择但定位精确的引用更难核查。应依据核查完成率、准确率与耗时比较，不能预先指定路径长度的最佳值。

3.04.4.2 进度显示需要一个明确分母

C-04-011 [E/H]：Harrison 等对 N=22 参与者的短时进度动画研究表明，运动函数可影响主观耗时判断；它没有证明对开放式 Agent 任务能估计真实完成比例。S-HI26

研究者综合：进度至少有四种可不同步的量：执行过的动作数量、已完成的已知计划项、已交付的目标结果、已经验证的需求。百分比必须说明分母。例如“已执行 8/10 个计划步骤”不等于“用户目标已完成 80%”，因为步骤耗时、价值、可失败程度不同，计划还可能扩展。剩余时间预测则额外需要分布与校准；不停移动的动画只表明显示正在更新，不能作为进展证据。

可以研究确定范围内的计数、阶段状态、已验证结果、剩余未知因素等表达方式的理解效果；本阶段不选择其中一个作为产品方案。关键研究约束是保留量的含义，避免把看起来持续前进误当任务必然接近完成。

3.04.5 直接相关的 Agent 界面研究与外推边界

近年的原型为技术路线提供具体例子，同时还不足以支持对通用第三方观察助手的总体结论。

研究	已核查的研究条件	实际支持	不应推出
C-04-012 [M/E] AgentGUI，2026	N=8；两类任务、四条轨迹；与 Hermes Dashboard 比较；问答带位置提示	该任务中结构化界面有助于回答执行信息问题，答题时间减少约 38%	普通用户长期无人值守监督已有效；任意现有客户端都可提供相同数据。S-HI11
C-04-013 [M/E] AGDebugger，2025	第一部分 N=6 比较错误理解；第二部分 N=8 对已知失败轨迹尝试引导，提供错误摘要	交互回溯与编辑是有用的探索机制；第二部分仅 2/8 达到精确正确答案	用户感觉易引导等于可靠修复；可视化本身足以替代实现知识。S-HI12
C-04-014 [M/E] Cocoa，CHI 2026	N=16 实验室比较；N=7、7 天部署，CS/邻近领域研究者	共同规划/执行改善自评可引导性；部署中较实验室更常保留人类步骤	无显著易用性差异等于统计等效；主观研究帮助等于成果质量得到独立验证。S-HI13

三个原型体现不同路线：可观察的运行界面、可回溯的调试工具、共同编辑工作计划。它们的输入、控制能力、用户群与任务均不同，所以不能按论文中的某个数值排列成统一排行榜。尤其需要区别主动承载/控制 Agent 的研究系统与只能外部观察其他客户端的工具。

这里也存在有价值的反向证据：原型显示了可引导性，但修复不保证成功；短实验中用户愿意把所有步骤交给 Agent，但真实工作的一周内会重新保留部分判断。研究不能一方面引用有利体验，另一方面忽略同文中的失败任务、参与者选择和更长期行为变化。

3.04.6 如何检验“用户真正理解了”

C-04-016 [M/H]：理解研究需要把测试问题与决策目标对应。Endsley 的测量论文是 SAGAT 等方法的重要入口，但本轮未获得足够全文，不能把精确测量流程和效度当作已核验结果。以下是根据本轮构念和 Agent 研究提出的候选测量框架。S-HI28

测量任务	示例问题（合成情境）	所测能力	关键混淆
状态识别	哪个测试仍在运行，哪一个已收到终止结果?	识别状态及来源	只记颜色、不理解状态含义
证据定位	哪项记录支持“这个版本测试通过”？	来源定位与匹配	能找到一条测试记录，但对应旧版本
范围辨别	当前证据能否证明所有要求完成?	区分局部与全局结论	被摘要的确定语气影响
矛盾发现	自述完成与工具失败能同时意味着什么？	处理冲突与保留未知	默认相信最后到达的消息
条件预测	需要看到什么，才能把等待改判为完成？	正确的状态更新模型	猜测下一步内容而无依据

测量任务	示例问题（合成情境）	所测能力	关键混淆
迁移问题	换一种 Agent 或出现事件缺失，原规则还成立吗?	心理模型而非记忆答案	训练阶段泄露答案模板
依赖选择	是否采用摘要、查看证据、请求澄清?	实际校准行为	只看最终是否与 AI 一致

这些测量应给“不足以判断”一个合理位置。把所有题都设计成非黑即白，会训练用户把未知强行解释成成功或失败。评分需要区分没有回答、错误确信、合理保留判断、回答正确但证据错误。对于开放问题，可先冻结具体时间点、明确当时可见证据，再由领域人员独立标注哪些结论可支持。

客观题也并非自动无偏。若题目恰好沿某种界面的目录组织，另一种界面会受到不公平惩罚；若问题给出精确日志位置，就削弱了真实监控中“主动发现哪里值得看”的困难。研究应区分定向查找、自由监控、错误诊断与事后审计，报告每类任务的表现，而非统称“理解准确率”。

长期研究还应观察用户是否形成错误常识、是否停止检查来源、能力改变后是否更新认识，以及系统在一次失误后是否导致全面弃用。单次实验能控制变量；纵向部署能看见学习、习惯与真实工作分配，两者解决不同问题。不能因为真实部署存在就自动认为没有招募偏差和新奇效应。

3.04.6.1 研究者提出的双重信任问题

C-04-018 [H/O]：第三方观察工具同时涉及“执行 Agent 的能力”和“观察者准确报告该能力的程度”。用户可能正确地不信任执行者，却过度信任观察摘要；也可能因执行者出错而把正确报告失败的观察者视为不可靠。是否出现这种信任混淆、什么表示有助于区分，需要专门实验，不能由通用 XAI 文献直接认定。

这提示一种新的理解目标：用户知道某条信息来自原始工具结果、执行 Agent 的陈述，还是观察模型的归纳；并知道不同来源能支持不同类型的主张。这一目标依赖 03 的来源与忠实性，以及 01 的完整性描述，不能只靠界面措辞解决。

3.04.7 Open Research Questions

ID / 优先级	问题	前置知识与最小可检验边界
RQ-04-01 / P0	普通用户能否稳定区分“动作结束、任务完成、结果已验证、证据未知”？	02 明确定义；07 构造相同活动但证据条件不同的对照案例
RQ-04-02 / P0	观察摘要的语言与视觉编码是否诱发超出证据的完成感?	03 主张范围标注；同时测客观回答和确信程度
RQ-04-03 / P0	总览、时间线、任务结构分别改善哪些任务?	保持底层证据相同；分别测试定位、关系、诊断、未知辨认
RQ-04-04 / P1	渐进披露何时降低核查成本，何时隐藏关键反证?	证据入口可用性、实际检查行为与正确性，不能只看点击率
RQ-04-05 / P1	用户能否区分执行者与观察者的可靠性?	01/03 能分开控制执行错误、数据缺失、解释错误
RQ-04-06 / P1	技术知识、任务知识和使用经验怎样调节解释需求?	超越专家/非专家二分；招募多维背景样本
RQ-04-07 / P1	长期使用如何改变委托、核查与介入行为?	06 提醒频率；真实任务纵向记录，报告退出与使用强度
RQ-04-08 / P2	动态计划与不确定剩余工作应怎样呈现进度?	可验证的分母；测试用户是否误把步骤比例当目标完成率

3.06 领域06 - Human-in-the-Loop & Intervention Detection

3.06.0 Knowledge Map：介入是决策问题

本领域研究“人类何时、以什么角色参与，参与后能产生什么净价值”。其核心分支包括：

分支	核心对象	主要方法	重要依赖
06-A 人机职责	获取信息、分析、决策、执行的分工	Levels/Types of Automation、监督控制、共同主动性	实际权限与任务责任
06-B 介入需求	信息缺口、目标冲突、错误、风险、授权	规则、判断模型、用户偏好澄清	01 覆盖；02 状态；03 证据
06-C 策略选择	问不问、问谁、何时问、无人回应怎么办	Expected Utility、Value of Information、Adjustable Autonomy、MDP	成本模型、人类可用性、行动集合
06-D 时机与注意	用户何时有能力处理提醒	中断成本、任务断点、注意力管理	04 的情境理解；时间敏感损失
06-E 重复暴露	提醒如何改变长期依赖行为	Alert Fatigue、Habituation、False Alarm Effects	真实基率、提醒历史与纵向研究
06-F 策略评价	提醒是否真正改善整体结果	事件级准确率、净效用、人机联合表现	07 的反事实与可行动性 Ground Truth

“检测到异常”只解决其中很小一部分。系统即使能准确检测异常，也未必知道人类是否有新信息、是否来得及改变结果、该找谁、是否有操作权限，或打断是否值得。

3.06.1 人类参与的模式与基本限制

3.06.1.1 自动化不能用一个总等级概括

C-06-001 [K/M]：Parasuraman、Sheridan、Wickens 区分信息获取、分析、决策选择、动作实施四类功能，各功能可有不同自动化程度。常见十级量表主要描述决策/动作分配，不能直接当作所有功能共享的单一成熟度排行榜。S-HI15

在同一个系统中，信息获取可以完全自动，状态解释由模型辅助，风险判断由人类承担，动作执行又需要另一套权限。因此，“Human-in-the-Loop”本身太粗：必须说明人在什么环节、能看什么、可以否决什么、错过时机会怎样。

人类参与方式	人类作用	需要区分的问题
预先约束	设定目标、偏好、边界或权限	约束是硬规则还是可修改建议?
持续协作	人机共同规划、补充知识、分配步骤	目标可变化时，偏离旧计划是否仍合理?
执行前确认	对具体行动审阅与授权	审阅材料是否充分，确认是否真的阻止未授权行动?
例外处理	系统在特定条件请求人类处理	判断何时值得询问；人类不回应如何处理?
监督与接管	人类在运行中诊断、停止或改道	用户是否有足够情境意识和可用控制?
事后审计	检查过程与结果，改善后续规则	已发生的外部后果能否纠正?

表格是研究者对功能分工的综合。它也解释为何“观察到了许可请求”“用户点击同意”“执行端接受授权”“动作已经实施”应是不同证据事件，而不是一个“已处理”状态。

3.06.1.2 人类不是无成本的完美后备

C-06-002 [K/M]：Bainbridge 的 Ironies of Automation 指出，自动化会留下困难的监督和异常接管工作；平时缺少操作机会又可能削弱技能。它是经典理论分析，不能直接换算为现代 Agent 的接管成功率。S-HI14

研究者综合：把系统称为“最终有人负责”，并没有回答责任者是否获得及时证据、是否理解动作后果、是否保留技能。一个观察器也可能把原来省去的操作负担变为持续监视负担。应分别研究用户持续在线、离开数分钟后返回、只接收少量提醒等参与模式，不能把实验室持续盯屏的表现当成日常监督能力。

3.06.1.3 Automation Bias 的两个方向

C-06-003 [E，摘要核查]：Skitka 等的模拟飞行决策研究区分 omission errors 与 commission errors：前者涉及因自动提示未出现而漏掉需要发现的问题，后者涉及遵从错误提示。原出版方摘要支持此区分；本轮未完整核验参与者与全部方法，故不声称职业飞行员样本或精确效应量。S-HI22

对观察系统的启发是双向的：错误提醒可能促使无必要干预；长期没有提醒也可能被解释为系统已经检查一切。后一种推断在第三方可见范围有限时尤其值得研究。它是否实际发生、发生频率怎样，仍需 04/07 的用户实验，不能从概念直接认定用户一定如此行为。

3.06.2 介入需求的五层区分

C-06-006 [P/H]：Google SRE 的监控实践强调，人类紧急注意力应对应需要处理的症状，而不是仅因数据看起来奇怪就触发。迁移到 Agent 时，需要进一步区分下表；迁移本身是综合推论，不是 SRE 已验证了 Agent 任务判别。S-HI25

概念	判断依据	可能反例	与介入的关系
Anomaly，异常	相对历史或统计模型少见	第一次全量测试很慢，新文件数量大	稀有不说明错误，更不说明应打断
Error，错误	违反明确规则、契约或局部期望	一次工具失败后重试成功	真实错误也可能已自动恢复
Failure，失败	在指定范围未达到所需功能/结果	某次测试失败但用户目标是复现该失败	必须说明失败对象和成功定义
Risk，风险	潜在后果、发生概率、暴露与可逆性	低概率但高代价的外部动作	可能在任何错误发生前就值得参与
Actionable issue，可行动问题	可用行动有望改善结果，且有合适执行者	发现已过期、无可用控制、重复报告同一问题	介入需要的不只是正确识别，还包括时效与选择

错误还应与偏好、授权、信息不足分开。用户没有说明采用哪种格式是偏好缺口；没有权限访问服务是操作边界；两项需求互相矛盾是目标冲突；证据通道失联是观察完整性问题。它们未必是 Agent 推理错误，但某些情况下向用户提问很有价值。

同样，偏离某个计划不必然偏离用户目标。计划可能是执行 Agent 临时提出的，用户目标可能更新，发现新证据后改路可能合理。要研究偏题检测，首先需要目标的来源、版本、优先级、可接受替代路径以及判断时点。缺少这些条件时，“像不像原计划”是相似度问题，不是任务正确性判定。

3.06.3 Mixed Initiative、信息价值与决策效用

3.06.3.1 询问应比较可选行为

C-06-004 [K/M]：Horvitz 的 Mixed-Initiative 工作把自动行动、不行动与发起对话放在期望效用中比较，纳入目标不确定性与行动/时机成本。原型情境是日历辅助，概率和效用需要相应模型；论文没有提供通用“置信度低于多少就问”的常数。S-HI16

C-06-007 [H，形式化综合]：可以用以下表达澄清研究变量，而不把它当成已验证的 Yukio 算法：

Δ U(a,t)=E[L(继续当前策略)-L(采取介入 a) | E_t]
-C_(attention)(a,t)-C_(delay)(a,t)-C_(action)(a,t).

这里，E_t 是到时间 t 真正可用的证据；L 是研究明确界定的结果损失；a 可以是澄清、检查、暂停、提供信息或转交他人。所有成本必须使用可比较的单位或明确的多目标规则，避免重复计数。这个表达的意义在于暴露前置条件：人类可能不回应、可能判断错误；某个操作可能无法执行；早问会中断，晚问可能错过改变结果的机会。

Value of Information 关注新信息改变决策后能减少多少预期损失。高不确定性不一定意味着高信息价值：如果无论真实情况怎样都应采取同一行为，获得答案可能不改变决策。低不确定性也可能值得检查，例如小概率事件的后果很大。因而校准的置信分数只是潜在输入，不是完整策略。

必须区分“请求用户提供偏好”和“要求用户核查事实”。前者的 Ground Truth 可能尚未形成，需要共同澄清；后者原则上需要证据与判定标准。把二者都训练为一个二分类“needs human”会掩盖不同的正确回应与错误成本。这是问题建模的限制，不是某种模型已经能解决的能力。

3.06.3.2 Adjustable Autonomy 处理无人回应与多次转交

C-06-005 [M/E/P]：Scerri 等把控制转移建模为策略序列，包括把控制交给其他实体、等待、改变协调约束，并以 MDP 表达状态、时间、不响应概率和奖励。E-Elves 有小型研究团队的长期部署经验，但最优性仍相对于设定的状态、转移与效用模型。S-HI17

这一技术路线提供比单次通知更完整的研究对象：一次提醒发出后，用户未响应究竟意味着未看到、暂时无暇、不同意还是没有能力处理？这些含义不能从“没有点击”直接识别。对等待动作的评价也依赖未来是否可能得到更好证据，以及等待会不会扩大损失。

在第三方观察情境中，还应先确认行为集合。观察者可以建议用户暂停，不代表它能使执行器暂停；发出说明与成功转移控制是两件事。此限制属于 01/02 的能力与状态事实，而不是提醒策略通过自然语言可以弥补的条件。

3.06.4 低基率、重复事件与分类指标

C-06-008 [K，概率推导]：若真正需要介入的情况很少，即使检测器的 sensitivity 与 specificity 看起来不错，提醒中也可能大部分不值得处理。以下只是合成算例，不是任何论文或 Yukio 实测：10,000 个独立判断机会中，可行动问题基率为 1%，敏感度 90%，特异度 95%，则真阳性为 90，假阳性为 495。

$$PPV = \frac{0.9 \times 0.01}{0.9 \times 0.01 + 0.05 \times 0.99} \approx 15.4\%.$$

这没有证明某个具体提醒系统不可用；它说明应报告真实基率、决策单位和绝对提醒量。若研究者把错误/正常轨迹人为配成 50:50，测试精确率不能直接代表生产使用。

判定单位尤其重要。一个测试失败可能产生数十条错误日志、一次失败状态、一次重试、一次恢复结果。按日志行测 recall、按会话测用户负担，会把同一问题重复计数。应区分事件检测、问题 episode、可行动窗口和用户通知。两个策略即使检测召回率相同，也可能因一个重复提醒十次、另一个只提醒一次而有不同使用价值。

延迟同样不能简单被“预测正确”吸收。问题出现后才知道最终结果的离线分类器，可能表现很好却无法及时提醒；过早提醒则可能捕捉到本会自动恢复的暂时故障。应标出最早可识别时点、最后有用介入时点与实际送达时点，评价方法必须限制在当时可获得的证据，避免未来信息泄漏。

3.06.5 中断时机：不是提醒越早越好

C-06-009 [E/M]：Bailey 与 Konstan 的 N=50 受控研究表明，在任务中间而非任务之间呈现外围任务会增加某些任务和情绪成本。Iqbal 与 Bailey 的通知管理研究在 N=16 的任务实验中支持利用任务断点降低部分打扰代价，但自动断点识别不完美，应用切换也不必然对应心理任务边界。S-HI19 S-HI18

研究者综合：时机至少涉及执行 Agent 的进度、人类当前活动、问题恶化速度、解释准备程度四个时间过程。最佳可读时点可能已经晚于最佳纠错时点。对于可等待的问题，断点送达可能合理；对于即将失去作用窗口的问题，延迟成本可能超过中断成本。研究不能只预测“用户现在忙不忙”，还需判断等一会儿会失去什么。

C-06-011 [E]：Mark 等 N=48 的模拟邮件工作实验提供反例：被打断时，扣除处理打断本身时间后的主任务耗时反而更短，同时压力、挫折等上升。作者把加快工作视为可能的补偿机制；这不表示包含打断的总时间更短，也不证明长期没有代价。S-HI29

因此，不能把某个未经核对的“平均恢复需要若干分钟”当所有桌面工作的固定常数，也不能只用完成时间评估提醒。要同时考虑主任务质量、总耗时、恢复成本、紧张程度、被打断任务的记忆与长期持续使用。

3.06.6 Alert Fatigue：现象不能用一个机制解释

C-06-010 [E]：Ancker 等对 112 名临床人员的多年日志研究发现重复提醒和每次就诊提醒数量与较低接受相关，但一般工作量、对新提醒随时间习惯化等假设并非都获得支持；未逐条判断提醒是否适当。Vance 等的多日神经/眼动研究与 N=102 的三周 Android 实验则提供重复警示习惯化证据，且变化外观在该情境减缓某些下降。
S-HI20 S-HI21

两个研究不构成简单互相否定：临床提醒与安全警示的价值、重复含义、用户训练、后果和测量方法不同。用户忽略提醒可能是注意力衰减，也可能是知道同一问题此前已处理，或觉得建议不适合当前情况。若只把所有 dismiss 都标成 fatigue，便无法判断该减少重复、改善内容、改变时机，还是修正错误的可行动性标签。

研究者综合：需要区分至少五个可能机制：对视觉模式的习惯化、频繁低价值信号导致的理性忽略、工作压力使处理资源不足、重复问题造成的冗余、错误警报损害对后续提醒的信任。它们可能共存，但需要不同数据验证。改变外观可以重新吸引注意，却未必改善内容价值，长期甚至可能增加打扰；本轮没有证据支持“持续换样式”作为通用解决办法。

长期研究不能只统计接受率。接受不是正确处理，拒绝不是失败，用户缺席不是忽视。更有意义的结果包括：是否发现真正需要参与的问题、是否来得及处理、建议是否有用、处理是否成功、重复通知负担是否下降，以及对主任务与信任校准的影响。

3.06.7 技术路线比较与采用条件

3.06.7.1 方法比较

下表是研究者综合。某方法较容易部署，不代表它在错误与介入价值的判断上更可靠；某方法有最优性证明，也不代表真实环境已满足证明假设。

路线	工作机制与输入	能解决的部分问题	不能自动解决的问题	证据地位/采用条件
显式规则/契约检查	已知事件与规则匹配，如确定的权限请求、工具失败	可定义状态或边界的识别	任务意图、用户偏好、失败是否已恢复	P；规则语义和覆盖明确时可审计
异常检测	相对基线找异常时间、频率、模式	发现值得调查的变化	异常是否错误、是否应打断	M/P；需稳定基线与后续判别
模型置信/选择性预测	不确定时不输出或转交	限定预测任务中的风险/覆盖权衡	用户是否更会判断、是否有空、时机成本	M/E；校准与分布变化必须检验
Learning to Defer	联合学习预测与转交，比较专家/模型损失	在有标签、专家表现数据的任务上分工	开放任务目标、长时依赖、权限、实际人类响应	M/E；见 C-06-012 的形式限制
基于目标的轨迹审查	将任务要求、计划与可见执行相比较	有明确任务标准时发现不一致候选	通用意图识别、隐含目标、合理重规划	M/H；需要独立的偏离 Ground Truth
固定周期/固定步骤确认	定时或每若干动作请求检查	易解释的控制与基线	不同阶段价值差异、快速错误传播	P/M；是重要对照，不宜预设最优
任务断点通知	预测人类任务边界后送达	可延迟提醒的打断成本	延迟带来的任务风险、消息可行动性	M/E；分类误差和问题时效共同评估
动态确认频率	用步骤成功率、诊断/重做时间优化检查位置	形式化多步任务的检查成本	模糊正确性、多目标损失与参数漂移	M/E；见 C-06-013
Adjustable Autonomy / MDP	对控制者、时间、响应与行动成本规划	多次转交、等待与协调	未建模状态、效用失真、可观测性不足	M/E/P；最优性依赖模型正确性

3.06.7.2 学习转交不能直接外推为通用介入检测

C-06-012 [M/E]：Mozannar 与 Sontag 研究给定监督分类任务中的 classifier 与 rejector，转交损失取决于专家输出，不默认专家正确。实验证据包含从 CIFAR-10H 标注分布采样的专家与 CheXpert 的模拟专家；不是实时邀请人类接管开放 Agent 的实验。S-HI23

这种路线的思想价值是比较人机的相对优势，而不只看模型自信。外推时却增加了许多变量：用户看见的解释会改变其判断；错误会随执行传播；一次提问可能改变目标本身；人类能否答复存在时延；某个用户的能力还可能随疲劳变化。因此需要新的任务定义、训练数据与评估，不能把分类器的 risk-coverage 曲线直接叫作 Agent 介入可靠性。

3.06.7.3 直接 Agent 确认模型的有条件结果

C-06-013 [M/E]：Zhou 等的 CHI 2026 研究用确认、诊断、纠正、重做过程构建动态规划。在 N=48 的模拟购物、图像编辑与游戏任务中，模型相对只在结束检查减少约 13.54% 完成时间。其主要目标是时间成本，假设正确/错误可明确定义、步骤与错误传播方式已知，参数来自先验或试点。S-HI24

这一结果说明检查时机可以作为可研究的决策变量，也说明应用前必须检查模型边界。若错误没有传播、用户能直接看出哪个局部结果有问题、目标在过程中变化，或损失主要不是时间，原模型最优策略未必适合。原文对于更复杂场景的扩展建议属于作者未来工作，不应被解释为已经验证了通用策略。

3.06.7.4 通用偏题识别仍缺少直接证明

C-06-015 [M/E/O]：AgentGUI 的 drift 实验提供值得调查的技术示例，但该实验以交付文件是否存在作为完成评分；不能把分数提升解释成文件内容正确、所有偏离被检测，或偏题检测的 precision/recall 已建立。S-HI11

研究者综合：完整研究应分别标注目标版本、行为与目标的关系、合理探索、错误但可恢复的动作、真正需要人类介入的偏离、介入能改变的结果。行为看似迂回可能是必要探索；复述目标可能掩盖实际失败。缺少规范性任务标签时，应把判定称为候选不一致或风险假设，而不是已经确认的“AI 做错了”。

3.06.8 Observer 的介入评价：从提醒准确到联合结果

C-06-014 [M/H]：介入检测与介入策略需要分层评价。下面是与 07 衔接的研究框架，不是已经存在的统一标准。

层次	Ground Truth/评价对象	合适结果	常见错误
证据识别	当时记录中是否存在目标事件	Event precision/recall，时间与身份正确率	用最终结果补入当时未知事实
问题判别	在任务标准下是否存在明确问题	问题级 precision/recall，未知覆盖与校准	把所有日志错误都当需要介入
可行动性	谁在什么窗口采取何种行动有望改善结果	可行动 episode 的发现率，误提醒/小时	用“专家觉得奇怪”代替行动价值
提醒时机	当时提醒相对可选时机的价值	提前量、有用窗口覆盖、延迟损失	到任务结束才准确识别仍算成功
人类处理	用户理解、决定与操作是否有效	理解正确率、正确接管、响应时间、误操作	只看确认点击率
联合任务	人机/观察系统最终产生什么结果	净质量、总成本、避免损失、主任务负担	把 Agent 本身提升归给 Observer
长期使用	学习、习惯、偏好与能力变化	持续负担、校准、退出原因、重复问题	将短实验体验视为长期满意度

可行动性的 Ground Truth 比错误标签更难建立，因为涉及未发生的反事实：“如果没有提醒会怎样？”和“如果用户当时处理会怎样？”离线轨迹回放能检验信息是否足以产生提醒，不能单独估计真实人类反应与最终收益。随机或匹配比较可以帮助因果评估，但仍须定义安全、可重复的任务范围，并避免用本就知道错误位置的用户代替真实发现过程。

不同错误代价应保持可见。一个误提醒会造成轻微阅读成本，另一个会诱发用户中断本来正确的长时执行；二者不应只计为一个 false positive。一个漏报可能没有实际损失，另一个可能错过不可逆动作前的最后窗口。成本权重可以不确定，需要敏感性分析；不应为了得到单一分数而隐藏价值判断。

3.06.9 Open Research Questions

ID / 优先级	问题	前置条件与进一步核验
RQ-06-01 / P0	在什么任务范围能可靠定义“值得用户参与”？	区分错误、偏好、授权、观察缺失；确认实际可行动选项
RQ-06-02 / P0	可行动性标签能否由不同标注者稳定给出？	任务目标/版本、行动窗口、人类能力与成本明确；分歧保留
RQ-06-03 / P0	误提醒与漏提醒的真实基率、成本是什么？	按 episode 而非日志行统计；真实未筛选轨迹与曝光时长
RQ-06-04 / P0	系统“不知道”应何时只是说明，何时值得询问?	01 可见范围；03 不确定性；询问预期会改变什么决策
RQ-06-05 / P1	部分观察下能否区分合理探索与目标偏离？	02 因果与状态；目标版本、探索预算和独立标签；先限定任务

ID / 优先级	问题	前置条件与进一步核验
RQ-06-06 / P1	注意断点收益和延迟风险如何联合估计?	人类任务与 Agent 任务同时记录；检测延迟与错过窗口
RQ-06-07 / P1	人类不响应时，哪些解释与策略成立?	区分未看到、没空、不同意、无能力；控制能力与权限真实可用
RQ-06-08 / P1	长期提醒中的疲劳来自什么机制?	重复、低价值、负担、习惯化分别操纵/分析；不把 dismiss 当统一失败
RQ-06-09 / P1	Learning to Defer 的专家优势模型如何迁移到多步任务?	人类响应与执行后果数据；目标可变性、非独立错误与延迟
RQ-06-10 / P2	个体化介入策略是否稳定优于可解释简单规则?	与固定周期、明确契约和用户主动检查比较；避免只对复杂模型设强基线

3.07 领域 07 - Evaluation & Reliability

3.07.1 知识地图与评价对象

研究问题 ID	分支	核心评价单位	关键依赖
RQ-07-01	Actor 与 Observer 的区分	任务结果／观察陈述	先定义被评估系统和成功语义
RQ-07-02	事件检测和可见范围	事件、调用、状态区间	独立参考记录、匹配规则、合法分母
RQ-07-03	状态、不确定性和拒答	在线时点、状态转换、输出主张	时间可用性、标签可识别性、分布条件
RQ-07-04	评判器的有效性	原子事实、响应对、整个系统分数	人工校验、反偏差实验、不同评价目标
RQ-07-05	Replay、模拟和实测	固定轨迹／重复执行／故障条件	可复现环境及明确控制边界
RQ-07-06	Ground truth 与标注	事实集合、证据关系、未知标签	标签来源、标注指南、分歧处理
RQ-07-07	用户价值与外部有效性	人、任务、客户端版本	客观理解、负担、实际介入结果
RQ-07-08	已有观察器基准	故障类、可观察性条件、检测器	区分结构可表达性与真实识别性能

C-07-001〔研究综合，M〕：Agent evaluation 和 Observer evaluation 应采用不同评价对象。 一个编码 Agent 写错代码而观察器准确报告“测试失败”，前者失败而后者正确；Agent 任务成功但观察器漏报关键结果，前者成功而后者失败。仅报告任务解决率，无法识别观察系统的贡献。

SWE-bench 通过真实仓库问题和测试考察补丁能否解决任务，AgentBench 对交互环境中的 Agent 能力进行评价，τ-bench 通过工具、策略规则和模拟用户评价连续交互。这些基准都可提供可观察工作负载，但不会自动给出观察器所需的每条事件、状态和解释支持标签。S-GE13 S-GE14 S-GE15 其中 AgentBench 本轮仅核对官方摘要，完整 PDF 因读取大小限制未取得，不能据此声称已审核其全部实验。

3.07.2 Ground truth 应至少区分三个层次

下列三层是本知识库提出的分析框架〔M〕，不是已有通用标准的名称：

层次	真值问题	可用参考	典型误用
任务与世界结果	用户目标实际上是否实现?	独立测试、环境状态、任务判据、人工验收	用 Agent 自述作为完成真值
来源与事件契约	该观察渠道在此配置下应该产生什么?	官方语义、受控触发、独立事件记录	把源本身不提供的内容计作采集器漏检
采集与呈现	哪些已产生材料被完整采集、正确关联和解释?	原始导出、独立采集对照、版本化解释	用观察器自己生成的日志证明自己无漏检

这三层允许提出不同的问题。可观察接口完整地输出了“调用结束”，但任务仍可能失败；采集器完整记录自述，也不能将自述内容提升为已验证结果。当两个来源都由同一包装器生成，它们的共同错误可能让“交叉校验”失效。

当前接口还有明确实例：Codex 的 turn/completed 需要继续读取 status；MCP Tasks draft 的 completed 与工具结果中的 isError 不是同一层语义。相关规范实例详见 S-IF03、S-IF09；特别不能把 draft 描述写成全部客户端均已支持的统一事实。

3.07.3 事件检测：先定义匹配，再计算 Precision/Recall

令 E 为受控实验中已由独立机制确认、且属于目标来源能力范围的事件集合，C 为采集结果，M 为按照预先声明规则得到的一对一匹配。则采集 precision = |M|/|C|，采集 recall = |M|/|E|。当 C 为空或 E 为空，不能隐藏分母为零的场景；应分别报告无事件控制的误报情况和确有事件时的漏检。这是事件评价的研究操作化，不能把 E 偷换成“所有真实活动”。

C-07-002〔研究综合，K/M〕：没有独立已知的事件分母，就不能宣称整体事件召回率。 真实环境中只看采集器输出时，最多能评价已捕获记录的内部一致性，或在抽样审计范围内估计误差。来源能力覆盖率、该范围内的采集召回率、关联准确率需要分别报告。

事件匹配至少需说明：是否要求同一 run/call ID；同类型重复事件怎样去重；允许多大时间偏差；多条低层事件对应一次用户可理解操作时如何聚合。否则一个系统重复输出十次“开始测试”可能获得十个命中，或大量重叠时间窗把一次偶然命中扩大成完整检测。

对持续状态或异常区间，Tatbul 等提出区间级 precision/recall，区分发现存在、覆盖时长、发现位置和碎片化程度。其权重具有应用选择性，不能从该论文推出唯一正确的状态评价指标。S-GE27 活动观察的合理综合是同时报告事件级命中、区间覆盖和检测延迟；若允许“任意时刻发现一次即整段正确”，必须明示这一宽松口径。

3.07.4 在线状态重建与认识上的未知

C-07-003〔研究综合，M〕：工作本身的状态，与观察器是否知道该状态，是两个轴。 一个进程可以实际已完成，而观察器因终止事件丢失只能回答未知；反之，源数据可用且最新，也不代表用户任务成功。只用 busy/idle 二分类无法表达这些差异。

评价维度	可研究指标	必须保留的限制
生命周期判别	分类混淆矩阵、各类召回率、宏平均指标	长时间“进行中”不能掩盖关键结束转换错误
状态区间	区间交并比、边界时间误差、错误持续时长	粒度与时间容差应预先说明
关联结构	调用配对准确率、父子/依赖边准确率	时间邻近不能充当因果真值
信息未知	正确拒答、过度断言、可判定样本覆盖率	无真值样本不能直接当预测错误或正确
变更响应	新证据到达后的更正延迟、旧结论持续时长	有些更正来自迟到事实，并非旧判断当时失当

在线评价在时刻 t 只能向观察器提供 t 之前实际接收到的证据。按事件发生时间排序后一次性提供完整轨迹，只能评价事后重建；它会泄露当时尚未收到的未来信息。完整真值可用于回看评价，但不能偷偷进入在线输入。对同一轨迹，应区分“当时基于有限证据判断是否合理”与“后来知道真实结果后是否准确”。

3.07.5 Calibration 与选择性输出

Guo 等以预测置信度与实际正确率的对应关系定义 calibration，并通过可靠性图和校准误差研究神经网络。temperature scaling 的实验成功来自特定分类任务和校准集，不是 LLM 任意自然语言置信度的通用保证。S-GE20

C-07-004〔K；统计定义及研究综合〕：置信度是待验证的预测，不能因模型写出“90%”就当作经过校准的正确概率。 要说明这个概率针对事件类型、主张支持、状态判别还是任务成功，且在何种数据分布中校准。多个不同不确定性不宜平均成一个“可信度”。

对于概率预测，可用 Brier score 或 log score 等 proper scoring rules；它们鼓励报告真实信念，但评分理论不会保证错误参考标签下仍得到正确结论，也不会使校准较好的恒定基准变得有辨别力。S-GE31 ECE 和可靠性图可补充观察，但需要公开分箱与样本数；总体校准也不能代替失败类或新客户端子组的校准。

Selective prediction 用拒答换取回答部分的较低风险。风险-覆盖率曲线应同时显示回答比例和错误率。SelectiveNet 在若干分类任务上研究了该权衡及验证集校准，并且实际测试覆盖率不必等于训练目标。S-GE21 对观察器而言，始终回答未知的系统不能仅凭极低已回答错误率获胜；总能回答的系统也不能用高覆盖掩盖错误断言。

3.07.6 解释评价与 LLM-as-a-judge 的独立审查

解释至少应分开评价：原始记录引用是否正确、主张是否受支持、重要信息是否遗漏、对象/版本/时间是否混淆、是否过度推断、用户能否理解。流畅度是另一个维度。通用 BLEU/ROUGE 或文本相似度不能独立证明这些属性；同一事实有多种表达，而几乎相同的句子可因一个否定词而意义相反。

评判方式	适合的事实	优势	失效方式
程序判据	ID、字段、退出码、明确后置条件	可重复、范围清晰	判据没覆盖需求，或验证了错误对象
人工逐项审查	复杂语义、含糊上下文、用户相关性	可显式保留分歧	共享误解、疲劳、能力差异
NLI/专用事实核验器	主张与有限证据的支持关系	可以规模化定位局部问题	域迁移、否定、数字、长材料、检索缺失
通用 LLM judge	开放文本质量、多维 rubric	柔性强、成本可控	偏差、提示敏感、未校准、自身推理失败
多评判器与人工抽样校正	大规模总体估计	可检测分歧并改善均值估计	相关错误和同源数据不被投票自动消除

C-07-005〔E；相反证据并存〕：LLM judge 可近似一些人类偏好，却不因此成为事实或逻辑正确性的可靠裁判。 MT-Bench/Chatbot Arena 在其条件下发现强模型与人类偏好有较好一致性，同时检验了位置、冗长度及推理问题；原文对 self-enhancement 特别说明数据不足以作确定判断，不能引用该文直接宣称所有模型都偏爱自身答案。S-GE16

G-EVAL 以 rubric、CoT 与结构化评分提高特定摘要/对话数据的人类一致性，属于经过局部实验的评估方法；与人类相关不等于每项判定准确。S-GE17 JudgeBench 使用带客观正确标签的困难响应对，展示相同“评判能力”

在不同目标下可能很弱；其样本故意筛选有区分难度的情况，不能把结果直接视为普通任务的自然错误率。S-GE18

ContextualJudgeBench 更贴近给定上下文的解释评价，研究 refusal、faithfulness、completeness、conciseness，并使用交换答案位置后的 consistent accuracy。该严格指标的随机基线为 25%，不能与普通二选一准确率的 50% 直接相比。它表明只给评判器增加明确 rubric 仍需实测，不构成自动保证。S-GE19

相应的研究要求是：冻结 judge 的版本、提示和输入证据；盲化系统身份并交换位置；对长度、否定、时间范围和引用错配设置针对性材料；用独立人工标签估计每类错误；把 disagreement 保留为研究信号。若生成器和 judge 共享模型或检索资料，其相关错误是需要测量的风险，不能假设独立。

3.07.7 人工标签、抽样和总体估计

标注一致性检验的是重复测量稳定性，不是绝对真值。Artstein 与 Poesio 清楚指出，高一致性仍可能来自共同偏见；κ、α 等系数还依赖标签分布、距离定义和研究目的。S-GE25 对执行解释，指南应区分 source-supported、source-contradicted、insufficient evidence，以及引用正确但语义范围错误等情况；最终标签应保留原始分歧及裁决理由。

Prediction-powered inference 提供一种重要中间路线：用大量模型预测帮助总体估计，再用独立人工标签估计偏差，从而在相应抽样条件下构造有效区间。原始框架不要求预测器一定准确，但要求匹配其理论中的数据和独立性条件；可用标签不是随意挑选的“难例集”。它校正总体参数的统计估计，不会把每条错误预测改成正确标签。S-GE24

Dror 等说明显著性检验的选择依赖任务、指标、配对关系及样本结构，bootstrap 也不能摆脱数据代表性问题。S-GE32 对长轨迹，本研究据此提出〔研究综合，M〕：相同用户任务、仓库或运行内的事件相关，应按可独立抽样的任务/运行进行聚类重采样或使用相应层级模型；不能把一条轨迹的一万个事件当成一万个独立样本。比较两个观察器时，应尽可能使用相同轨迹形成配对比较。客户端/版本数量很少时，不能靠重采样事件制造对新客户端的可靠外推。

数据集文档需说明采样范围、来源能力、触发机制、版本、删除和脱敏过程、标签生成者及允许用途。Datasheets for Datasets 为这种透明记录提供系统问题清单；它是文档实践提议，文档完整本身不等于数据无偏。S-GE28

3.07.8 Replay、故障注入、模拟和真实运行

C-07-006〔P 与研究综合〕：重复播放同一轨迹、确定性模拟和重新运行 Agent，回答的是不同问题。

研究方法	保持固定的对象	能检验什么	不能证明什么
固定轨迹重放	已保存事件与顺序	解析、归并、状态与解释是否可重复；条件差异比较	原采集没有遗漏；实际系统仍会产生相同轨迹
事件层故障注入	基础轨迹；人工改变丢失、重复、延迟	观察器对指定输入缺陷的稳健性	注入分布代表现实全部故障
确定性模拟	调度、随机种子、虚拟 I/O	重现罕见交错、检验状态不变量	未被模型化的依赖、真实性能和人类行为
真实客户端受控运行	已知脚本任务和环境快照	验证接口、采集器、来源语义和真实时序	一次成功覆盖所有版本和工作负载
同任务多次 Agent 执行	任务语义；允许模型采样变化	真实轨迹变异、故障基率、重复可靠性	将运行差异都归因于观察器
长期自然使用	用户、任务随真实环境变化	生态有效性和长期价值	缺少独立真值时的绝对召回率

Jepsen 将操作历史、故障产生机制及模型检查分开：生成操作，记录起止，注入故障，再用 checker 检验历史是否符合约定模型。这是已采用的工程方法；把它用于日志关联可提供测试思想，但不意味着线性一致性就是 AI 工作流的正确语义。S-GE22

FoundationDB 的论文记录了确定性模拟、故障注入、可执行不变量和罕见行为触发的真实工程实践。作者同时指出模拟不能可靠检验所有性能问题、第三方依赖和未纳入其实现环境的代码；这些边界比“模拟跑很多次”更重要。S-GE23

τ-bench 的 pass^k 衡量同一任务 k 次独立试验全成功的概率，pass@k 衡量至少一次成功；前者关注稳定性，后者关注多次尝试的解题机会。原论文是模拟用户与工具环境的结果，不能用其具体分数预测观察器质量。S-GE15 对观察器的迁移要求是：先固定输入重放测组件稳定性，再在真实多次运行中测面对轨迹变化的稳健性，分别报告两个问题。

3.07.9 已有直接相关观察器基准：AgentTelemetry 的证据边界

C-07-007〔M/P；来源核查有限〕：已存在面向 Agent 可观测性和故障检测的直接基准，不能简单写成“该领域没有评价工作”；但结构可表达性与真实故障识别率仍需分开。

AgentTelemetry 已在 AIware 2026 Benchmark & Dataset Track 发表。官方摘要说明其 490 个 fault-detection cells 来自 14 类故障、5 种观察条件和 7 个框架；2,940 个 raw configurations 是再乘以 6 个 mock-LLM seeds。摘要把 FDR=1.000 明确称为结构完整性上界；这不是六种真实模型在自然日志上达到满分的证据。112 次 SWE-bench Lite 案例中达到迭代上限的记录被按结构模式归为 reasoning loops；小规模干预效应在摘要中明示统计不显著。S-GE33

当前作者仓库另外区分实际 adapter 的完整度与 conformance-complete adapter 的上界，并给出模型作为 detector 的评估入口。仓库基准和 AIware 论文摘要的条件数量及数值不同，应视为不同快照，不能选择性拼成一个结果。S-GE34

本轮没有取得该论文完整正文：OpenReview 被验证页面阻挡，作者 PDF 的工具读取也失败；已核对出版/会务信息及作者 README 相关正文，分别标 A1/A2，未复现。由此能得出的结论仅是“直接研究路线已存在且其上界声明有明确条件”，而非其全部 detector、跨框架性能或原因识别已被独立验证。下一轮应优先审计冻结版本的故障生成、真值标签、检测判据和自然故障对照。

3.07.10 用户理解与实际效用

观察系统可靠而完全难用，或语言顺畅却误导用户，都不能只用单一总分合理评价。用户研究可考察以下不同终点〔研究综合，M〕：

终点	示例任务	为什么需要独立测量
事实理解	指出改了什么、哪次测试返回什么	比“你觉得清楚吗”更接近客观信息获取
验证边界理解	区分已测试版本和后续修改	直接暴露完成声明的范围误解
不确定性理解	指出日志中无法判断的部分	检查限定语是否真的被用户理解
证据核查能力	找出支持或反驳某个解释的记录	判断引用界面的实际可用性
恰当行动	决定继续等待、查看结果或请求检查	需要独立效用标准，不能只奖励介入次数
认知与时间成本	完成理解题的耗时、负担、打断恢复	防止用大量细节换取不可接受的成本
信任校准	在正确与错误提示下的差异性依赖	高平均信任未必是好结果

对不同呈现方式进行因果比较，应尽可能提供同一证据、同一任务难度，随机化顺序或条件，并避免反复观看相同轨迹造成学习泄漏。实际理解的客观测量思想有 Hase 与 Bansal 的实验支持；上述 Agent 具体题型仍需新研究验证其效度。S-GE26 长期提醒疲劳、个体差异及介入收益需与领域 04、06 联合调查。

3.07.11 与领域03共同的进一步验证问题

优先级	问题 ID	尚未完成的问题	知识依赖／可推进的研究证据
P0	RQ-07-01/02	每个观察渠道的可识别真值与合法分母如何定义?	来源契约、独立触发记录；先于任何总召回率
P0	RQ-03-02/06	原始结果与 Agent 可见结果的转换怎样改变解释?	客户端接口、版本化材料；调查转换前后主张支持变化
P0	RQ-03-01/05	身份、时间、版本、否定、范围和冲突能否稳定标注?	语义操作化与标注一致性；先于自动 judge
P0	RQ-07-08	AgentTelemetry 的结构上界与真实检测差距是什么?	获取全文和冻结源码；分开注入真值、语义标签、自然故障
P1	RQ-03-03	模板、抽取、生成、逐项核验的实际误差结构有何差异?	同一轨迹和证据预算；不预设 LLM 路线最优
P1	RQ-07-03/04	置信度及拒答能否跨任务、版本和缺失模式校准?	独立标签、风险-覆盖率及漂移评价
P1	RQ-03-07／RQ-07-07	用户能否理解验证范围与未知，而非只觉得透明?	随机对照理解任务；与领域04/06联合
P1	RQ-07-05	模拟故障能否代表真实采集与状态故障?	真实故障对照、独立来源、版本变化
P2	RQ-03-04	可见推理文本在什么条件下提供额外可靠信息?	行为干预、对照公开活动证据；不以自述为金标准
P2	RQ-07-06	少量人工标签如何有效支持长期总体评价?	PPI/分层抽样；检查模型、样本和偏差校正独立性

继续研究时须保留：本章的操作化定义不是跨客户端标准；没有新采集的 Yukio 数据；没有本地复现任何外部性能；动态资料要固定版本；资料库中的 A1/A2 标记不能在下轮自动升级为全文核验。应优先补齐上述 P0 缺口，然后才能判断项目适用性。

3.07.90 近期观察者研究与反证核查

以下两项2026年预印本直接研究Agent报告或LLM观察者，但尚不能与成熟测量理论等量齐观。本研究核查了相关方法、结果和限制，没有复现其数据或模型运行。

C-03-901〔E，预印本〕自述能覆盖多少活动，与自述是否准确是两个评价问题。 Kraishan与Jitkajornwanich在SWE-chat上比较计划、工具调用和最终自述。其recoverability由模型probe估计，不能称为人类理解实验；主张核验器与人工判断的一致性较低，因此作者限制了从该核验器得出的结论。摘要的总体措辞还应与正文存在的小幅统计关联分别阅读。该研究适合作为“观察者评价也必须验证测量工具”的案例，不宜提取一个全行业通用遗漏率。S-FR01

C-07-901〔E，预印本〕更详细的过程文本也可能使观察者过度拒绝正确结果。 Chen等在19个构造任务、5个LLM观察者上操纵过程细节和证据对象标签，分析4,551次有效判断；反证始终可见。部分模型的错误拒绝随细节增加，不能概括为所有模型都被解释说服而漏检。没有人类参与者，亦未检验隐蔽错误或自然长任务。S-FR02

研究综合〔H〕： 观察者至少需要分别报告命中率、错误拒绝率、证据归属正确率与弃答行为。提高一个指标可能来自判断阈值变化，也可能来自识别能力变化；这两种机制对介入价值的含义不同。详细说明、可信语气和更多步骤均不应被单独当作可靠性的替代指标。

4 Comparative Technical Analysis 技术路线比较

4.1 比较单位：先确定要回答的问题

不能把“采集很多数据”“生成容易理解的故事”“识别某类故障”放进同一个准确率排行。比较必须固定研究问题、可见范围、事件语义、真值、时间窗口及允许使用的信息。第3章给出各路线原理；本章比较它们在相同问题下承担什么证据责任。

问题与输出	主要候选路线	最低前置条件	主要无法解决的问题
某操作是否发起、执行或返回	原生事件、Hook、SDK插桩、系统事件	明确检查点语义；调用和进程身份；采集覆盖	单一检查点不能证明后续效果、结果正确或目标完成
若干事件是否属于同一过程	Context Propagation、Schema关联、对象中心日志、统计关联	身份作用域；关系类型；时间有效区间	相似文本与时间邻近不能单独证明实际依赖
一次执行目前处于什么状态	状态机、权威事件投影、保守候选集合、概率过滤	状态与转移定义；初始条件或先验；观察模型	未建模状态、漏失事件及未知参与者可使唯一状态不可判
执行是否符合明确规定	Conformance Checking、Runtime Verification	可检验规范；日志与命题映射；覆盖假设	符合流程不等于自然语言目标已实现；规范本身可能不充分
一句解释是否有依据	规则生成、检索引用、事实分解、蕴含与矛盾检查	证据对象及版本；陈述范围；独立验证规则	引用存在不等于支持；证据支持不等于生成过程具有因果忠实性
用户是否理解执行	任务相关视图、证据展开、预测和错误辨认实验	明确用户问题；独立测量理解；合适对照	满意度、信任评分和阅读时长不能替代理解测量
是否值得请求人类参与	显式请求转达、规则阈值、决策效用、学习转交策略	可选行动；人的能力和成本；后果与反馈	故障概率本身不能决定净效用；无行动价值的异常未必值得提醒

依据：S-OT03 S-OT08 S-OT24 S-OT31 S-OT32 S-GE03 S-GE07 S-HI16 S-HI23。表中跨路线关系属于研究综合，不是同一实验得出的排名。

4.2 主动合作观察与外部推断

合作式观察通过客户端、库、协议参与者主动发布语义和关联信息。其优势来自信息靠近生成点，通常能明确请求、响应和生命周期；其限制来自部署范围、客户端选择、Instrumentation遗漏以及上下文传播失败。Dapper和X-Trace提供已采用或已实验的机制，但其部署前提是证据的一部分。S-OT06 S-OT07

外部观察从操作系统、文件制品、网络边界或已有日志收集行为，再作关联。它可以发现客户端未主动描述的效果，具有独立核对价值；其限制是高层语义和行为归属需要额外依据。Magpie用明确事件Schema关联，CamFlow保守记录潜在信息流，AgentSight把系统记录与模型通信结合；三者没有共同的“无侵入且全知”保证。S-OT08 S-OT13 S-OT15

比较维度	合作式观察	外部观察	研究时的判断方式
语义接近程度	可以直接表达客户端定义的Tool、Turn、Agent	通常直接表达进程、文件、网络或可见文本	逐项确认字段究竟声明什么，不用“高层/低层”代替真值
覆盖来源	取决于客户端与库的支持范围	取决于OS、权限、探针和可观察边界	分别列源头盲区与传输丢失，不只报告收到了多少

比较维度	合作式观察	外部观察	研究时的判断方式
身份关联	可能拥有显式调用ID和Context	可能依赖句柄、进程谱系、时间或Schema	用关联真值评价错误边与缺失边
部署与观察者效应	SDK修改、启动方式、同步回调、导出负载	权限、探针开销、缓冲和采集器自活动	在固定环境测平均、尾部开销及失败行为
跨版本稳定性	公开接口可能比内部Transcript明确，但仍会变化	内核ABI、库边界、日志格式、应用行为也会变化	固定版本和配置；变化后重查，不作永久承诺
多来源核对	能核对外部效果，但可能只报告意图	能核对部分效果，但未必看到Agent接收内容	证明两个来源的独立范围，不能把同一上游输出的两份副本当独立证据

当前官方接口已经给出一个具体反例：工具原始输出、Hook改写后的Agent可见输出、遥测保存内容可能不同。因此“拥有两条相同工具日志”甚至未必说明观察者看见了Agent最终接收的结果。S-IF01

4.3 确定性重建、集合推断与概率推断

三者在不同前提下都可能合理，关键区别在于如何处理不确定性。

路线	输出与机制	可靠性来源	主要成本及风险
确定性投影	从已知起点按事件语义计算一个状态	输入历史足够、顺序和转移明确	遗漏事件或Schema漂移可能产生稳定但错误的状态
保守集合 / 三值判断	保留相容状态；只对所有相容历史一致的性质作确定判断	明确允许的历史和缺失范围	组合可能膨胀；过宽的集合会增加不可判；错误排除候选会制造虚假确定性
概率过滤 / HMM	依据转移模型和观测似然更新状态分布	概率模型与部署分布相符、参数得到验证	模型错设、相关观测重复计证、罕见状态和变化中的行为
POMDP及信念上的策略	在状态分布上比较行动与信息收益	除状态估计外还需行动效果和效用模型	状态和策略空间复杂；最优性只相对于所给模型成立
语言模型语义推断	从异构记录提出任务结构、状态或说明	需要独立样本验证、证据约束及适当弃答	生成流畅不保证关系正确；自报概率未经校准；长上下文可能遗漏关键条件

理论基础分别见事件投影、显式不确定Trace、LTL3与概率模型原始资料。S-OT24 S-OT31 S-OT32 S-MT01 S-MT02

研究综合： 不能把“输出单个标签”直接理解为更有用，也不能把“始终输出Unknown”当作高可靠性的充分证明。应共同报告可回答覆盖率、已回答部分的错误风险、未知原因、正确决策比例与使用成本。确定性规则也可以错误；概率输出也可以可靠；关键在于证据前提和实际校准。S-GE20 S-GE21

4.4 解释方法的能力边界

方法	可验证的优势	主要限制	合适的评价单位
直接展示原始证据	减少转述步骤，可复核内容	原始记录可能难懂、缺上下文、包含敏感或误导文本	查找时间、理解题、关键事实遗漏
模板 / 规则说明	映射和证据范围相对明确，容易检查	只覆盖预定义语义；模板中的条件也可能错	每种声明与证据条件；新事件类型下的拒绝行为

方法	可验证的优势	主要限制	合适的评价单位
抽取式摘要	可保留原句和局部出处	选择、拼接和代词消解也会改变含义；自述仍可能不真实	抽取准确性、对象一致性、遗漏与上下文保持
检索增强生成与逐句引用	可表达异构证据并支持逐条核对	检索缺口、错误引用、相互矛盾及联合不一致	Claim支持度、引用充分性、相关性、重要事件覆盖
因果 / 反事实解释	在模型和干预成立时可以研究影响因素	需要干预有效性和因果识别；文本自述无法代替	特定因果命题与干预设计，而非仅相似度
自动事实评判器	能提高大规模评价吞吐	Judge偏差、任务迁移、位置与表达影响；会与生成器共享错误	独立人工样本、错误类型、校准、置信区间及失败案例

AIS、ALCE、FActScore等资料研究可归因或可支持的陈述；CoT Faithfulness研究询问可见理由与模型决策的关系，二者不是同一评价目标。自动评判工具的方法有效性不能由“也是LLM”或“使用更强模型”直接推定。S-GE02 S-GE03 S-GE04 S-GE05 S-GE07 S-GE08 S-GE18

4.5 界面与介入策略不能只按信息量比较

作为研究综合，可以按问题区分候选视图：时间线用于回答“前后发生什么”，任务结构用于回答“工作属于哪个目标”，证据卡用于回答“凭什么这样说”，状态概览用于回答“现在哪些部分仍未确定”。没有一种视图同时保留全部关系；对象与任务存在多对多关系时，单一树尤其容易隐藏交叉影响。S-OT28 S-HI09 S-HI10

需要比较的是视图对具体用户问题的帮助。例如，同样的“测试通过”卡片，若不显示验证版本，用户可能把旧验证推广到后来修改的文件。显示更多底层细节也可能提高查找负担。Progressive Disclosure应被当作信息访问策略，在特定任务中验证，而不是天然有效的解释原则。S-HI04 S-HI05 S-HI07

介入策略则有不同决策对象：转达Agent明确请求、发现违反显式规定、提示目标含糊、建议用户核对结果、调整通知时机。这些任务的错误代价与Ground Truth不同。以一个“异常检测准确率”评价全部介入，会掩盖是否可行动和是否值得打断。S-HI16 S-HI18 S-HI23

4.6 实验支持、采用程度与性能证据的读法

本轮资料中，工程采用、形式化结果、小规模研究系统和大规模基准同时存在。应分别阅读：

- 规范与公开实现证明机制被定义或提供，不证明所有客户端已实现，更不证明用户收益。
- 生产系统经验能证明特定组织条件下的实际可用性，但部署覆盖、规模和基础设施可能与第三方桌面环境不同。
- 形式化结果在给定模型与假设下有效；其现实价值还取决于模型是否覆盖真实行为。
- 基准实验证明该数据、任务与评价方法中的表现；结构上界、模拟故障和模型评判结果需单独标明。
- 受控用户研究能帮助识别局部因果效果，但实验任务、受试者、提示方式与真实长期使用不同。
- 自然使用记录有生态价值，却可能含选择偏差、不可见行为及难以排除的混杂。

没有统一任务、同样可用信息、相同真值和成本预算时，本库不合并开销或准确率数字作跨系统排名。各域中保留原始实验的条件，是为了未来进行有意义的比较。

5 Critical Findings 关键发现与争议

5.1 得到较充分支持的结论

下表的“较充分”针对限定命题，不表示其所有产品应用都已经验证。研究综合主张使用C-SYN编号，其逻辑根据来自原始资料，但跨域结论本身没有被伪装成单篇论文的实验结果。

主张ID与结论	证据与支持程度	关键限制
C-SYN-001：记录数量与问题可回答性不同；存在相同观测对应不同真实状态的情况	K及逻辑综合；可观测性、分布式时序、有限前缀监测。S-OT33 S-OT19 S-OT32	不意味着所有状态都不可判；需对具体问题和覆盖条件分析
C-SYN-002：采集未报错不能证明活动覆盖完整	P及综合；Instrumentation盲区、过滤与缓冲机制。S-OT06 S-OT09 S-OT12	源头不产生、传输丢失、解析失败是不同分母
C-SYN-003：时间邻近、Trace关系与决策原因不等价	K/P；happens-before及保守信息流。S-OT19 S-OT20 S-OT13	可以支持受限关系；不能据此排除已被其他证据证明的原因
C-SYN-004：生命周期结束、局部结果成功、验证通过和目标达成应分开判断	规范与综合；OTel、Codex、MCP Tasks提供直接反例。S-OT04 S-IF03 S-IF09	MCP条目是草案；各客户端必须分别核查
C-SYN-005：基于证据的解释可以验证支持关系，但不能因此声称还原模型内部因果理由	K/M/E；AIS、Faithfulness与CoT干预研究。S-GE02 S-GE03 S-GE04 S-GE06	可见CoT不必总不忠实；干预方法本身也有识别局限
C-SYN-006：逐条事实正确仍可能形成整体错误的叙述	E/M及综合；实体一致性和引用评价边界。S-GE29 S-GE07	需要联合对象、版本和关系检查；该实验不是Agent运行真值研究
C-SYN-007：解释更透明不保证用户更会辨错或更适当依赖	E及理论；解释界面与认知强制实验。S-HI07 S-HI08 S-GE26	不证明所有解释有害；效果受任务、受试者和界面设计影响
C-SYN-008：异常、错误、风险和值得行动是不同判断	K/M/P及综合；Mixed Initiative、转交学习与通知研究。S-HI16 S-HI18 S-HI23	行动效用依赖人的可用性、能力和任务后果
C-SYN-009：Replay能揭示观察者逻辑问题，但不能单独证明现场采集完整	P及逻辑综合；Event Sourcing、分布式故障测试。S-OT24 S-GE22 S-GE23	固定日志、模型执行与真实重新运行的结论范围不同
C-SYN-010：评判模型需要作为测量工具单独验证	E/M；JudgeBench、ContextualJudgeBench、人工校正方法。S-GE18 S-GE19 S-GE24	Judge在某任务中的相关性不保证跨域、逐条或因果可靠
C-SYN-011：弃答和Unknown可以提高特定风险控制，但必须同时评价覆盖与效用	K/M及综合；选择性预测和校准。S-GE20 S-GE21	总是拒绝回答不是有用观察者；未知类型和可补信息应明确
C-SYN-012：目前资料不足以证明存在跨客户端、跨任务且普遍可靠的偏题或错误介入器	本轮范围调查结论；AgentSight、AgentGUI、AgentTelemetry及介入实验的限定证据。S-OT15 S-HI11 S-GE33 S-GE34 S-HI24	不是证明该目标不可能，也不是声称学界没有任何其他研究；需要更广泛独立验证

5.2 重要争议及如何避免错误二分

可解释是否等于可理解。 解释可以让用户获得线索，也可以增加未经核对的确信。争议的一个来源是研究测量了不同结果：主观信任、接受建议、任务准确率、反事实预测、故障发现不是同一量。可信的综合应说明解释帮助了哪项能力，并报告另一项是否受损。S-HI07 S-HI08 S-GE26

更多Trace是否带来更好判断。 工程上，额外记录可以使原本不可辨识的问题可区分；认知上，更多内容可能增加噪声、选择性注意和判断成本。2026年一项预印本发现，特定构造任务中的LLM监督者可能因详细过程而错误拒绝本来正确的结果。这支持“信息呈现效果需要实验”，不能推出“过程记录通常有害”或“人类也必然如此”。S-FR02

LLM解释是否必然不忠实。 某些偏置信息和CoT干预实验揭示了不忠实情况；另一些研究指出干预可能改变任务本身，测量分数并不纯粹反映因果解释。合理结论是明确要验证哪类Faithfulness，而非用一个概念判所有解释真假。S-GE04 S-GE05 S-GE06

更多人类监督是否更可靠。 用户可能缺少上下文、时间或专业能力，也可能因重复提醒而形成惯性。交还控制并不自动恢复良好判断。相反，在明确可行动且人拥有额外信息的场景，参与可能很有价值。两者可以同时成立。S-HI14 S-HI20 S-HI21 S-HI23

更复杂的状态模型是否更准确。 更细的模型能够表达并发、多对象和不确定性，却需要更多可辨认参数及更可靠语义。表达力、可识别性、计算复杂度和可验证性是不同维度；不能以模型复杂证明外部有效性。S-OT28 S-OT31 S-MT01

5.3 本次不成立的强结论

以下说法缺少足够支持，未来AI不应把它们作为背景事实继承：

1. 所有AI编程客户端都有可订阅且语义等价的统一日志流。
2. 只要同时采集OS事件与Transcript，就能恢复完整真实因果过程。
3. 一段自述、一个completed事件或一次通过的测试足以证明用户目标已完成。
4. 为每一句话附上引用就能解决幻觉、遗漏、实体错配和证据过时。
5. 可解释界面会普遍提高信任、理解和准确率，并且没有相互冲突。
6. 模型能够普遍判断任何Agent是否偏题，并自动找到最佳提醒时机。
7. 一个模拟基准的满分、一个平台的低开销或一个小样本用户研究可以直接作为Yukio的预计效果。
8. 使用更强模型作Judge就不再需要人工真值、统计检验和部署分布测试。

这些不是悲观结论，而是为可靠研究保留正确的证明责任。

6 Open Research Questions 开放研究问题

6.1 优先级的含义

P0表示其他结论赖以成立的知识前提；P1表示有基础后应开展的比较与因果调查；P2表示更长期、情境化或昂贵的问题。优先级按知识依赖组织，不是产品开发排期。下表每项都是O；其中提到的可能收益均属于H，尚未在Yukio验证。

6.2 开放问题与依赖矩阵

ID / 优先级	明确的研究问题	前置依赖	能够推进知识的证据
ORQ-01 / P0	对给定观察源，如何表达可以检查的Coverage Contract，包括结构盲区和版本条件?	RQ-01-02/03/04	以独立记录的真实活动为分母；分别验证生成、采集、解析和展示覆盖
ORQ-02 / P0	哪些用户问题在给定证据下可回答，哪些存在无法排除的相容反例?	ORQ-01；RQ-02-06/07	构造观测等价但真值不同的执行对；检验确定判断与正确弃答
ORQ-03 / P0	跨客户端Task、Run、Turn、Tool和终态映射可保留多少原始语义?	RQ-02-01/02	固定版本规范对照；无法等价的映射及其反例，而非只统计成功解析
ORQ-04 / P0	如何建立独立的事件、关系、状态及陈述支持真值?	ORQ-01/03；RQ-07-01/02	多层标注规则；独立测量源；分歧与不可判保留；对象及版本关联
ORQ-05 / P0	Observer Judge在哪些错误类型、证据长度和模型分布上有效?	ORQ-04	盲评人工样本、困难反例、模型互评与位置测试；分层误差及校准
ORQ-06 / P1	多来源融合究竟增加独立证据，还是重复强化同一错误?	ORQ-01/04	来源消融、共享上游依赖分析、矛盾样本及关联边Ground Truth
ORQ-07 / P1	集合状态、概率过滤、规则和LLM在相同部分观测条件下如何比较?	ORQ-02/04/05	固定可用信息和成本；结构性缺失、延迟、分布变化；风险-覆盖曲线
ORQ-08 / P1	如何衡量解释中的重要遗漏、联合不一致及过时验证?	ORQ-03/04/05	与用户问题有关的事实清单；版本变化；摘要之外的独立证据覆盖分母
ORQ-09 / P1	什么视图帮助普通用户正确区分执行、验证、目标及Unknown?	ORQ-02/08；领域04理论	随机对照理解任务、错误辨认、迁移预测；满意度与信任单列
ORQ-10 / P1	何种不确定性表达既不夸大能力，又避免用户把Unknown理解为失败?	ORQ-02/05/09	定性访谈与行为实验；原因式表达、概率、区间、证据缺口的对照
ORQ-11 / P1	哪些错误或风险存在正的干预净效用?	ORQ-04/09；领域06理论	定义人可采取的行动；估计纠正概率、等待损失、中断成本和人类错误
ORQ-12 / P1	介入策略怎样在动态工作负荷下平衡时机、频率与遗漏?	ORQ-11；用户情境测量	同一错误的不同提醒时机比较；重复使用和延迟反馈；总成本测量
ORQ-13 / P1	观察者本身造成多少时延、信息暴露与执行变化?	ORQ-01；独立基线	观测启闭对照；负载、同步Hook、资源争用和尾部行为；避免只报平均
ORQ-14 / P2	如何在长期使用中维持适当依赖而非惯性接受或过度怀疑?	ORQ-09/10/12	纵向研究；真实失误和成功比例；行为与理解随时间变化

ID / 优先级	明确的研究问题	前置依赖	能够推进知识的证据
ORQ-15 / P2	面向单次解释的采样与信息保留是否不同于运维统计采样?	ORQ-01/08/13	在相同成本下比较重要证据可恢复性、延迟和用户决策质量
ORQ-16 / P2	自然语言目标可有多大比例转化为可靠且不误伤的显式属性?	ORQ-02/04/11	属性内容效度；人工目标歧义；Runtime Verification与最终任务结果的区别
ORQ-17 / P2	数据、客户端和Agent策略变化后，旧评估结论多久失效?	ORQ-03/05/07	跨版本、跨框架、跨任务持出；版本与配置记录；时间外验证
ORQ-18 / P2	签名收据或可验证记录能增加哪些证据保证，又仍留下哪些语义缺口?	ORQ-01/04；Provenance区分	分别验证来源认证、记录完整性、漏记检测和内容真值；补查原始协议

这些问题由已核查的覆盖限制、状态理论、解释评价、人因证据和故障测试研究共同引出。S-OT06 S-OT31 S-GE07 S-GE21 S-GE24 S-HI08 S-HI18 S-HI24

6.3 研究依赖中容易走反的顺序

在没有独立事件和状态真值之前，不宜先比较复杂解释模型的“正确率”；否则评价可能只反映两个模型是否讲出相似故事。在没有定义可采取的行动与成本之前，不宜把异常检测阈值称为干预策略。在没有测量实际理解之前，也不宜用用户“更喜欢这个界面”判断它改善了监督能力。

这些约束不要求所有研究串行开展。理论分析、数据标注和用户问题访谈可以并行；但每个实验应标明哪些前提已验证、哪些仍是暂定假设，并避免把暂定部分隐藏在最终得分中。

7 Cross-Domain Synthesis 跨领域综合

7.1 从活动到人类决策的证明责任

下面五个转变需要不同证据：

1. 世界中的活动 → 可获得记录。 要知道观察范围、事件语义和缺失机制。
2. 记录 → 执行关系与状态。 要知道身份、时间、版本、并发及模型假设。
3. 状态与记录 → 自然语言解释。 要检查事实支持、引用充分性、冲突、遗漏及不确定性。
4. 解释与视图 → 用户理解。 要测量用户是否能回答、预测和辨错，不能只测好感。
5. 理解与问题判断 → 参与策略。 要考虑人的行动能力、后果、时机及中断成本。

领域07分别评价这些转变，也评价整体效果。任何一步的性能都不能单独证明后续结果。这个依赖是本研究的理论综合，不是本次进行过的端到端Yukio实验。

7.2 哪些连接有直接证据，哪些仍是推论

跨域连接	直接证据支持的内容	本研究推论与仍需检验的部分
01 → 02	缺失Instrumentation、上下文传播和事件顺序会限制记录结构。S-OT06 S-OT19	对特定Agent问题的可回答上界，需要Coverage Contract和独立真值
02 → 03	事件身份、对象关系和Provenance有可定义的数据语义。S-OT26 S-OT28 S-GE01	保留这些关系能减少哪些解释错误、减少多少，需专门实验
03 → 04	某些解释设计影响用户依赖与任务表现，且方向不一致。S-HI07 S-HI08	面向Agent执行的逐证据解释是否提高普通用户理解仍需检验
04 → 06	通知时机、认知负担及持续重复会影响行为。S-HI18 S-HI20 S-HI21	这些效应如何迁移到桌面Agent监督，不能直接套用其他行业的数值
02/03 → 06	部分观测决策与转交模型能形式化信息和行动效用。S-MT01 S-HI16 S-HI23	真实Agent任务的效用参数、人的能力和错误后果能否可靠估计仍未解决
07 → 各域	独立测试、故障注入、人工校正与测量区分能揭示不同误差。S-GE22 S-GE24 S-HI10	各局部改进能否转化为长期净价值，需要现场与纵向证据

7.3 一个贯穿六域的构造案例

以下记录是教学用虚构示例，不来自Yukio、Claude Code或Codex实际接口。为隔离问题，假设源时间使用同一时钟；“版本”表示被独立记录的制品内容身份。

记录	发生时间 / 到达时间	已获得的内容
E-01	10:00:00 / 10:00:00	用户要求修改导入逻辑并运行相关测试；任务范围记为U
E-02	10:00:11 / 10:00:12	一次明确关联的修改生成版本r7
E-03	10:00:18 / 10:00:18	测试调用T开始，验证对象为r7
E-04	10:00:24 / 10:00:40	T返回成功，记录显示12项测试通过；结果延迟到达

记录	发生时间 / 到达时间	已获得的内容
E-05	10:00:26 / 10:00:26	后续修改生成r8
E-06	10:00:27 / 10:00:27	子工作B发出等待用户确认的明确请求；另一子工作C仍有运行信号
E-07	10:00:29 / 10:00:29	主Agent自述：“已完成，测试通过”
E-08	10:00:30 / 10:00:30	主Agent本轮结束；没有足以证明U全部子工作终止的聚合证据
E-09	10:00:31 / 10:00:31	一条观察通道断开，尚无补齐回执

在10:00:35，解释可以说：“导入逻辑已出现两个记录到的版本。测试T已开始，但其结果尚未到达。Agent自述任务已完成；子工作B请求确认，C最近仍有运行信号。部分观察通道已断开，因此无法确定当前全部执行状态。”

在10:00:41，新增证据允许修订：“后来收到的记录显示，针对r7的12项测试已通过。此后产生了r8；现有记录尚未确认r8经过相同测试。任务U的整体完成状态仍未得到独立确认。”

这里不应说“r8有错误”，因为旧验证不覆盖新版本只能说明验证缺口；也不应说“r8没有被测试”，因为观察通道存在缺口。可以准确表达的是“现有记录尚未确认”。

领域	本例需要解决的问题	会发生的典型错误
01	通道是否覆盖相关动作，E-09意味着哪段信息不完整	把断连后的安静显示为无活动
02	T关联r7；B和C并发；迟到E-04改变现在所知	用最后一条事件决定整个任务状态
03	区分自述、实际测试结果及验证范围	把E-07转述成观察者已确认事实
04	帮助用户看懂“旧版本通过、新版本未知、局部等待”	将多维状态压成一个绿色完成标识
06	判断B的请求是否需要及时转达，以及谁能采取什么行动	看到任何等待就打断，或因主轮结束而遗漏真实请求
07	分别评价10:00:35和10:00:41的可用证据	混同事后事实真值与当时证据充分性，或把E-04提前输入在线观察者

这个例子只验证概念之间是否一致，不提供某种界面或策略的效果证据。其原则与事件时间/观察时间、版本化证据、状态和解释分层相容。S-OT18 S-OT25 S-GE01 S-GE03

7.4 证据支持、来源可信与不确定性的组合

一个可复核的陈述至少需要明确对象、谓词、范围、时间/版本、证据来源和表达模态。这是一种研究分析方式，并不规定存储Schema。例如，“测试通过”只有在补充“哪个测试、什么结果、针对什么对象、何时、由谁记录”之后，才具有足够明确的验证范围。

需要避免三种替代：

- 来源认证替代事实真值。 一条记录确实来自某组件，只能确认其归属；组件仍可能只报告意图、错误自述或不完整结果。
- 证据支持替代因果解释。 文件被读取与其影响决策是不同命题；PROV关系与Faithfulness研究提醒我们限制措辞。

- 概率替代可回答前提。 估计概率需要定义事件及校准样本；缺少关键身份、版本或覆盖信息时，数字不能自行补齐语义。

这些区分并不否定概率模型、签名或语言模型的价值，而是防止一种保证被用于回答另一种问题。S-GE01 S-GE02 S-GE20 S-MT01

7.5 可靠性不是各层准确率简单相乘

联合成功概率可以按概率链式法则分解为条件概率之积，这不要求独立。只有直接把各层的边际成功率相乘时，才需要相应独立假设或其他足以支持该等式的条件。真实观察者的错误常常相关：缺失调用ID同时影响关联、状态和引用；同一模型可能生成解释并作Judge；界面隐藏未知会改变用户行动及后续证据。

因此，本研究不使用若干不同数据集的准确率相乘来预测整体可靠性。更可解释的分析是：定位具体错误链，保留每层独立指标，再用端到端任务和用户结果检验总体价值。只有在共同实验中明确估计条件概率及依赖关系，分解才有实际意义。S-GE18 S-GE24 S-HI10

C-SYN-013｜H：面向普通用户的可靠观察，核心可能是“在有用范围内保持证据边界”，而非持续输出最详细的故事。 这一判断来自六域综合。它提出可检验方向：在同样证据条件下比较详尽叙述、简明且标明未知的说明以及原始记录展示，衡量理解、错误辨认、适当依赖和总任务成本。该假设尚未获得Yukio实验证明。

8 Research Source Library 带注释的来源库

8.1 资料构成与使用规则

本库收录 114条来源记录：A3 85条、A2 20条、A1 9条；A0和A4均为0。记录可能指向同一研究的论文、仓库或相关规范，因此不能将记录数等同于独立研究数。K/E/P/M类别可重叠，不能直接相加。

每条资料给出作者或机构、年份、访问入口、证据性质、实际核查定位、成立条件和限制。A1条目的“支持”仅指摘要或出版页面直接允许的有限结论；A3也不代表逐页通读或本地复现。来源自身对未来用途的推测不会因进入本库而升级成已证实结论。

来源组	记录数	主要作用
S-OT01-33	33	可观测性、分布式事件与状态理论、系统机制
S-GE01-35	35	证据支持、事实评价、Judge与Observer评价
S-HI01-29	29	人类理解、可视化、参与与提醒研究
S-IF01-13	13	当日官方接口、协议和代表性观测平台
S-FR01-02	2	近期直接相关预印本，保留窄证据边界
S-MT01-02	2	POMDP与HMM概率方法基础

以下来源ID在续研中保持不变；来源更新时记录新版本与核查日期，不覆盖旧结论的条件。

8.2 可观测性、事件与状态

S-OT01 - Feedback Systems: An Introduction for Scientists and Engineers

作者 / 机构： Karl Johan Åström；Richard M. Murray。 发表 / 版本时间： 2008。

来源状态： 权威学术教材；机构档案。 证据类型： K。 核查深度： A1。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： 机构档案的目录、摘要、出版信息；第7章 Output Feedback / Observability 的搜索索引摘录
- 直接支持的范围： 提供状态空间、可观测性与估计器的经典教材入口。
- 成立条件： 理论入口对应书中已定义的状态空间模型；本轮未以未取得的第7章全文支持具体证明。
- 重要限制： 本次第7章PDF多条作者及机构下载链接均抓取失败；没有将索引摘录算作全文核查。
- 在本库的作用： 权威理论背景及后续全文核查入口；秩条件本轮改由S-OT33支持。

S-OT02 - Observability primer

作者 / 机构： OpenTelemetry Authors。 发表 / 版本时间： 持续更新（核查2026）。

来源状态： 官方工程概念文档。 证据类型： P。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： What is Observability? / Reliability and metrics / Understanding distributed tracing，正文行 858-889
- 直接支持的范围： 工程可观测性依赖适当的Instrumentation；日志与聚合指标承担不同信息功能。
- 成立条件： 适用于OpenTelemetry所讨论的软件遥测语境，需要应用或相关层级实际生成所需信号。
- 重要限制： 这是项目概念说明，不是证明任意系统全状态可重建的数学定理。
- 在本库的作用： 软件可观测性术语基线，与控制理论定义对照。

S-OT03 - OpenTelemetry Specification - Overview

作者 / 机构： OpenTelemetry Authors。 发表 / 版本时间： 持续更新（核查2026）。

来源状态： 官方技术规范。 证据类型： P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Tracing / Metrics / Logs；Span关系和scatter/gather示例；测量、聚合、Views
- 直接支持的范围： Trace使用Span及关系表达执行；Metrics区分原始测量与属性聚合。
- 成立条件： 定义只约束遵循对应规范的信号表示；采集、传播及语义映射需另行成立。
- 重要限制： 数据表达规范不保证Instrumentation覆盖，也不提供用户任务语义。
- 在本库的作用： 信号定义和非树形Span关系的规范依据。

S-OT04 - OpenTelemetry Specification - Tracing API

作者 / 机构： OpenTelemetry Authors。 发表 / 版本时间： 持续更新（核查2026）。

来源状态： 官方技术规范。 证据类型： P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Set Status；End；Links；Span生命周期，尤其End不影响child spans条款
- 直接支持的范围： Span默认状态为Unset，结束父Span不能改变其子Span的结束状态。
- 成立条件： 状态与End行为适用于遵循该Trace API的实现及被定义为Span的操作范围。
- 重要限制： Ok是应用侧操作状态声明，不是用户目标或制品正确性的统一验证。
- 在本库的作用： 终态含义、树结构误读和证据边界的直接规范反例。

S-OT05 - Trace Context - W3C Recommendation, 23 November 2021

作者 / 机构： W3C Distributed Tracing Working Group。 发表 / 版本时间： 2021。

来源状态： W3C Recommendation，2021-11-23。 证据类型： P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： §3.2 traceparent；§3.2.2.5 trace-flags / Sampled；§4 Processing Model
- 直接支持的范围： Trace Context标准化跨组件身份传播，sampled标志是受实现与负载条件影响的建议。
- 成立条件： 仅在参与组件解析和传播所选版本Trace Context时适用；采样决策允许组件差异。
- 重要限制： 采样标志不是事件持久化回执或端到端完整性证明；核查的是2021 Recommendation正文。
- 在本库的作用： 跨组件上下文、采样边界与标准语义。

S-OT06 - Dapper, a Large-Scale Distributed Systems Tracing Infrastructure

作者 / 机构： Benjamin H. Sigelman；Luiz André Barroso；Mike Burrows；Pat Stephenson；Manoj Plakal；Donald Beaver；Saul Jaspan；Chandan Shanbhag。 发表 / 版本时间： 2010。

来源状态： Google原始技术报告，2010。 证据类型： P/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： §2分布式跟踪与库级Instrumentation； §3.2 Tracing Coverage，PDF第4-5页附近
- 直接支持的范围： 库级上下文传播可支持生产追踪，但完全不产生Trace的进程不可见，非标准控制流可漏关联或错关联。
- 成立条件： 实验与部署经验来自Google基础设施、共同库Instrumentation和论文描述的抽样条件。
- 重要限制： Google内部部署经验；本文没有为第三方客户端覆盖或通用用户任务成功提供保证。
- 在本库的作用： 成熟生产实践与完整性反例。

S-OT07 - X-Trace: A Pervasive Network Tracing Framework

作者 / 机构： Rodrigo Fonseca；George Porter；Randy H. Katz；Scott Shenker；Ion Stoica。 发表 / 版本时间： 2007。

来源状态： NSDI 2007学术论文。 证据类型： M/E。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： §1-3元数据传播与部署条件；正文的partial deployment及causal connections讨论
- 直接支持的范围： 跨协议层传播任务元数据能够关联路径，但依赖参与组件遵循传播机制。
- 成立条件： 相关协议层、客户端或设备需要携带并传播X-Trace元数据，且管理域允许共享相应报告。
- 重要限制： 相关协议、设备或客户端可能需修改；部分部署与管理域共享限制覆盖；未在本地复现。
- 在本库的作用： 跨层协作式追踪替代路线。

S-OT08 - Using Magpie for request extraction and workload modelling

作者 / 机构： Paul Barham；Austin Donnelly；Rebecca Isaacs；Richard Mortier。 发表 / 版本时间： 2004。

来源状态： OSDI 2004学术论文。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： §3 Request parser / Event schema / Temporal joins； §3性能实验及 §6场景范围
- 直接支持的范围： 应用特定Schema与有效时间区间可从交织事件中提取请求，而无需全局请求ID传播。
- 成立条件： 必须有应用特定事件Schema、可用于Join的属性及有效时间区间；实验采用论文年代的ETW工作负载。
- 重要限制： 需要领域语义和Instrumentation；实验是当时Web及数据库工作负载，未证明Agent任务理解能力。
- 在本库的作用： 基于既有事件关联的主要替代路线。

S-OT09 - BPF ring buffer - Linux Kernel Documentation

作者 / 机构： Linux Kernel Documentation Contributors。 发表 / 版本时间： 持续更新（核查2026）。

来源状态： Linux内核官方文档。 证据类型： P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Motivation / Semantics and APIs / Design and Implementation；buffer reservation及NMI失败条件
- 直接支持的范围： Ring buffer可以跨CPU共享，但满队列或特定锁竞争条件会使记录预留失败。
- 成立条件： 描述Linux BPF Ring Buffer指定的预留与提交接口；事件是否被挂接探针观测不由缓冲区决定。
- 重要限制： 描述缓冲传输机制，不保证所有系统事件都被Instrument；未运行压力实验。
- 在本库的作用： 系统监测无损假设的直接反例。

S-OT10 - ETW - About Event Tracing; EVENT_TRACE_PROPERTIES structure

作者 / 机构： Microsoft。 发表 / 版本时间： 持续更新（核查2026）。

来源状态： Microsoft官方技术文档。 证据类型： P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： About Event Tracing；EVENT_TRACE_PROPERTIES中的EventsLost、LogBuffersLost、RealTimeBuffersLost及Remarks
- 直接支持的范围： ETW区分事件未记录、日志缓冲未写入与实时消费者未收到等丢失计数。
- 成立条件： Provider、会话与消费者已按相应Windows API配置；丢失统计需在正确会话范围内查询。
- 重要限制： API文档存在不表示目标客户端已启用所需Provider，也不说明当前账户具备权限。
- 在本库的作用： Windows事件监测与采集健康的官方依据。

S-OT11 - Build an Endpoint Security app - WWDC20 Session 10159

作者 / 机构： Apple。 发表 / 版本时间： 2020。

来源状态： Apple WWDC20官方技术讲解。 证据类型： P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： 官方转录：订阅与队列、AUTH与NOTIFY、缓存和muting、耗时处理造成消息丢失，行164-206及248-304
- 直接支持的范围： Endpoint Security按订阅发布系统事件；AUTH可阻塞操作，过滤与处理队列影响覆盖。
- 成立条件： 针对已授权且订阅相应事件的Endpoint Security客户端；缓存、muting和处理时延影响交付。
- 重要限制： 历史官方API说明；具体2026系统版本与授权需另核查；独立seq_num文档只取得搜索摘录。
- 在本库的作用： macOS观察与控制边界、观察者效应实例。

S-OT12 - inotify(7) - Linux manual page

作者 / 机构： Linux man-pages project。 发表 / 版本时间： 持续更新（核查2026）。

来源状态： Linux man-pages项目文档。 证据类型： P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： /proc interfaces；Limitations and caveats；事件合并、队列溢出及不含行为者信息

- 直接支持的范围： inotify可合并相同未读事件、丢弃溢出事件，且不提供发起进程或用户身份。
- 成立条件： 针对inotify监控对象和已启用通知；不跨越其文件系统及事件语义限制。
- 重要限制： 它是文件系统通知机制，不能单独用于可靠活动计数和Agent归因；本轮没有本地复现。
- 在本库的作用： 文件观察不能等同于审计记录的反例。

S-OT13 - Practical Whole-System Provenance Capture

作者 / 机构： Thomas Pasquier；Xueyuan Han；Mark Goldstein；Thomas Moyer；David Eyers；Margo Seltzer；Jean Bacon。 发表 / 版本时间： 2017。

来源状态： ACM CCS 2017学术论文。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1145/3127479.3129249。

- 核查定位： §3系统Provenance、共享内存近似、对象版本；PDF第2-3页相关段落
- 直接支持的范围： CamFlow对无法直接观测的共享内存传播采用保守关联，并使用对象版本组织信息流图。
- 成立条件： 系统采用CamFlow捕获机制及其对象版本、内核对象和共享内存保守近似。
- 重要限制： 潜在信息流不等于实际语义影响；没有复核全部实验数据或执行系统。
- 在本库的作用： 系统级Provenance的能力与过度关联限制。

S-OT14 - AgentOps: Enabling Observability of LLM Agents

作者 / 机构： Liming Dong；Qinghua Lu；Liming Zhu。 发表 / 版本时间： 2024。

来源状态： 学术研究论文；按所引2024预印本核查。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.48550/arXiv.2411.05285。

- 核查定位： arXiv v2（2024-11-30）； §2 GitHub/Google工具检索； §4分类； §5限制
- 直接支持的范围： 论文基于17个工具的资料提出Agent目标、规划、工作流、任务及工具观测点分类。
- 成立条件： 工具样本由论文描述的GitHub/Google检索与公开资料获得，分类基于17个工具。
- 重要限制： 工具资料映射有检索和分类遗漏；未证明分类能保证安全或准确重建所有Agent行为。
- 在本库的作用： Agent专门观测的概念分类，不作为成熟性证明。

S-OT15 - AgentSight: System-Level Observability for AI Agents Using eBPF

作者 / 机构： Yusheng Zheng；Yanpeng Hu；Tong Yu；Andi Quinn。 发表 / 版本时间： 2025。

来源状态： 2025学术预印本，所引v1。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.48550/arXiv.2508.02736。

- 核查定位： 固定arXiv v1； §3技术机制； §5性能环境、Table 1、三个案例
- 直接支持的范围： 固定Linux/Claude Code环境的三类任务各三次实验中报告平均2.9%开销，单项最高4.9%。
- 成立条件： Ubuntu22.04、Linux6.14.0、Claude Code1.0.62与固定仓库，三类工作流各三次。
- 重要限制： 小样本固定任务及版本；案例没有通用错误判断Precision/Recall；未在Yukio或其他平台复现。
- 在本库的作用： 系统层Agent观察候选路线及经验结论外推边界。

S-OT16 - Semantic Conventions for GenAI agent and framework spans

作者 / 机构： OpenTelemetry GenAI Semantic Conventions Contributors。 发表 / 版本时间： Development 分支快照（2026-10-17）。

来源状态： OpenTelemetry专门仓库；Development状态。 证据类型： M/P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Status: Development；Agent/Workflow/Tool操作及字段定义；旧站页面迁移说明
- 直接支持的范围： 当日GenAI Agent约定处于Development状态，定义Agent、Workflow和Tool等操作语义。
- 成立条件： 核查日专门GitHub仓库main分支的Development约定；实现方实际采用情况需独立验证。
- 重要限制： main为可变分支；旧官网页面已停止维护；约定不能证明客户端已实现字段或采集完整。
- 在本库的作用： 前沿标准化状态及文档迁移风险。

S-OT17 - Sampling - OpenTelemetry

作者 / 机构： OpenTelemetry Authors。 发表 / 版本时间： 2025。

来源状态： OpenTelemetry官方工程文档。 证据类型： P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Head Sampling / Tail Sampling；页面最后修改2025-10-16
- 直接支持的范围： Head Sampling缺少完整结果信息；Tail Sampling利用更多Span但增加状态保存和运行资源需求。
- 成立条件： Head/Tail策略必须结合各自采样位置、缓冲和处理资源讨论；依赖完整上下文的决策受已收集Span限制。
- 重要限制： 文档给出机制和取舍，不是所有部署的成本或完整性实测；源头已丢弃的数据不能由下游恢复。
- 在本库的作用： 抽样与观测成本、覆盖取舍。

S-OT18 - OpenTelemetry Specification - Logs Data Model

作者 / 机构： OpenTelemetry Authors。 发表 / 版本时间： 持续更新（核查2026）。

来源状态： OpenTelemetry官方数据模型规范。 证据类型： P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Field: Timestamp；Field: ObservedTimestamp；TraceId/SpanId与Resource/InstrumentationScope
- 直接支持的范围： 日志模型区分源事件时间与采集系统观察时间，源事件时间可以未知。
- 成立条件： 源系统与观察组件需分别说明时间字段来源；未知Timestamp不能等同于ObservedTimestamp。
- 重要限制： 不同时间字段仍受来源时钟影响；字段存在不证明跨来源时间可精确比较。
- 在本库的作用： 事件时间与到达时间的规范依据。

S-OT19 - Time, Clocks, and the Ordering of Events in a Distributed System

作者 / 机构： Leslie Lamport。 发表 / 版本时间： 1978。

来源状态： Communications of the ACM 1978学术论文。 证据类型： K。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1145/359545.359563。

- 核查定位： Happened before定义；Clock Condition；total ordering，正文前4页
- 直接支持的范围： Happens-before蕴含逻辑时钟递增，逆命题不成立，任意平局规则构成的全序不唯一。
- 成立条件： 基于进程内顺序、发送接收匹配与传递性定义的分布式系统模型。
- 重要限制： 关系建立于指定进程和通信模型；它不是决策理由或反事实因果的证明。
- 在本库的作用： 偏序、并发、排序显示与因果含义的理论基础。

S-OT20 - Virtual Time and Global States of Distributed Systems

作者 / 机构： Friedemann Mattern。 发表 / 版本时间： 1989。

来源状态： Parallel and Distributed Algorithms，1989学术论文。 证据类型： K。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： §6 Virtual time；§7 Vector time，PDF第5-8页定义、协议与分量偏序
- 直接支持的范围： 完整参与和时间传播模型下，向量时钟可保留因果偏序与并发关系。
- 成立条件： 参与进程按协议更新并传播向量，比较关系限于该事件和通信模型。
- 重要限制： 维度及传播均有成本；不能为原本没有传播信息的任意日志事后恢复全部因果。
- 在本库的作用： 向量时钟、潜在影响与真实因果的区分。

S-OT21 - Timestamps in Message-Passing Systems That Preserve the Partial Ordering

作者 / 机构： Colin J. Fidge。 发表 / 版本时间： 1988。

来源状态： Australian Computer Science Communications，1988学术论文。 证据类型： K。 核查深度： A1。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： 搜索索引中的摘要和导言；多处全文镜像抓取失败
- 直接支持的范围： 提供与向量时间及偏序保留有关的同期原始研究线索。
- 成立条件： 仅作为待补查原始文献线索；证明适用条件本轮未全文核实。
- 重要限制： 未取得可读全文；不据此宣称已核查证明，正文理论由S-OT20支持。
- 在本库的作用： 理论历史与后续全文补查。

S-OT22 - Distributed Snapshots: Determining Global States of Distributed Systems

作者 / 机构： K. Mani Chandy；Leslie Lamport。 发表 / 版本时间： 1985。

来源状态： ACM TOCS 1985学术论文。 证据类型： K。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1145/214451.214456。

- 核查定位： §1稳定性质；§2系统模型；Marker算法与相容全局状态讨论
- 直接支持的范围： 一致全局状态需计入在途消息；原算法依赖可靠FIFO通道和参与方Marker协议。
- 成立条件： 原算法要求参与方执行Marker协议、可靠FIFO通道及有限消息延迟，并计入在途消息。
- 重要限制： 被动、不完整日志不自动满足条件；阶段结束与整个计算终止有区别。
- 在本库的作用： 全局完成、相容切面与局部状态拼接限制。

S-OT23 - Unreliable Failure Detectors for Reliable Distributed Systems

作者 / 机构： Tushar Deepak Chandra；Sam Toueg。 发表 / 版本时间： 1996。

来源状态： Journal of the ACM 1996学术论文。 证据类型： K。 核查深度： A1。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1145/226643.226647。

- 核查定位： Cornell作者资料页的论文摘要；JACM 43(2):225-267；1995技术报告入口
- 直接支持的范围： 故障检测器以Completeness和Accuracy分类，异步系统中的检测可发生错误怀疑。
- 成立条件： 作者摘要针对异步、可崩溃进程的故障检测与共识模型；具体定理条件待全文补查。
- 重要限制： 本次未取得可读全文；正文不复述完整证明或各类检测器的精确最弱条件。
- 在本库的作用： 静默、怀疑与失败区别的理论入口。

S-OT24 - Event Sourcing

作者 / 机构： Martin Fowler。 发表 / 版本时间： 2005。

来源状态： 原始工程模式论述，2005。 证据类型： P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： 2005-12-12文章；状态变化与重建；External Updates / External Queries及Replay边界
- 直接支持的范围： 从事件重建状态要求保留变化历史，重放外部效果与外部历史查询需要额外处理。
- 成立条件： 领域变化被保留为权威事件历史；重放时外部副作用和历史查询已有处理机制。
- 重要限制： 工程模式论述，不是任意日志的无损重建定理；模型重执行并不等于历史复现。
- 在本库的作用： Event Sourcing与普通审计日志、Replay的区别。

S-OT25 - The Dataflow Model: A Practical Approach to Balancing Correctness, Latency, and Cost in Massive-Scale, Unbounded, Out-of-Order Data Processing

作者 / 机构： Tyler Akidau；Robert Bradshaw；Craig Chambers；Slava Chernyak；Rafael J. Fernández-Moctezuma；Reuven Lax；Sam McVeety；Daniel Mills；Frances Perry；Eric Schmidt；Sam Whittle。 发表 / 版本时间： 2015。

来源状态： PVLDB 2015学术论文。 证据类型： M/P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.14778/2824032.2824076。

- 核查定位： §2 Event Time / Processing Time；Watermark及离线来源脚注；窗口、触发与更新语义

- 直接支持的范围： 无界乱序数据需区分事件时间与处理时间，Watermark完整性依赖来源和策略假设。
- 成立条件： 面向无界或乱序输入的数据处理模型；Watermark能否保证完整取决于来源及策略。
- 重要限制： 启发式Watermark并非一般完备证明；2015的系统对比不代表今日工具能力。
- 在本库的作用： 乱序、迟到、修订及正确性-延迟-成本取舍。

S-OT26 - CloudEvents Specification - Version 1.0.2

作者 / 机构： CloudEvents Project。 发表 / 版本时间： v1.0.2（固定版本）。

来源状态： CloudEvents技术规范v1.0.2。 证据类型： P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Terminology: Occurrence / Event / Source；Required Attributes: id、source、specversion
- 直接支持的范围： 一次Occurrence可产生多个事件；source加id要求区分不同事件，可用于重复投递识别。
- 成立条件： 遵循固定CloudEvents1.0.2规范的生产者正确维护source与id语义。
- 重要限制： 格式规范不提供Exactly-once执行、真实因果或全局排序保证；发布日期未独立核查。
- 在本库的作用： 事件与事实、身份与重复语义的规范基线。

S-OT27 - About XES - IEEE Task Force on Process Mining

作者 / 机构： IEEE Task Force on Process Mining。 发表 / 版本时间： 2020。

来源状态： IEEE Task Force官方概述；不是完整IEEE规范正文。 证据类型： P。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： 官方说明的Log / Trace / Event元模型及属性扩展；页面更新2020-12-19
- 直接支持的范围： XES以Log、Trace与Event组织日志，扩展为属性提供约定语义。
- 成立条件： 本次只采用官方XES概述中的元模型和扩展说明，不据此推断全部IEEE规范要求。
- 重要限制： 未取得IEEE XES规范全文；本轮仅核查官方概述，不将其当完整规范符合性审查。
- 在本库的作用： 传统Case-centric日志交换表示。

S-OT28 - OCEL (Object-Centric Event Log) 2.0 Specification

作者 / 机构： Alessandro Berti；István Koren；Jan Niklas Adams；Gyunam Park；Benedikt Knopp；Nina Graves；Majid Rafiei；Lukas Liß；Leah Tacke Genannt Unterberg；Yisong Zhang；Christopher Schwanen；Marco Pegoraro；Wil M. P. van der Aalst。 发表 / 版本时间： 2024。

来源状态： OCEL技术规范；固定arXiv v1。 证据类型： P/M。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.48550/arXiv.2403.01975。

- 核查定位： 固定v1，2024-03-04提交；封面2.0/2023-10-16； §2-4及Definition 2
- 直接支持的范围： OCEL 2.0支持一事件多对象、带角色关系和随时间变化的对象属性。
- 成立条件： 采用固定arXiv v1的2.0定义，事件、对象、类型和关系已按该元模型表示。
- 重要限制： 表达关系不等于发现真实因果；原站旧2.0路径当日返回2.1.0pre5，故采用固定arXiv版本。

- 在本库的作用： Object-centric替代表示及来源版本漂移案例。

S-OT29 - Workflow Mining: Discovering Process Models from Event Logs

作者 / 机构： Wil M. P. van der Aalst；Ton Weijters；Laura Maruster。 发表 / 版本时间： 2004。

来源状态： IEEE TKDE 2004学术论文。 证据类型： K/M。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1109/TKDE.2004.47。

- 核查定位： 作者稿； §2 Petri nets定义；α-algorithm相关模型与无噪声、完整日志假设，前7页
- 直接支持的范围： 经典α方法的重发现保证限于特定工作流网类别及符合条件的事件日志。
- 成立条件： α算法相关保证限于指定工作流网类别以及完整、无噪声和明确Case的日志条件。
- 重要限制： 不保证从噪声、稀有路径缺失或任意非结构化Agent过程恢复真实流程。
- 在本库的作用： 流程发现、Petri Net与方法成立条件。

S-OT30 - Process Mining Manifesto

作者 / 机构： Wil M. P. van der Aalst et al.；IEEE Task Force on Process Mining。 发表 / 版本时间： 2011形成；2012出版。

来源状态： 领域共同宣言；2011形成，2012学术出版。 证据类型： K/P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1007/978-3-642-28108-2_19。

- 核查定位： Process Mining类型； §3 Guiding Principles GP1-GP6；事件质量及用途相关模型
- 直接支持的范围： 流程分析结果取决于事件语义和质量，模型是目的相关抽象，发现与符合性检查不同。
- 成立条件： 属于流程挖掘社区的指导原则；分析问题、事件语义与模型抽象范围必须显式确定。
- 重要限制： 社区指导与历史领域总结，不是单一方法实验；当年成熟度描述不作2026市场事实。
- 在本库的作用： Process Mining方法地图及批判性数据前提。

S-OT31 - Conformance Checking over Uncertain Event Data

作者 / 机构： Marco Pegoraro；Merih Seran Uysal；Wil M. P. van der Aalst。 发表 / 版本时间： 2020预印本；2021期刊。

来源状态： 2021期刊论文；同时提供2020预印本。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1016/j.is.2021.101810。

- 核查定位： 不确定活动/时间/存在性表示、behavior net和alignment上下界； §6合成实验及复杂度讨论
- 直接支持的范围： 显式不确定事件集合可产生相容Trace的符合性成本上下界，但可能组合数迅速增长。
- 成立条件： 不确定活动、时间和存在性范围已明确编码，Conformance模型与代价函数已给定。
- 重要限制： 结果依赖输入的不确定性范围；界限不是状态概率，也不覆盖未建模的漏采；未本地复现。
- 在本库的作用： 保留不确定性的替代路线与组合复杂度反例。

S-OT32 - Runtime Verification for LTL and TLTL

作者 / 机构： Andreas Bauer；Martin Leucker；Christian Schallhart。 发表 / 版本时间： 2011。

来源状态： ACM TOSEM 2011学术论文；作者稿。 证据类型： K/M。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1145/2000799.2000800。

- 核查定位： 作者稿§1.1-1.3及§2 LTL3，PDF前7页；最终出版元数据由作者机构核对
- 直接支持的范围： LTL3对有限前缀依据所有未来延伸给出true、false或inconclusive。
- 成立条件： 监测已知命题构成的执行前缀和显式LTL/TLTL属性；未知未来与过去漏采不能混同。
- 重要限制： 未见未来不等于过去漏采；验证选定运行的显式属性不等于证明整体任务正确。
- 在本库的作用： 三值运行时监测、有限前缀和重复观察状态的边界。

S-OT33 - 16.30/31 Feedback Control Systems, Topic 9: State-space model features

作者 / 机构： MIT OpenCourseWare, Department of Aeronautics and Astronautics。 发表 / 版本时间： 2010。

来源状态： MIT OpenCourseWare原始课程讲义，2010。 证据类型： K。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： 2010-09-30讲义，第9-6至9-10页：LTI定义、不可观测方向与rank测试推导
- 直接支持的范围： 已知LTI模型中可观测性等价于由C、CA至CA^(n-1)组成矩阵的秩为状态维数。
- 成立条件： 已知有限维LTI状态模型和无噪声输入/输出观察；秩条件不覆盖任意未知或非线性系统。
- 重要限制： 高校原始授课材料，不是Kalman首次提出理论的论文；前提不适用于任意未知非线性Agent。
- 在本库的作用： 本轮实际读到的可观测性关键定理与前提。

8.3 证据解释与评价

S-GE01 - PROV-DM: The PROV Data Model

作者 / 机构： Luc Moreau and Paolo Missier (eds.); W3C。 发表 / 版本时间： 2013。

来源状态： W3C Recommendation，2013-04-30。 证据类型： K/P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： §1、§2.1.2 Derivation、§5；§2 为解释性章节，§5 为规范性核心
- 直接支持的范围： 定义 Entity、Activity、Agent 及使用、生成、衍生、责任等关系；§2.1.2 说明使用 A 并生成 B 不是 B 衍生于 A 的充分条件。
- 成立条件： 在 PROV-DM 2013 Recommendation 的实体、活动和责任语义下，参与者已建立明确的对象身份与关系声明。
- 重要限制： PROV 表达来源关系，不验证来源内容真实、采集完整或真实因果影响；本次未执行任何规范一致性测试。
- 在本库的作用： 证据沿革和来源责任的规范基础；C-03-002

S-GE02 - Towards Faithfully Interpretable NLP Systems: How Should We Define and Evaluate Faithfulness?

作者 / 机构： Alon Jacovi; Yoav Goldberg。 发表 / 版本时间： 2020。

来源状态： ACL 2020 同行评审论文。 证据类型： K/M。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.18653/v1/2020.acl-main.386。

- 核查定位： §2 定义、后续评价假设与建议；已读有关论证正文
- 直接支持的范围： 区分对人有说服力的 plausibility 与反映预测过程的 faithfulness，审查以主观判断替代机制验证的逻辑。
- 成立条件： 讨论 NLP 模型解释的概念与评价假设；faithfulness 指解释相对于真实预测过程的关系，plausibility 指对人的合理性。
- 重要限制： 概念性立场论文，不是通用忠实性验证器，也不表示人类不能判断外部证据是否支持某句话。
- 在本库的作用： 解释研究的概念边界；C-03-001

S-GE03 - Measuring Attribution in Natural Language Generation Models

作者 / 机构： Hannah Rashkin; Vitaly Nikolaev; Matthew Lamm; Lora Aroyo; Michael Collins; Dipanjan Das; Slav Petrov; Gaurav Singh Tomar; Iulia Turc; David Reitter。 发表 / 版本时间： 2023。

来源状态： Computational Linguistics 49(4):777-840，同行评审。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1162/coli_a_00486。

- 核查定位： §3.3 AIS、 §4 两阶段标注、相关实验及标注附录；64 页 PDF 相关部分，非逐页通读
- 直接支持的范围： AIS 对带语言和时间上下文的陈述先判断可解释性，再检查是否可归于给定来源；在会话问答、摘要、表格生成任务中检验标注可操作性。
- 成立条件： 给定独立来源、生成陈述及其语言和时间上下文，按 AIS 两阶段指南评价；实证覆盖会话问答、摘要和表格到文本。
- 重要限制： 给定来源的支持不等于来源真实；人工指南本身不保证跨域标注一致性，未在 Yukio 日志任务上验证。
- 在本库的作用： 主张与证据支持、语境与时间条件的核心框架

S-GE04 - Language Models Don’ t Always Say What They Think: Unfaithful Explanations in Chain-of-Thought Prompting

作者 / 机构： Miles Turpin; Julian Michael; Ethan Perez; Samuel R. Bowman。 发表 / 版本时间： 2023。

来源状态： NeurIPS 2023 同行评审论文。 证据类型： E/M。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： §2 干预设计、 §3 偏置实验、结果及限制；会议 PDF
- 直接支持的范围： 在被测 2023 年模型与多选任务中，选项顺序和提示性答案影响输出，而理由经常不报告这种影响。

- 成立条件： 在作者选定的 2023 年语言模型和多选基准中，通过选项顺序、提示性答案等受控偏置观察回答与理由的变化。
- 重要限制： 实验是特定偏置、模型和任务的反例；不证明全部 CoT 都不忠实，不直接测量外部观察器准确率。
- 在本库的作用： Agent 自述不能自动充当内部机制真值的实证反例

S-GE05 - Measuring Faithfulness in Chain-of-Thought Reasoning

作者 / 机构： Tamera Lanham et al.; Anthropic。 发表 / 版本时间： 2023。

来源状态： 2023 年学术预印本。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.48550/arXiv.2307.13702。

- 核查定位： §2 截断、插错、改写与填充等干预；相关任务结果与局限；PDF
- 直接支持的范围： 用对 CoT 的干预检查答案对可见推理的依赖，结果随任务和模型改变；作者明确单项测试不能决定性证明忠实性。
- 成立条件： 以作者模型在受控多选任务上的 CoT 为对象，分别施加截断、插错、改写和填充等干预并比较最终答案。
- 重要限制： 主要为受控多选任务和作者模型；干预方法排除某些失效方式，不直接恢复完整内部计算。
- 在本库的作用： 机制忠实性检验方法及识别条件

S-GE06 - Chain-of-Thought Unfaithfulness as Disguised Accuracy

作者 / 机构： Oliver Bentham; Nathan Stringham; Ana Marasović。 发表 / 版本时间： 2024。

来源状态： TMLR 2024；核查 arXiv v3 及其 accepted/camera-ready 元数据。 证据类型： E/M。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.48550/arXiv.2402.14897。

- 核查定位： 忠实性度量定义与 Normalized Lanham Unfaithfulness；多模型家族实验、结果讨论；v3
- 直接支持的范围： 部分不忠实性指标混入选项偏好和准确率因素；通过归一化与复查实验挑战简单的尺度解释。
- 成立条件： 在选定模型家族与多选任务上重算 CoT 不忠实性度量，并控制或归一化选项偏好及比较准确率关联；核查版本 v3。
- 重要限制： 针对被研究度量与模型家族，不证明所有 CoT 忠实或无用；不应将指标相关关系当作普遍因果规律。
- 在本库的作用： 对忠实性研究自身测量效度的反证与审查

S-GE07 - Enabling Large Language Models to Generate Text with Citations

作者 / 机构： Tianyu Gao; Howard Yen; Jiatong Yu; Danqi Chen。 发表 / 版本时间： 2023。

来源状态： EMNLP 2023 同行评审论文。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.18653/v1/2023.emnlp-main.398。

- 核查定位： §3.3 引用评价、相应实验与 Appendix E 评价误差；ALCE
- 直接支持的范围： 区分输出质量与引用支持；citation recall 针对已经生成的陈述，citation precision 检查引用支持相关性，并处理合并引用。

- 成立条件： 在 ALCE 的问答生成及检索文档条件下，对输出陈述与其引用集合进行蕴含判断，并与相应人工标注比较。
- 重要限制： citation recall 不是所有重要任务事实的覆盖率；自动蕴含判别有误差，不要求最小引用集，未验证 Agent 日志迁移。
- 在本库的作用： 引用正确性、覆盖率和内容评价的主要方法；C-03-004

S-GE08 - FActScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation

作者 / 机构： Sewon Min; Kalpesh Krishna; Xinxi Lyu; Mike Lewis; Wen-tau Yih; Pang Wei Koh; Mohit Iyyer; Luke Zettlemoyer; Hannaneh Hajishirzi。 发表 / 版本时间： 2023。

来源状态： EMNLP 2023 同行评审论文。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.18653/v1/2023.emnlp-main.741。

- 核查定位： §2 原子事实、§4.2 ER 定义、Appendix B.2 个体与系统级评价；限制和小规模跨内容探索
- 直接支持的范围： 以可支持原子事实比例量度长文本事实精确度；ER 衡量系统总体分数估计误差；总体误差与单条判断质量可以给出不同排序。
- 成立条件： 主实验为人物传记生成、Wikipedia 支持与人工原子事实标注；系统总体 ER 与单条事实判别指标分别计算。
- 重要限制： 摘要小于 2% error 不是每个事实低于 2% 错误；主实验为人物传记/Wikipedia，事实精确度未覆盖全部遗漏或整体关系错误。
- 在本库的作用： 事实分解、逐项支持及汇总指标误读的核心案例；C-03-005

S-GE09 - RAGAs: Automated Evaluation of Retrieval Augmented Generation

作者 / 机构： Shahul Es; Jithin James; Luis Espinosa Anke; Steven Schockaert。 发表 / 版本时间： 2024。

来源状态： EACL 2024 System Demonstrations 同行评审论文。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.18653/v1/2024.eacl-demo.16。

- 核查定位： Faithfulness、Answer Relevance、Context Relevance 定义；WikiEval 实验及结果
- 直接支持的范围： 提出不需要人工参考答案的 RAG 自动评价路线，并在人类评价的 WikiEval 条件下比较指标。
- 成立条件： 以问题、检索上下文和生成答案为输入，使用原论文指定模型评价流程，在 WikiEval 及其人工对比标签上检验。
- 重要限制： Reference-free 不意味着不需要证据、人工元评价或模型判断；原论文任务与采样规模不覆盖开放 Agent 活动解释。
- 在本库的作用： 公开 RAG 评估工具的代表性研究，不作通用正确性保证

S-GE10 - ARES: An Automated Evaluation Framework for Retrieval-Augmented Generation Systems

作者 / 机构： Jon Saad-Falcon; Omar Khattab; Christopher Potts; Matei Zaharia。 发表 / 版本时间： 2024。

来源状态： NAACL 2024 同行评审论文。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.18653/v1/2024.naacl-long.20。

- 核查定位： 合成训练数据、专门评判器和 PPI 流程；输入要求；KILT/SuperGLUE/AIS 实验
- 直接支持的范围： 用领域材料和合成数据训练评价器，再用人工标注校正总体评价；实验涵盖多项知识密集任务和指定分布变化。
- 成立条件： 拥有领域材料、少量示例与人工标注验证集，生成合成训练数据并训练专用 judge；实验限于指定 KILT、SuperGLUE 和 AIS 任务。
- 重要限制： 仍需人工标注、明确抽样及数据条件；域迁移实验不证明任意客户端、日志形式或事实类型下均可靠。
- 在本库的作用： 评判器训练、人工校准与总体统计推断的路线

S-GE11 - The FACTS Grounding Leaderboard: Benchmarking LLMs' Ability to Ground Responses to Long-Form Input

作者 / 机构： Alon Jacovi et al.; Google DeepMind, Google Research and Google Cloud。 发表 / 版本时间： 2025。

来源状态： 2025 年技术预印本；v1。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.48550/arXiv.2501.03200。

- 核查定位： v1；评价 eligibility 与 grounding 的两步流程、模型评判器与聚合、相关结果
- 直接支持的范围： 在给定长文档下同时检查是否实质回应请求和是否得到上下文支持，避免空泛回答只凭少出错得高分。
- 成立条件： 核查 2025 年 v1：模型收到给定长文档和生成请求，按 eligibility 与 grounding 两阶段、指定多模型 judge 流程评分。
- 重要限制： 给定上下文不是世界真值；多评判器不能保证独立或无偏；本条仅指 v1，不混用后续 suite 分数。
- 在本库的作用： 回应充分性与 grounding 共同评价；版本化基准案例

S-GE12 - AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents

作者 / 机构： Edoardo Debenedetti; Jie Zhang; Mislav Balunović; Luca Beurer-Kellner; Marc Fischer; Florian Tramèr。 发表 / 版本时间： 2024。

来源状态： NeurIPS 2024 Datasets and Benchmarks 同行评审论文。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： §3 环境、任务判定、效用和攻击成功；关于 LLM 评价器被注入的说明
- 直接支持的范围： 提供针对外部工具数据注入的任务环境，分别检查用户任务效用和攻击目标；程序化状态判定降低纯文本裁判依赖。
- 成立条件： 在 AgentDojo 受控工具环境、预定义用户目标与攻击目标下，通过环境状态及程序判据分别评估效用和注入成功。
- 重要限制： 受控攻击与任务集合不覆盖所有攻击；迁移到外部活动观察器的风险是本研究推论，未证明 Yukio 存在该漏洞。
- 在本库的作用： 观察证据中的间接指令和评判器威胁模型

S-GE13 - SWE-bench: Can Language Models Resolve Real-World GitHub Issues?

作者 / 机构： Carlos E. Jimenez; John Yang; Alexander Wettig; Shunyu Yao; Kexin Pei; Ofir Press; Karthik Narasimhan。 发表 / 版本时间： 2024。

来源状态： ICLR 2024 同行评审论文。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： 任务构造、§2 代码快照和测试评价、结果及附录任务字段；51 页 PDF 相关部分
- 直接支持的范围： 从真实 Python 项目问题、代码快照和补丁构造任务，以测试套件检验生成的代码修改。
- 成立条件： 对基准收集的 Python 仓库问题，在指定代码快照上生成补丁，并用对应测试套件评价修复与既有行为。
- 重要限制： 测试通过是特定测试语义下的目标达成；原基准不提供观察器采集完整性、在线未知状态或解释证据链接的全套真值。
- 在本库的作用： Actor evaluation 与 Observer evaluation 的边界案例

S-GE14 - AgentBench: Evaluating LLMs as Agents

作者 / 机构： Xiao Liu et al.。 发表 / 版本时间： 2024。

来源状态： ICLR 2024 同行评审论文；本轮仅摘要核查。 证据类型： M/E。 核查深度： A1。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： ICLR 官方摘要；PDF 请求因约 23 MB 大小限制未获得全文
- 直接支持的范围： 官方摘要确认其评价多种交互环境下 LLM 作为 Agent 的能力与结果，足以用于定位其评价对象。
- 成立条件： 仅依 ICLR 2024 官方摘要确定其多种交互环境的 Agent 能力评价范围；本条不承载需要全文支持的实验结论。
- 重要限制： 本次未核查实验细节、全部结果或附录，不据此陈述精确性能、因果解释或 Observer 指标。
- 在本库的作用： Actor benchmark 代表性资料与明确的全文续查项

S-GE15 - τ-bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains

作者 / 机构： Shunyu Yao; Noah Shinn; Pedram Razavi; Karthik Narasimhan。 发表 / 版本时间： 2024。

来源状态： 2024 年预印本 v1。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.48550/arXiv.2406.12045。

- 核查定位： 交互任务环境、最终状态判定、pass^k 与 pass@k 定义；v1
- 直接支持的范围： 通过重复交互评估可靠性，pass^k 要求多次均成功，区别于 pass@k 至少一次成功；给出基于重复样本的估计。
- 成立条件： 在指定业务工具、策略约束和模型模拟用户环境中重复运行同一任务，以最终数据库状态判定，并按所述重复试验规则估计 pass^k。
- 重要限制： 模拟用户、有限业务域和指定策略；重复结果依赖采样条件，不能自动当成观察器状态真值或跨域稳定性证明。

- 在本库的作用： 重复执行可靠性与聚合评价单位的案例

S-GE16 - Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena

作者 / 机构： Lianmin Zheng et al.。 发表 / 版本时间： 2023。

来源状态： NeurIPS 2023 Datasets and Benchmarks 同行评审论文。 证据类型： E/M。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： §3.3 位置、冗长、自我偏好和推理局限；人工偏好一致性实验
- 直接支持的范围： 在其模型、响应对和协议下发现位置和冗长等偏差，比较模型与人工偏好；原文对 self-enhancement 明确保留样本不足的不确定性。
- 成立条件： 使用 MT-Bench 与 Chatbot Arena 的指定模型输出、人类偏好标签和提示协议；偏差分析对应其构造的响应对与顺序变换。
- 重要限制： 人工偏好一致不等于事实正确；不应把所有候选偏差写成已确证，更不能外推所有 2026 年评判器。
- 在本库的作用： LLM judge 偏差、适用范围与误引审查；C-07-005

S-GE17 - G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment

作者 / 机构： Yang Liu; Dan Iter; Yichong Xu; Shuohang Wang; Ruochen Xu; Chenguang Zhu。 发表 / 版本时间： 2023。

来源状态： EMNLP 2023 同行评审论文。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.18653/v1/2023.emnlp-main.153。

- 核查定位： §2 CoT 和表单评分、token 概率加权； §3 摘要与对话实验、消融和局限
- 直接支持的范围： 将明确评价准则和生成步骤结合为评分流程，在指定摘要和对话数据集上提高与人工评价的相关性。
- 成立条件： 在 SummEval、Topical-Chat 和 QAGS 的摘要/对话任务中，使用原论文 GPT 系列版本、rubric、CoT 和概率加权评分流程。
- 重要限制： 相关性不是每条判断正确率；评分模型、提示、相关系数和数据集影响结论，作者讨论对模型生成文本的偏好风险。
- 在本库的作用： 有条件的模型评判改进方法及元评价范式

S-GE18 - JudgeBench: A Benchmark for Evaluating LLM-Based Judges

作者 / 机构： Sijun Tan; Siyuan Zhuang; Kyle Montgomery; William Y. Tang; Alejandro Cuadron; Chenguang Wang; Raluca Ada Popa; Ion Stoica。 发表 / 版本时间： 2025。

来源状态： ICLR 2025 同行评审论文。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： 构造正确/错误响应对的流程； §4 评判结果、正确性任务和限制
- 直接支持的范围： 用有客观答案的困难响应对检验 judge 对正确性的区分，展示难例中的表现不同于普通偏好评价。

- 成立条件： 从具有可验证答案的问题中构造同题正确/错误困难响应对，覆盖知识、推理、数学和代码等指定任务，并比较所选 judges。
- 重要限制： 从可生成正确与错误答案的问题中筛选难例，难度分布经构造；低分不能直接估计自然 Agent 轨迹错误率。
- 在本库的作用： 用客观正确性挑战评判器的基准

S-GE19 - Does Context Matter? ContextualJudgeBench for Evaluating LLM-based Judges in Contextual Settings

作者 / 机构： Austin Xu; Srijan Bansal; Yifei Ming; Semih Yavuz; Shafiq Joty。 发表 / 版本时间： 2025。

来源状态： ACL 2025 同行评审论文。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.18653/v1/2025.acl-long.470。

- 核查定位： 八类上下文判定、数据构造、顺序交换一致准确率、结果与附录分析
- 直接支持的范围： 在支持性、完整性、简洁度、拒答等上下文任务检查 judge；一致准确率要求两种顺序都正确，其随机基线为 25%。
- 成立条件： 在八类给定上下文评价任务与构造响应对上比较 judges；consistent accuracy 要求交换两种答案顺序后均判断正确。
- 重要限制： 不是普通二选一准确率的 50% 基线；部分分析依赖模型元评判，长度关联并非充分因果证明；任务分布有限。
- 在本库的作用： 上下文敏感评价和指标基线审查

S-GE20 - On Calibration of Modern Neural Networks

作者 / 机构： Chuan Guo; Geoff Pleiss; Yu Sun; Kilian Q. Weinberger。 发表 / 版本时间： 2017。

来源状态： ICML 2017 同行评审论文。 证据类型： K/M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： §2 校准定义、可靠性图/ECE、temperature scaling 与实验
- 直接支持的范围： 正式区分预测置信与实际正确频率，并在被测分类器上比较校准方法。
- 成立条件： 对有确定参考标签的分类预测与独立校准数据研究置信度和经验正确频率；temperature scaling 参数在指定校准集拟合。
- 重要限制： 原实验为确定标签的分类问题；不保证 LLM 自述百分比经过校准，也不保证分布变化后的校准。
- 在本库的作用： Observer 概率评价的基础定义；C-07-004

S-GE21 - SelectiveNet: A Deep Neural Network with an Integrated Reject Option

作者 / 机构： Yonatan Geifman; Ran El-Yaniv。 发表 / 版本时间： 2019。

来源状态： ICML 2019 同行评审论文。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： 选择性风险与覆盖率定义、训练/校准过程、实验表 1

- 直接支持的范围： 将预测与拒答选择联合训练，明确以 coverage 和 conditional risk 一起比较有拒答能力的模型。
- 成立条件： 在给定监督学习任务与数据分布下联合学习预测器和选择函数，并在验证/测试样本上衡量选择性风险及覆盖率。
- 重要限制： 训练目标覆盖率与真实测试覆盖率不同；被测任务和分布有界，不证明任意日志状态上的拒答保证。
- 在本库的作用： 未知、拒答与信息价值的评价路线

S-GE22 - Jepsen - Design Overview and official README

作者 / 机构： Jepsen project; Kyle Kingsbury et al.。 发表 / 版本时间： 2026。

来源状态： 持续维护的开源工程资料；2026-10-17 核查。 证据类型： P。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： 官方 README Design Overview：history、generator、nemesis、checker 及示例；动态页面快照
- 直接支持的范围： 工程测试组织客户端操作历史、故障注入与基于模型的检查，适合解释故障实验怎样获得可审查判据。
- 成立条件： 能够定义操作历史、系统预期模型和 checker，并控制客户端操作与 nemesis 故障；本轮读取的是官方设计说明。
- 重要限制： 本次只读官方实现说明，未运行；需明确系统模型和控制能力，不能直接获得 Agent 语义完成的 oracle。
- 在本库的作用： 分布式故障注入和历史检查的成熟工程实践

S-GE23 - FoundationDB: A Distributed Unbundled Transactional Key Value Store

作者 / 机构： Jingyu Zhou et al.。 发表 / 版本时间： 2021。

来源状态： SIGMOD 2021 同行评审系统论文；官方作者 PDF。 证据类型： P/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： §4 模拟环境、§6.2 测试与故障；确定性执行及无法覆盖的情况
- 直接支持的范围： 展示确定性模拟、故障与 buggification 在实际数据库开发中的作用，同时说明性能、第三方组件及非受控代码等覆盖边界。
- 成立条件： FoundationDB 使用可控制调度、随机性和虚拟 I/O 的模拟实现，并以其数据库不变量、故障模型和真实工程环境评价。
- 重要限制： 数据库系统自身工程报告；模拟覆盖依赖模型和可控制边界，不证明 Agent 外部环境或自然语言判断均可确定性重放。
- 在本库的作用： 可复现故障研究与 simulation-to-reality 边界

S-GE24 - Prediction-Powered Inference

作者 / 机构： Anastasios N. Angelopoulos; Stephen Bates; Clara Fannjiang; Michael I. Jordan; Tijana Zrnic。 发表 / 版本时间： 2023。

来源状态： Science 382:669-674，2023；核查作者 arXiv 全文。 证据类型： K/M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1126/science.adi6000。

- 核查定位： §2 带标签校正、总体参数推断、相应定理和 Appendix B 有限总体条件；作者全文 v4
- 直接支持的范围： 在抽样与独立性等条件下，将少量标签和大量预测结合以估计总体参数并构造区间；有效推断与单个模型预测正确性不同。
- 成立条件： 总体参数、标注样本与未标注样本的抽样方式满足相应定理条件，预测器符合所述独立性要求，并用真实标签构造校正项。
- 重要限制： 需满足其统计设定；任意便利样本、相关标签或未知选择偏差不自动受原保证覆盖；不会把每条模型判断转为真值。
- 在本库的作用： 人工校正的总体评价理论，补充 ARES

S-GE25 - Inter-Coder Agreement for Computational Linguistics

作者 / 机构： Ron Artstein; Massimo Poesio。 发表 / 版本时间： 2008。

来源状态： Computational Linguistics 34(4):555-596，同行评审综述。 证据类型： K。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1162/coli.07-034-R2。

- 核查定位： §2.1 agreement、reliability 与 validity；系数假设与分布影响讨论
- 直接支持的范围： 系统讨论标注一致性度量的假设，指出多个标注者可能一致但共同偏离目标构念。
- 成立条件： 对明确标注单位、类别或距离定义及多个标注者的重复判断，选择与任务及标签分布相符的一致性系数。
- 重要限制： 不存在脱离类别分布、任务和系数假设的万能阈值；高一致性不等于事实正确或构念有效。
- 在本库的作用： Ground truth 标注质量与共同偏差的基础

S-GE26 - Evaluating Explainable AI: Which Algorithmic Explanations Help Users Predict Model Behavior?

作者 / 机构： Peter Hase; Mohit Bansal。 发表 / 版本时间： 2020。

来源状态： ACL 2020 同行评审论文。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.18653/v1/2020.acl-main.491。

- 核查定位： 行为预测实验、文本/表格任务、 §5.3 主观评分与客观表现；结果与限制
- 直接支持的范围： 比较解释对行为预测的帮助；主观评分未显示可靠预测客观表现的证据，有效性随方法与任务改变。
- 成立条件： 在论文设计的文本/表格分类模型行为预测任务中比较解释方法，同时收集主观评价；参与者与实验流程由其研究设定。
- 重要限制： 作者不将不显著关系视为不存在任何关系；被测分类任务不是桌面 Agent 用户理解的直接实测。
- 在本库的作用： 理解度与喜欢程度分开测量的实验参照

S-GE27 - Precision and Recall for Time Series

作者 / 机构： Nesime Tatbul; Tae Jun Lee; Stan Zdonik; Mejbah Alam; Justin Gottschlich。 发表 / 版本时间： 2018。

来源状态： NeurIPS 2018 同行评审论文；作者 PDF。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： §4 区间存在、大小、位置与基数奖励，相关例子及实验
- 直接支持的范围： 提出面对时间区间事件时可调的 precision/recall 定义，显示逐点计分不能表达所有应用关注。
- 成立条件： 真值与预测表示为时间区间，预先确定存在、覆盖位置、区间长度和碎片化等奖励权重，再计算区间级 precision/recall。
- 重要限制： 不同权重对应不同目标，不存在无条件最优口径；异常区间方法需要重定义后才能用于 Agent 状态区间。
- 在本库的作用： 事件区间匹配、迟报与重复报警度量的参照

S-GE28 - Datasheets for Datasets

作者 / 机构： Timnit Gebru; Jamie Morgenstern; Briana Vecchione; Jennifer Wortman Vaughan; Hanna Wallach; Hal Daumé III; Kate Crawford。 发表 / 版本时间： 2021。

来源状态： Communications of the ACM 64(12):86-92，2021；初版预印本 2018。 证据类型： M/P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1145/3458723。

- 核查定位： §3 关于动机、采集、组成、处理、用途、分发和维护的问题；核查 arXiv PDF 及 Microsoft 正式发表元数据
- 直接支持的范围： 提供使数据来源、采样、采集机制和已知限制可审阅的文档框架。
- 成立条件： 数据创建者或维护者能说明数据动机、组成、采样、采集、处理、用途与维护过程，并回答与数据生命周期相关的问题。
- 重要限制： 文档化不证明数据无偏或标签正确；预印本与 2021 年 CACM 排版及内容细节需要区分。
- 在本库的作用： 长期可复用 Observer 数据集资料说明

S-GE29 - Merging Facts, Crafting Fallacies: Evaluating the Contradictory Nature of Aggregated Factual Claims in Long-Form Generations

作者 / 机构： Cheng-Han Chiang; Hung-yi Lee。 发表 / 版本时间： 2024。

来源状态： Findings of ACL 2024 同行评审论文。 证据类型： E/M。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.18653/v1/2024.findings-acl.160。

- 核查定位： 同名人物拼接案例、D-FActScore、相关实验和限制
- 直接支持的范围： 展示逐条可支持事实组合后仍可能构成错误单一主体叙述，并提出专门检测此类问题的方法。

- 成立条件： 主要在人物传记与 Wikipedia 证据条件下考察同名实体的事实聚合，并用其提出的 D-FActScore 评价相应矛盾。
- 重要限制： 主要人物传记/Wikipedia 场景；向多个 run、调用和文件身份拼接的迁移是本研究类比，未被该论文直接验证。
- 在本库的作用： 原子事实精确度不足以验证整体一致性的反证

S-GE30 - FEVER: a Large-scale Dataset for Fact Extraction and VERification

作者 / 机构： James Thorne; Andreas Vlachos; Christos Christodoulopoulos; Arpit Mittal。 发表 / 版本时间： 2018。

来源状态： NAACL 2018 同行评审论文。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.18653/v1/N18-1074。

- 核查定位： 数据标注及 §5.2 支持/反驳/信息不足分类与证据评价
- 直接支持的范围： 将受支持、被反驳与信息不足分开，并为适用标签评价证据集合。
- 成立条件： 对 Wikipedia 派生的主张及证据集合，采用 Supported、Refuted、Not Enough Info 标签与基准指定检索/验证协议。
- 重要限制： Wikipedia 派生主张与构造流程限定任务；NEI 标签不等于现实为假，也不提供日志未知状态的直接性能。
- 在本库的作用： 三值证据关系和证据检索评价的任务范式

S-GE31 - Strictly Proper Scoring Rules, Prediction, and Estimation

作者 / 机构： Tilmann Gneiting; Adrian E. Raftery。 发表 / 版本时间： 2007。

来源状态： Journal of the American Statistical Association 102(477):359-378，2007。 证据类型： K。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1198/016214506000001437。

- 核查定位： Proper scoring rule 理论定义、二次与对数评分及概率预测讨论；作者全文相关部分
- 直接支持的范围： 给出在期望评分下鼓励真实概率报告的规则理论，为 Brier/log score 的解释提供依据。
- 成立条件： 明确预测分布、结果空间和评分方向，在真实结果分布下取期望；严格适当性是该数学设定下的最优报告性质。
- 重要限制： 理论需明确预测对象、结果空间与真值；优良概率评分不单独证明某一次状态或解释正确。
- 在本库的作用： 概率评价、校准与准确率分离的理论基础

S-GE32 - The Hitchhiker’s Guide to Testing Statistical Significance in Natural Language Processing

作者 / 机构： Rotem Dror; Gili Baumer; Segev Shlomov; Roi Reichart。 发表 / 版本时间： 2018。

来源状态： ACL 2018 同行评审论文。 证据类型： K/M。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.18653/v1/P18-1128。

- 核查定位： §3-4 测试选择、成对比较、重采样和代表性条件
- 直接支持的范围： 强调依据指标、数据配对和抽样条件选择统计检验，避免把一种检验机械用于所有 NLP 比较。

- 成立条件： 确定比较系统、评价指标、同一样本的配对结构和抽样假设后，选择适当的显著性检验或重采样方法。
- 重要限制： 按 task/run 聚类 bootstrap 是本研究针对轨迹相关性的综合建议，不冒称其专门研究 Agent；统计显著性不等于实际价值。
- 在本库的作用： 置信区间、配对比较与样本单位选择的基础

S-GE33 - AgentTelemetry: A Fault Detection Benchmark and Toolkit for LLM Agent Observability

作者 / 机构： Krishna Chaitanya Balusu。 发表 / 版本时间： 2026。

来源状态： AIware 2026 Benchmark and Dataset Track，pp.380-387，2026-07-05；仅摘要级实质核查。 证据类型： M/E。 核查深度： A1。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1145/3805760.3814931。

- 核查定位： AIware 2026 官方页面摘要和出版元数据；OpenReview 与 ACM 全文遭访问挑战，未获得论文正文
- 直接支持的范围： 确认存在面向 Agent 观察故障的已发表工作；摘要清楚区分结构上界、mock-seeded 配置和有限真实运行，并报告干预 p=.53。
- 成立条件： 仅摘要级核查 AIware 2026 条件：14 类故障、5 种观察条件、7 个框架及 6 个 mock-LLM seeds；真实运行与小规模干预另列。
- 重要限制： 2,940 配置不是六个真实模型；FDR=1 是结构上界。循环标签按耗尽迭代预算定义。无法全文核查标注、独立性、完整方法或复现；不得宣称显著实效。
- 在本库的作用： 直接 Observer benchmark 的前沿线索及防止过读的案例；C-07-007

S-GE34 - AgentTelemetry - repository README, benchmark and Inspect evaluator descriptions

作者 / 机构： Krishna Chaitanya Balusu; AgentTelemetry project。 发表 / 版本时间： 2026。

来源状态： 动态开源仓库快照，2026-10-17。 证据类型： P/M。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： 2026-10-17 README：Benchmark Results (MDE Intelligence 2026)、Inspect Evaluator、span coverage、HallucinationTracer；未执行源码
- 直接支持的范围： 当前仓库分别列出真实检测器、conformance-complete 上界、FDR/FPR 和可检测分母；展示实际输出语义比单一概览数字复杂。
- 成立条件： 核查 2026-10-17 当前 README 的 MDE Intelligence 2026 配置和 Inspect 评价说明；区分实际 adapter、完整符合性上界及可检测分母。
- 重要限制： 当前 3,780-row 配置与 AIware 摘要 2,940 配置不同，不能混用；README 是作者报告而非独立复现。词重叠启发式不等于语义忠实证明；未固定 commit。
- 在本库的作用： 版本漂移、检测分母与构造上界的工程核查；补充 S-GE33

S-GE35 - FACTS Benchmark Suite: a new way to systematically evaluate LLMs factuality

作者 / 机构： Google DeepMind。 发表 / 版本时间： 2025。

来源状态： 官方工程/研究发布，2025-12-09。 证据类型： P/M。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： 2025-12-09 官方介绍；Benchmark overview、Grounding v2 与 suite 的不同子基准
- 直接支持的范围： 官方资料确认 suite 区分 Grounding、Parametric、Search、Multimodal 维度，Grounding 已标为 v2。
- 成立条件： 核查 2025-12-09 官方 suite 介绍中的 Grounding v2、Parametric、Search 和 Multimodal 范围；不复用其排行榜数字作性能推断。
- 重要限制： 官方发布说明不是独立验证；本研究只据此确认范围与版本变化，不使用模型排行榜得出因果或项目性能结论。
- 在本库的作用： 基准口径与版本化维护的当时资料

8.4 人类理解与介入

S-HI01 - Toward a Theory of Situation Awareness in Dynamic Systems

作者 / 机构： Mica R. Endsley。 发表 / 版本时间： 1995。

来源状态： Human Factors 1995理论论文。 证据类型： K/M/H。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口；本轮原文入口；DOI 10.1518/001872095779049543。

- 核查定位： 原论文相关正文：三层 SA 定义，心理模型与目标机制；作者上传 PDF 第 5、11-13、26 页（浏览器零基页码可能差 1）。
- 直接支持的范围： C-04-001：感知、理解、预测是有区别的分析层次。；C-04-002：心理模型参与解释当前情境；原文部分机制明确作为假设提出。
- 成立条件： 动态系统中有任务目标的操作者；三层 SA 是理论分解，具体认知机制需按原文假设区别。
- 重要限制： 理论框架综合多个动态控制领域；不是桌面 Agent 用户实验。；未逐页核验全部所引原始实验，不能把框架的全部预测归为已确证规律。
- 在本库的作用： 04 理论入口；区分信息可见性、当前情境认知与系统心理模型。

S-HI02 - Trust in Automation: Designing for Appropriate Reliance

作者 / 机构： John D. Lee；Katrina A. See。 发表 / 版本时间： 2004。

来源状态： Human Factors 2004综述/理论论文；摘要级核查。 证据类型： K/M。 核查深度： A1。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1518/hfes.46.1.50_30392。

- 核查定位： PubMed/出版方原摘要与元数据；Iowa 作者 PDF 和 SAGE 全文获取失败。
- 直接支持的范围： C-04-003：信任研究的目标涉及适当依赖，情境、自动化特征与认知过程均相关。
- 成立条件： 复杂或非预期情境下人与自动化的信任/依赖研究；本轮仅核原摘要。
- 重要限制： 本轮未取得可核查全文；不宣称完整核实文中全部分类、量表或因果机制。；正文的信任/依赖/能力操作性区分还借助本轮原始实验和研究者综合，不靠此摘要单独证明。
- 在本库的作用： 经典信任综述入口；优先补全文。

S-HI03 - Guidelines for Human-AI Interaction

作者 / 机构： Saleema Amershi；Dan Weld；Mihaela Vorvoreanu；Adam Fourney；Besmira Nushi；Penny Collisson；Jina Suh；Shamsi Iqbal；Paul N. Bennett；Kori Inkpen；Jaime Teevan；Ruth Kikin-Gil；Eric Horvitz。 发表 / 版本时间： 2019。

来源状态： CHI 2019学术论文。 证据类型： M/E/P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1145/3290605.3300233。

- 核查定位： 表 1；四阶段生成与验证方法；修改后的 heuristic evaluation 方法与局限。
- 直接支持的范围： C-04-004：18 条指南覆盖初始交互、使用中、错误时、长期变化。；49 名 HCI 从业者、20 个产品主要验证指南的适用性和清晰度。
- 成立条件： 49 名 HCI 从业者对 20 个 AI 产品评估指南的清晰度和适用性，属于修改后的启发式评估。
- 重要限制： 不是遵循指南后用户理解或安全收益的随机对照实验。；一般 HAI 指南不直接证明第三方 Agent 观察界面的效果。
- 在本库的作用： 连接能力表达、错误恢复与控制的工程研究框架。

S-HI04 - Beyond Expertise and Roles: A Framework to Characterize the Stakeholders of Interpretable Machine Learning and their Needs

作者 / 机构： Harini Suresh；Steven R. Gomez；Kevin K. Nam；Arvind Satyanarayan。 发表 / 版本时间： 2021。

来源状态： CHI 2021学术论文。 证据类型： M。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1145/3411764.3445088。

- 核查定位： 知识类型×情境框架、目标/任务分类；58 篇论文描述性应用与 limitations。
- 直接支持的范围： C-04-005：知识背景与解释需求应分别描述，单一专家/普通用户标签不足。
- 成立条件： 解释性 ML 利益相关者研究框架；以 58 篇论文及研究实例展示描述、比较与生成作用。
- 重要限制： 框架的描述与生成效用不等于用该分类适配界面必然提高理解。
- 在本库的作用： 研究对象与解释任务的建模依据。

S-HI05 - Questioning the AI: Informing Design Practices for Explainable AI User Experiences

作者 / 机构： Q. Vera Liao；Daniel Gruen；Sarah Miller。 发表 / 版本时间： 2020。

来源状态： CHI 2020学术论文。 证据类型： E/M。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1145/3313831.3376590。

- 核查定位： 20 名 UX/设计从业者访谈方法；XAI question bank 与设计情境。
- 直接支持的范围： C-04-006：以用户问题组织解释需求，有助于区分 why、why-not、how、what-if 等目标。
- 成立条件： 20 名 UX/设计从业者的半结构化访谈，多个产品团队但同一企业语境。
- 重要限制： 参与者来自同一大企业多个团队；访谈结论不是界面对普通用户的因果效果。；问题库不是穷尽所有解释需求的标准。
- 在本库的作用： 将抽象 explainability 转为用户可回答的问题。

S-HI06 - Explanation in Artificial Intelligence: Insights from the Social Sciences

作者 / 机构： Tim Miller。 发表 / 版本时间： 2019。

来源状态： Artificial Intelligence 2019综述论文。 证据类型： K/M。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1016/j.artint.2018.07.007。

- 核查定位： 作者综述正文的 contrastive、selective、social explanation 讨论，尤其 why 问题与 foil 的条件。
- 直接支持的范围： C-04-006：解释常有对比、选择与交互性质；并非所有 why 问题都可简单归为对比问题。
- 成立条件： 对社会科学解释研究的跨学科综述；概念针对人的解释实践，非特定 Agent 原始实验。
- 重要限制： 这是跨学科综述，不是本文逐个所引心理学效应的独立重复。；交互上令人信服不能单独证明解释忠实于 Agent 内部原因。
- 在本库的作用： 解释的认知/社会性质；与 03 的证据忠实性形成互补。

S-HI07 - Manipulating and Measuring Model Interpretability

作者 / 机构： Forough Poursabzi-Sangdeh；Daniel G. Goldstein；Jake M. Hofman；Jennifer Wortman Vaughan；Hanna Wallach。 发表 / 版本时间： 2021。

来源状态： CHI 2021学术论文。 证据类型： E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1145/3411764.3445315。

- 核查定位： 预注册实验设计，N=3800；特征数量/透明度操纵，模拟模型预测与纠错结果；局限。
- 直接支持的范围： C-04-007：透明、较少特征可改善模拟预测，但不保证更好辨别或修正错误。
- 成立条件： N=3800，预注册公寓售价预测实验；操纵线性模型特征数量与透明程度。
- 重要限制： 公寓售价与线性模型的受控任务；不是多步 Agent 轨迹。；信息过载是作者解释之一，缺少直接过程测量，不能当已证实中介机制。
- 在本库的作用： 反驳透明度必然带来正确理解或适当依赖。

S-HI08 - To Trust or to Think: Cognitive Forcing Functions Can Reduce Overreliance on AI in AI-Assisted Decision-Making

作者 / 机构： Zana Buçinca；Maja Barbara Malaya；Krzysztof Z. Gajos。 发表 / 版本时间： 2021。

来源状态： PACM HCI / CSCW 2021学术论文。 证据类型： E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1145/3449287。

- 核查定位： 参与者筛选 N=199，营养选择任务、模拟 AI 错误、条件设计；表 1/2 与主观评价。
- 直接支持的范围： C-04-008：部分 cognitive forcing 条件降低某些过度依赖指标，但伴随偏好/认知成本权衡。
- 成立条件： N=199 保留参与者，营养选择任务与模拟 AI 错误；比较简单解释与多种促使独立思考的交互条件。
- 重要限制： 各指标不一致：错误碳水来源辨识与完整决策不能合并。；所有题目的整体效果并非均显著；不能称为消除过度依赖。
- 在本库的作用： 解释、独立判断与实际依赖的实验区分。

S-HI09 - The Eyes Have It: A Task by Data Type Taxonomy for Information Visualizations

作者 / 机构： Ben Shneiderman。 发表 / 版本时间： 1996。

来源状态： IEEE Visual Languages 1996学术论文。 证据类型： K/M。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1109/VL.1996.545307。

- 核查定位： 任务×数据类型分类；overview、zoom、filter、details-on-demand、relate、history、extract 定义。
- 直接支持的范围： C-04-009：可视化应与数据关系和用户检索任务匹配；总览与细节属于不同任务支持。
- 成立条件： 信息可视化的任务×数据类型概念框架；面向浏览、定位、关系与细节检索。
- 重要限制： 经典设计启发式；原文自己称为 starting point，并非 Agent 场景的效果定理。
- 在本库的作用： 可视化方法比较与渐进披露的基础。

S-HI10 - A Nested Model for Visualization Design and Validation

作者 / 机构： Tamara Munzner。 发表 / 版本时间： 2009。

来源状态： IEEE TVCG 2009学术论文。 证据类型： K/M。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1109/TVCG.2009.111。

- 核查定位： 四层设计/验证框架、上层错误向下游传播的论证。
- 直接支持的范围： C-04-009：领域问题、数据/任务抽象、视觉编码交互与算法性能是不同的验证层。
- 成立条件： 可视化设计/验证方法学；领域问题、数据/任务抽象、编码/交互、算法四层。
- 重要限制： 方法学框架；不直接给出时间线或任务树的普适优劣。
- 在本库的作用： 防止用漂亮图形和快速渲染替代问题有效性。

S-HI11 - AgentGUI: An Interface for Observing and Steering Long-Running AI Agents

作者 / 机构： Xuan Zhao；Jiwoong Sohn；Qinyue Zheng；Michael Moor。 发表 / 版本时间： 2026。

来源状态： arXiv v2；机构称EMNLP 2026接收，正式proceedings未独立核查。 证据类型： M/E/P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.48550/arXiv.2607.26300。

- 核查定位： v2，2026-08-04；N=8 轨迹问答研究，任务/基线/问题提示；drift mitigation 的任务定义与文件存在评分。
- 直接支持的范围： C-04-012：在小样本轨迹问答中，结构化界面帮助查找和理解特定执行信息。；C-06-015：drift 实验的完成分数只核对交付文件存在，不能视为通用偏题检测。
- 成立条件： N=8、两个任务四条 rollout 的定向问答界面研究；另有合成交付任务中按文件存在计分的 drift 实验。
- 重要限制： 仅两个任务、四条 rollout，问题有位置提示；基线及参与者构成影响外推。；使用可控 agent harness，不能证明被动观察现有客户端的相同能力。；机构公告称被 EMNLP 2026 接收；本轮未核查正式 proceedings，依据 arXiv v2。
- 在本库的作用： 直接相关的新型 Agent 观察界面及严格外推边界。

S-HI12 - Interactive Debugging and Steering of Multi-Agent AI Systems

作者 / 机构： Will Epperson；Gagan Bansal；Victor Dibia；Adam Fourney；Jack Gerrits；Erkang Zhu；Saleema Amershi。 发表 / 版本时间： 2025。

来源状态： CHI 2025学术论文。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1145/3706598.3713581。

- 核查定位： AGDebugger 两部分研究：6 人错误理解，8 人真实交互 steering；失败 GAIA 轨迹、给定错误摘要、成功修复结果。
- 直接支持的范围： C-04-013：交互式回溯/编辑有助于探索调试；感知有用和最终修复成功应分开。
- 成立条件： 同一企业技术参与者；两部分分别 N=6 与 N=8，失败 GAIA 任务与交互调试，第二部分提供错误摘要。
- 重要限制： 同一企业技术人员；两条失败任务；第二部分 8 人中仅 2 人达到精确正确答案。；控制效果依赖内部实现知识；不是普通用户被动观察实验。
- 在本库的作用： 区别可理解性、可控制性、调试效能。

S-HI13 - Cocoa: Co-Planning and Co-Execution with AI Agents

作者 / 机构： K. J. Kevin Feng；Kevin Pu；Matt Latzke；Tal August；Pao Siangliulue；Jonathan Bragg；Daniel S. Weld；Amy X. Zhang；Joseph Chee Chang。 发表 / 版本时间： 2026。

来源状态： CHI 2026学术论文；核查arXiv v4。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1145/3772318.3791673。

- 核查定位： 核查更新至 v4，2026-02-18/CHI 2026；实验室 N=16 方法/结果，7 天 N=7 部署与局限；早期 v1 不作为最终结论。
- 直接支持的范围： C-04-014：共同规划/执行界面改善自评 steerability；短实验与一周实际使用的委托方式不同。
- 成立条件： N=16 实验室比较；其中自愿参加的 N=7 在真实研究任务中部署 7 天；参与者为 CS/邻近领域研究者。
- 重要限制： CS 及邻近领域研究者；部署自选择且仅 7 人、至少 90 分钟使用建议。；ease-of-use 无显著差异不等于统计等效；field 反馈并非客观科研质量提升证明。
- 在本库的作用： 人机工作分配与长期使用研究的直接 Agent 证据。

S-HI14 - Ironies of Automation

作者 / 机构： Lisanne Bainbridge。 发表 / 版本时间： 1983。

来源状态： Automatica 1983理论论文。 证据类型： K/M。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1016/0005-1098(83)90046-8。

- 核查定位： 原 Automatica 论文：操作者监督、技能维持、异常情况下接管困难的分析。
- 直接支持的范围： C-06-002：自动化可能留下更困难的监督与接管工作，人在环中不等于随时具备纠错能力。
- 成立条件： 传统工业自动化的监督与接管分析；讨论自动化后的操作技能、情境和异常处置。
- 重要限制： 经典分析与工程例子；不是现代 LLM Agent 的量化接管实验。

- 在本库的作用： 监督能力和技能保持的理论边界。

S-HI15 - A Model for Types and Levels of Human Interaction with Automation

作者 / 机构： Raja Parasuraman；Thomas B. Sheridan；Christopher D. Wickens。 发表 / 版本时间： 2000。

来源状态： IEEE SMC-A 2000理论论文。 证据类型： K/M。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1109/3468.844354。

- 核查定位： 原论文全文的四类功能、自动化程度和相互依赖论证，IEEE pp.287-288 等。
- 直接支持的范围： C-06-001：信息获取、分析、决策选择、动作实施可以有不同自动化程度。
- 成立条件： 自动化系统的功能分配框架；四类功能可有不同程度，决策/动作十级表不代表所有功能统一尺度。
- 重要限制： 10 级表主要面向决策/动作，不能直接当所有系统共用的一条能力等级。；理论框架不是最优固定分工的实证证明。
- 在本库的作用： 人机参与模式的功能分解。

S-HI16 - Principles of Mixed-Initiative User Interfaces

作者 / 机构： Eric Horvitz。 发表 / 版本时间： 1999。

来源状态： CHI 1999学术论文。 证据类型： K/M/P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1145/302979.303030。

- 核查定位： mixed initiative 原则；action/no-action/dialog 的 expected utility 形式与 LookOut 场景。
- 直接支持的范围： C-06-004：询问用户应比较潜在收益与时机/行动成本，不能仅按模型不确定性决定。
- 成立条件： LookOut 日历辅助原型及决策理论；预先建模目标概率、行动、对话与时间成本。
- 重要限制： 日历辅助领域原型；效用与概率需来自情境模型，原论文不提供通用 Agent 干预阈值。
- 在本库的作用： 介入价值、成本、可撤回控制的决策理论入口。

S-HI17 - Towards Adjustable Autonomy for the Real World

作者 / 机构： Paul Scerri；David V. Pynadath；Milind Tambe。 发表 / 版本时间： 2002。

来源状态： JAIR 2002学术论文。 证据类型： M/E/P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1613/jair.1037。

- 核查定位： §4 transfer-of-control 的 MDP 状态/动作/奖励； §5 原型部署及策略比较；不是 2011 年首次发表。
- 直接支持的范围： C-06-005：控制转移可包含等待、再次转移与调整协调约束，需要计入人类不响应及团队成本。
- 成立条件： MDP 状态/转移/奖励给定的控制转移策略；E-Elves 在小型研究团队日程协调中部署，涉及人类不响应和协调约束。
- 重要限制： E-Elves 为小型研究团队日程协调；最优性限于既定状态、概率、效用模型。；系统并未提供对开放式 Agent 任意失败的检测器。
- 在本库的作用： 从单次询问扩展到时间中的控制转移策略。

S-HI18 - Effects of Intelligent Notification Management on Users and Their Tasks

作者 / 机构： Shamsi T. Iqbal；Brian P. Bailey。 发表 / 版本时间： 2008。

来源状态： CHI 2008学术论文。 证据类型： E/M。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1145/1357054.1357070。

- 核查定位： 断点分类及用户实验方法；第二研究 N=16，两类主任务，延迟通知与即时通知的比较；分类局限。
- 直接支持的范围： C-06-009：在研究任务中等到任务断点送达通知可降低部分打扰成本。
- 成立条件： 第二个用户实验 N=16，编程或图形任务中的外围通知；比较即时通知与断点送达。
- 重要限制： 应用切换不一定等于心理任务边界；断点分类的总体准确率会被大量非断点样本抬高。；通知延迟存在收益/时效权衡，不能固定照搬平均等待时间。
- 在本库的作用： 提醒时机和基于任务断点的策略证据。

S-HI19 - On the Need for Attention-Aware Systems: Measuring Effects of Interruption on Task Performance, Error Rate, and Affective State

作者 / 机构： Brian P. Bailey；Joseph A. Konstan。 发表 / 版本时间： 2006。

来源状态： Computers in Human Behavior 2006学术论文。 证据类型： E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1016/j.chb.2005.12.009。

- 核查定位： N=50、6 类主任务，主任务中间与任务间呈现外围任务；错误、耗时、焦虑结果。
- 直接支持的范围： C-06-009：通知时点影响完成任务和情绪成本，打断并非零成本。
- 成立条件： N=50、六类受控主任务；比较主任务执行中与任务之间呈现外围任务。
- 重要限制： 受控短任务；不能导出所有工作通用的每次中断恢复分钟数。
- 在本库的作用： 注意力与任务中断的实验基础。

S-HI20 - Effects of Workload, Work Complexity, and Repeated Alerts on Alert Fatigue in a Clinical Decision Support System

作者 / 机构： Jessica S. Ancker；Alison Edwards；Sarah Nosal；Diane Hauser；Elizabeth Mauer；Rainu Kaushal；HITEC Investigators。 发表 / 版本时间： 2017。

来源状态： BMC Medical Informatics and Decision Making 2017学术论文。 证据类型： E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1186/s12911-017-0430-8。

- 核查定位： 112 名初级保健临床人员、2010-2013 年回顾性日志；重复与接受定义、回归结果、局限。
- 直接支持的范围： C-06-010：更多重复或每次就诊更多提醒与较低接受相关；一般工作量和新提醒随时间下降并非均获支持。
- 成立条件： 112 名门诊初级保健临床人员，2010-2013 年回顾性提醒日志；接受是系统记录的行为指标。
- 重要限制： 观察研究不证明因果；未人工判断每条提醒是否临床适当。；接受/忽略行为不是实际临床正确性，不能直接迁移到开发者提醒。

- 在本库的作用： alert fatigue 机制细分与反例。

S-HI21 - Tuning Out Security Warnings: A Longitudinal Examination of Habituation Through fMRI, Eye Tracking, and Field Experiments

作者 / 机构： Anthony Vance；Jeffrey L. Jenkins；Bonnie Brinton Anderson；Daniel K. Bjornn；C. Brock Kirwan。 发表 / 版本时间： 2018。

来源状态： MIS Quarterly 2018学术论文。 证据类型： E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.25300/MISQ/2018/14124。

- 核查定位： 多日 fMRI/眼动 N=15 完成者；3 周 Android 场景 N=102 完成者；静态/变化警示比较和限制。
- 直接支持的范围： C-06-010：重复安全警示的习惯化具有跨方法证据，改变外观在特定研究中减缓下降。
- 成立条件： 多日 fMRI/眼动实验 15 名完成者；三周 Android 应用任务 102 名完成者，比较静态与变化的安全警示。
- 重要限制： 学生、有偿规定的应用安装任务；忽略警告无真实损失，仍可能含 crying-wolf 解释。；大量警示次数不等于同样多的独立参与者；不能据此保证长期实际风险减少。
- 在本库的作用： 长期重复暴露与注意衰减的直接研究。

S-HI22 - Does Automation Bias Decision-Making?

作者 / 机构： Linda J. Skitka；Kathleen L. Mosier；Mark Burdick。 发表 / 版本时间： 1999。

来源状态： International Journal of Human-Computer Studies 1999学术论文；摘要级核查。 证据类型： E。 核查深度： A1。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1006/ijhc.1999.0252。

- 核查定位： 原出版方摘要；本轮未完整获取实验方法。
- 直接支持的范围： C-06-003：模拟飞行决策任务区分 omission 与 commission 两类自动化相关错误。
- 成立条件： 有/无不完善自动辅助的模拟飞行决策任务；本轮摘要不能确认具体样本与职业构成。
- 重要限制： 不能据摘要确认参与者是否职业飞行员、精确样本与全部设计。；不把所有不采纳提醒行为归因于 automation bias。
- 在本库的作用： 自动化偏差原始研究线索与基本区分。

S-HI23 - Consistent Estimators for Learning to Defer to an Expert

作者 / 机构： Hussein Mozannar；David Sontag。 发表 / 版本时间： 2020。

来源状态： ICML / PMLR 119，2020学术论文。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： §3-4 分类/拒绝函数与损失；§6 CIFAR-10H 和 CheXpert 的模拟专家、数据与对照。
- 直接支持的范围： C-06-012：学习转交应建模模型与专家的联合损失，专家并非默认永远正确。
- 成立条件： 给定标签空间与专家预测的监督分类；理论目标是联合损失，CIFAR-10H 标注分布和 CheXpert 模拟专家用于部分实验。

- 重要限制： 形式结论属于给定监督分类问题及其假设；未独立重证全部理论附录。；CIFAR-10H 专家由已有标注分布采样；CheXpert 用模拟专家，不是在线临床介入实验。
- 在本库的作用： 选择性预测/转交的替代路线与外推限制。

S-HI24 - When Should Users Check? Modeling Confirmation Frequency in Multi-Step Agentic AI Tasks

作者 / 机构： Jieyu Zhou；Aryan Roy；Sneh Gupta；Daniel Weitekamp；Christopher J. MacLellan。 发表 / 版本时间： 2026。

来源状态： CHI 2026学术论文；核查arXiv v3。 证据类型： M/E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1145/3772318.3790655。

- 核查定位： v3/CHI 2026；CDCR 假设、动态规划、参数取得、N=48 控制实验及局限；早期标题含 Decision-Theoretic Model。
- 直接支持的范围： C-06-013：在已定义错误、步骤和时间成本的模拟 Agent 任务中，自适应确认频率可优于仅末尾检查。
- 成立条件： N=48、模拟购物/图像编辑/游戏多步任务；已定义正确性、错误传播和诊断/重做方式，目标是时间成本。
- 重要限制： 最小化时间，不是直接优化安全损失；常数成功率来自先验/试点，不是各用户实时学习。；正确/错误明确、错误传播与诊断方式假设限制开放任务适用性。
- 在本库的作用： 直接 Agent 介入时机模型，作为条件成立的方法而非普适检查频率。

S-HI25 - Monitoring Distributed Systems

作者 / 机构： Rob Ewaschuk；Betsy Beyer (editor)。 发表 / 版本时间： 2016。

来源状态： Google SRE原始工程书章，2016。 证据类型： P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Google SRE 第 6 章，监控/告警分类、symptoms vs causes、paging 的可行动性原则。
- 直接支持的范围： C-06-006：异常记录、调查线索与需要人立即处理的告警应区分。
- 成立条件： Google 生产分布式服务的监控与值班实践；区别记录、调查与需要人立即处理的呼叫值班人员的紧急告警。
- 重要限制： 生产系统工程经验，不是跨行业普适干预政策或 Agent 错误判别标准。
- 在本库的作用： 工程中 actionability 与人类注意资源的成熟实践。

S-HI26 - Rethinking the Progress Bar

作者 / 机构： Chris Harrison；Brian Amento；Stacey Kuznetsov；Robert Bell。 发表 / 版本时间： 2007。

来源状态： UIST 2007学术论文。 证据类型： E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1145/1294211.1294231。

- 核查定位： N=22，9 种运动函数、同为 5.5 秒、成对主观时间判断，顺序效应。
- 直接支持的范围： C-04-011：进度动画的运动方式可改变主观时间感；主观感觉与真实完成比例不同。
- 成立条件： N=22、9 种运动函数的进度条成对比较；每条均为 5.5 秒，评价主观时间感。

- 重要限制： 短时、确定时长、研究机构样本；不证明开放式任务可以准确给出完成百分比。
- 在本库的作用： 进度表达的知觉效应及真实性边界。

S-HI27 - Cognitive Load During Problem Solving: Effects on Learning

作者 / 机构： John Sweller。 发表 / 版本时间： 1988。

来源状态： Cognitive Science 1988学术论文；摘要级核查。 证据类型： K/M/E。 核查深度： A1。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1207/s15516709cog1202_4。

- 核查定位： 原出版方摘要/元数据；本轮未取得全文实验细节。
- 直接支持的范围： C-04-019：有限认知资源、任务活动与学习之间的竞争是认知负担研究背景。
- 成立条件： 教育/问题解决与学习语境；本轮摘要级核查，不报告未核对的样本和具体实验操作。
- 重要限制： 教育问题解决语境；不能单靠此源证明 Agent 卡片数量、特定折叠策略或界面认知负担。；不声称已核实所有实验细节。
- 在本库的作用： 认知负担原始入口；补全文后再发展精确机制。

S-HI28 - Measurement of Situation Awareness in Dynamic Systems

作者 / 机构： Mica R. Endsley。 发表 / 版本时间： 1995。

来源状态： Human Factors 1995测量论文；摘要级核查。 证据类型： K/M。 核查深度： A1。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1518/001872095779049499。

- 核查定位： 原论文元数据与摘要；SAGE 全文访问失败，RG 未提供可充分核实的方法全文。
- 直接支持的范围： 为 C-04-016 的 situation awareness 测量提供继续调查入口；不将其未读细节当本轮验证成果。
- 成立条件： 动态系统 SA 测量方法论文；本轮仅原摘要/元数据，详细测量效度需续查。
- 重要限制： SAGAT 的精确流程、效度论证和限制需补读原文；本轮只作方法线索。
- 在本库的作用： 优先补证的测量理论，而非已复现测试工具。

S-HI29 - The Cost of Interrupted Work: More Speed and Stress

作者 / 机构： Gloria Mark；Daniela Gudith；Ulrich Klocke。 发表 / 版本时间： 2008。

来源状态： CHI 2008学术论文。 证据类型： E。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1145/1357054.1357072。

- 核查定位： 4 页原论文的方法、结果表与讨论；N=48，模拟办公室邮件任务，主任务计时明确减去处理打断的时间。
- 直接支持的范围： C-06-011：被打断条件下净主任务耗时更短，同时报告更高压力等成本。
- 成立条件： N=48、模拟办公室邮件任务、同/异语境打断；主任务耗时指标扣除了处理打断的时间。
- 重要限制： 不等于总耗时更短；质量指标未显著不同不等于广泛质量等效。；加快补偿是作者解释，需更细过程数据验证；短实验不能预测长期适应。

- 在本库的作用： 反驳用单一完成时间刻画中断成本。

8.5 当前官方接口、协议与平台

S-IF01 - Hooks reference

作者 / 机构： Anthropic / Claude Code。 发表 / 版本时间： 持续更新，核查2026-10-17。

来源状态： 官方接口文档。 证据类型： P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： PreToolUse; PostToolUse decision control; StopFailure; Run hooks in the background
- 直接支持的范围： 钩子覆盖特定生命周期；调用前事件不证明操作已执行；结果可在工具执行后被改写再交给Agent。
- 成立条件： 只针对当日文档所描述的Claude Code能力；各字段有版本或配置条件。
- 重要限制： 未连接用户客户端；不证明全部文件读取可见，也不证明钩子采集无扰动。
- 在本库的作用： 01观察边界与02/03结果证据分层的直接反例

S-IF02 - Monitoring

作者 / 机构： Anthropic / Claude Code。 发表 / 版本时间： 持续更新，核查2026-10-17。

来源状态： 官方接口文档。 证据类型： P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Traces (beta); Event correlation attributes; Privacy; Content attributes under detailed beta tracing
- 直接支持的范围： 记录序号属于进程；恢复会话可能重复；转录格式内部且版本相关；内容字段受开关、截断及beta条件限制。
- 成立条件： 需启用相应telemetry；详细beta在交互CLI等环境有额外限制。
- 重要限制： 没有实测丢失率、开销或本机可用性；不能把文档声明当端到端历史完整性保证。
- 在本库的作用： 01来源能力、02身份时间边界、07缺失机制

S-IF03 - Codex App Server

作者 / 机构： OpenAI。 发表 / 版本时间： 持续更新，核查2026-10-17。

来源状态： 官方接口文档。 证据类型： P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Protocol; Message schema; Core primitives; Read a stored thread; Events / Turn events
- 直接支持的范围： thread/turn/item分层；thread/read与resume/事件订阅不同；turn/completed的status仍可失败或中断。
- 成立条件： 面向所连接的app-server与其线程；schema由具体Codex版本生成；部分transport实验性。
- 重要限制： 未证实第三方可旁听任意已运行客户端会话；本次未启动或控制会话。
- 在本库的作用： 01接口异质性、02终态语义、07评价单位

S-IF04 - Run Claude Code programmatically

作者 / 机构： Anthropic / Claude Code。 发表 / 版本时间： 持续更新，核查2026-10-17。

来源状态： 官方接口文档。 证据类型： P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Get structured output; Stream responses; Follow subagent messages; Stop a run with SIGTERM
- 直接支持的范围： 受管理运行可输出stream-json；子Agent消息可通过parent_tool_use_id关联；输出模式和终止方式影响记录。
- 成立条件： 针对相应非交互运行与配置，部分转发能力受版本/选项限制。
- 重要限制： 不是附接任意桌面会话的承诺；流记录范围仍由运行器决定。
- 在本库的作用： 01主动管理运行这一替代路线

S-IF05 - Non-interactive mode

作者 / 机构： OpenAI。 发表 / 版本时间： 持续更新，核查2026-10-17。

来源状态： 官方接口文档。 证据类型： P。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Make output machine-readable
- 直接支持的范围： codex exec -json输出运行事件，事件名及schema与App Server协议不相同。
- 成立条件： 用于调用者启动的非交互运行；必须按该接口解释。
- 重要限制： 不说明用户已有GUI会话可被同样观察；没有运行样例。
- 在本库的作用： 01接口族边界与02避免按同名事件机械映射

S-IF06 - Orchestration and handoffs

作者 / 机构： OpenAI。 发表 / 版本时间： 持续更新，核查2026-10-17。

来源状态： 官方SDK文档。 证据类型： P。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Handoffs; Use agents as tools for manager-style workflows
- 直接支持的范围： handoff和agent-as-tool是不同编排形式；高级handoff可带结构化元数据或经过过滤的历史。
- 成立条件： 只证明Agents SDK存在这些机制，具体API依语言文档。
- 重要限制： 未读取用户真实交接；委派文本不自动等于接收者全部输入。
- 在本库的作用： 02交接身份与03接收侧证据边界

S-IF07 - Integrations and observability

作者 / 机构： OpenAI。 发表 / 版本时间： 持续更新，核查2026-10-17。

来源状态： 官方SDK文档。 证据类型： P。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Choose what lives in the SDK; Tracing
- 直接支持的范围： Agents SDK正常服务端路径有内建tracing，可记录模型调用、工具、handoff及custom spans。
- 成立条件： 仅适用于使用该SDK且相应追踪启用的工作流。
- 重要限制： 不证明不同产品全部内部推理/用户会话可见；没有性能或用户实验。
- 在本库的作用： 01合作式instrumentation的代表

S-IF08 - Model Context Protocol 2026-07-28 Key Changes

作者 / 机构： Model Context Protocol maintainers。 发表 / 版本时间： 2026-07-28。

来源状态： 版本化协议变更规范。 证据类型： K/P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Breaking changes; Minor changes; Deprecations
- 直接支持的范围： 2026-07-28版本改变会话/请求模型、迁移Tasks至扩展、弃用Logging并描述OTel上下文传播。
- 成立条件： 规范版本为2026-07-28；实际客户端仍可能协商旧版本。
- 重要限制： 标准发布不等于所有现有客户端已实现；不提供全局活动总线或被观察端任意历史。
- 在本库的作用： 01标准变迁与02协议版本不可混用

S-IF09 - Tasks extension specification

作者 / 机构： Model Context Protocol Tasks extension maintainers。 发表 / 版本时间： draft，核查2026-10-17。

来源状态： 扩展规范草案。 证据类型： M/P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Task Status; Task Creation; Task Polling; Task Input; Lifetime
- 直接支持的范围： 草案将completed与JSON-RPC层完成关联，允许其result含isError:true；failed有更窄的协议错误含义。
- 成立条件： 仅指当日draft，不标为稳定部署合同；需要扩展支持。
- 重要限制： 不把该命名推广至旧MCP或其他Agent；没有实现互操作性实验。
- 在本库的作用： 02多层成功语义的直接反例

S-IF10 - Life of a Task

作者 / 机构： Agent2Agent Protocol project。 发表 / 版本时间： v1.0.1，发布日期未独立核实。

来源状态： 版本化协议说明。 证据类型： K/P。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Task lifecycle; Task Immutability; Parallel Follow-ups; Tracking Artifact Mutation
- 直接支持的范围： 区分context与task，终态任务后续细化产生新task；artifact版本关系并不由该协议全面管理。
- 成立条件： 仅针对v1.0.1文档及实现该协议的端点。
- 重要限制： 不能以contextId推出完整因果关系或结果质量；未做互操作试验。
- 在本库的作用： 02任务语义与跨Agent观察替代路线

S-IF11 - Instrumentation

作者 / 机构： Langfuse maintainers。 发表 / 版本时间： 持续更新，核查2026-10-17。

来源状态： 开源系统官方文档。 证据类型： P。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Manual observations; Update trace; Trace and observation IDs
- 直接支持的范围： SDK通过observation/span和输入输出属性组织轨迹；当前trace输入输出从根observation派生。
- 成立条件： 适用于已instrument的应用及当前SDK语义。
- 重要限制： 官方功能说明不是跨平台比较试验；不会自动取得无插桩第三方进程的完整语义。
- 在本库的作用： 01代表性工程路线，不作平台排名

S-IF12 - How Tracing Works

作者 / 机构： Arize Phoenix / OpenInference maintainers。 发表 / 版本时间： 持续更新，核查2026-10-17。

来源状态： 开源系统官方文档。 证据类型： P。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Instrumentation; Exporter; Collector
- 直接支持的范围： OpenInference instrumentors产生spans，经exporter送给Phoenix collector与UI。
- 成立条件： 需要应用手工或自动instrumentation及相应导出链路。
- 重要限制： auto-instrumentation仍需受支持组件与运行环境；不等于任意客户端零接入观察。
- 在本库的作用： 01收集后端与数据来源能力相区分

S-IF13 - Structured model outputs

作者 / 机构： OpenAI。 发表 / 版本时间： 持续更新，核查2026-10-17。

来源状态： 官方API文档。 证据类型： P。 核查深度： A2。 核查日期： 2026-10-17。

原始来源 / 官方入口。

- 核查定位： Handling user-generated input; Handling mistakes
- 直接支持的范围： 输出遵循schema仍可能出现事实或内容错误，不兼容输入可能诱发幻觉。
- 成立条件： 只讨论schema约束与内容正确性的边界。
- 重要限制： 没有证据蕴含或观察者准确率保证；本次未调用模型接口。

- 在本库的作用： 03格式验证与事实验证分离

8.6 近期相关前沿研究

S-FR01 - Plans They Abandon, Reports They Author: The Narrative Layer of Autonomous Agents

作者 / 机构： Obada Kraishan; Kulsawasd Jitkajornwanich。 发表 / 版本时间： 2026-09，arXiv v1。

来源状态： 预印本，未核实同行评审发表。 证据类型： E/M。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.48550/arXiv.2609.12205。

- 核查定位： §4 corpus/measures; §5 validation; §6 results; §8 limitations
- 直接支持的范围： 在SWE-chat语料中检验计划、自述和工具调用记录的差距，并披露模型主张核验器与人工判断一致性差。
- 成立条件： 一个采集语料，主要为同一scaffold；各分析子样本不同；recoverability使用模型probe而非用户实验。
- 重要限制： 摘要概括与正文小效应需区别；模型判断失败限制精确遗漏/虚假率解读；无本研究复现。
- 在本库的作用： 03自述覆盖与07测量工具也需验证的近年线索

S-FR02 - Beyond Accuracy: How Procedural Traces Shift the Decision Criterion of LLM Overseers

作者 / 机构： Zihan Chen; Di Zhu; Lei Zheng; Weiling Li。 发表 / 版本时间： 2026-09，arXiv v1。

来源状态： 预印本，未核实同行评审发表。 证据类型： E/M。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.48550/arXiv.2609.18204。

- 核查定位： §4 controlled audit; §5 hit/false-alarm/criterion; §6.3 limitations
- 直接支持的范围： 19个人工构造餐馆合规任务中，详细过程自述可提高部分LLM观察者对正确答案的错误拒绝。
- 成立条件： 5个模型，反证始终可见、单标准违规；4551次有效判断不是4551个独立任务；按item聚类。
- 重要限制： 没有人类观察者试验；未检验隐藏错误或自然长Agent轨迹；作者机制解释部分依赖自述原因。
- 在本库的作用： 03/06/07详细解释的反方向风险与信号检测分析

8.7 概率推断基础

S-MT01 - Planning and acting in partially observable stochastic domains

作者 / 机构： Leslie Pack Kaelbling；Michael L. Littman；Anthony R. Cassandra。 发表 / 版本时间： 1998。

来源状态： 同行评审期刊论文；作者机构公开PDF。 证据类型： K/M。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1016/S0004-3702(98)00023-X。

- 核查定位： §1； §3.1-3.4 POMDP、belief及Bayes更新； §4.3-4.4精确规划复杂性相关段落。未核验全部算法证明。
- 直接支持的范围： 部分观测下以状态分布总结历史；状态估计与决策策略不同；信息获取和行动影响可在共同决策模型表达。

- 成立条件： 论文相应基础表述使用有限状态/行动/观测集合及给定正确的转移、观测、奖励模型；充分统计量结论依赖这些条件。
- 重要限制： 不是AI编程Agent观察器实验；状态枚举与策略计算可能昂贵；本次未比较现代求解器，也未验证现实参数可辨识性。
- 在本库的作用： 02概率重建的原始理论基础及06信息价值连接

S-MT02 - A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition

作者 / 机构： Lawrence R. Rabiner。 发表 / 版本时间： 1989。

来源状态： 学术论文；出版状态按所引来源。 证据类型： K。 核查深度： A3。 核查日期： 2026-10-17。

原始来源 / 官方入口；DOI 10.1109/5.18626。

- 核查定位： Proceedings of the IEEE77(2):257-286； §II、 §III.A-C、 §IV.D，重点PDF第2、5-9、13页
- 直接支持的范围： 标准HMM区分似然计算、状态序列推断和参数学习，最优路径与逐时刻后验最大化并不等价。
- 成立条件： 基础模型采用一阶Markov、时间齐次转移及给定隐藏状态序列的条件独立观测；扩展模型应另核查假设。
- 重要限制： 本文是权威原始教程而非所有算法首次提出；未复核其语音实验，也不提供Agent Observer效果证据。
- 在本库的作用： 成熟概率状态推断路线及其模型条件。

9 Research Continuation Guide 继续研究指南

9.1 接手时必须保留的上下文

本知识库已经完成六域的代表性知识地图、原始资料调查、方法比较、反证审查和跨域综合。完成本轮调查不等于所有开放问题已经解决。 研究空白、来源获取限制和适用条件是知识内容的一部分，不能在后续摘要中被删去。

接手的AI应先阅读第1、2、5、6章，再按任务进入领域章节。使用一条结论时同时读其来源条目的“条件、核查定位、限制”；不要仅检索到一个C-ID的短句就忽略范围。任何Yukio应用判断应在独立Application Analysis中处理，本库本身不承担客户端接入、架构选择或效果预测。

特别需要保持五项区分：Actor与Observer；源事件与观察记录；Agent自述与外部验证；支持关系与因果忠实性；检测正确与介入有价值。这些区分被破坏时，更多来源并不能补救推理错误。

9.2 研究覆盖清单

“已覆盖”表示本轮给出理论、方法或资料边界，不表示存在成熟通用解法。问题ID对应领域章节；开放问题集中在第6章。

9.2.1 领域01

原始调查主题	覆盖位置 / 问题	本轮证据与残余缺口
Observability基础与发展	3.01.2；RQ-01-01	LTI讲义、软件观测定义；不是完整控制理论史
Logs、Metrics、Traces、Spans、Instrumentation	3.01.3；RQ-01-02	OTel数据模型与关键规范；未做SDK符合性测试
Agent与传统软件的连续性和差异	3.01.4、3.01.8	分布式困难与新增语义层分别讨论；AgentOps分类不等于可靠性证明
外部行为与原生API、Hooks、日志、系统监控	3.01.5-3.01.7、3.01.90；RQ-01-03	多路线机制及当前Claude/Codex官方说明；没有现场接入
可见范围、完整性、盲区、采样	3.01.9；RQ-01-04/05	源头遗漏、缓冲、过滤、截断、断连等已区分
标准、代表系统、第三方限制	3.01.6-3.01.8、3.01.90	Dapper、X-Trace、Magpie、CamFlow、AgentSight、OTel及协议；跨平台效果未建立
观察者效应与性能	3.01.9；RQ-01-06/07	机制与已有实验条件；真实桌面成本属ORQ-13

9.2.2 领域02

原始调查主题	覆盖位置 / 问题	本轮证据与残余缺口
Event、State、Execution、Task、Session、Run、Tool Call	3.02.2；RQ-02-01	跨系统分析词汇与厂商原义分开
身份、时间与因果	3.02.3-3.02.5；RQ-02-02/03	Lamport、Mattern、快照；Fidge和故障检测经典全文仍缺
Tracing、Event Sourcing、State Machines、Process Mining	3.02.6-3.02.9；RQ-02-04	机制、输入、适用与失效条件；未统一比较现有工具性能

原始调查主题	覆盖位置 / 问题	本轮证据与残余缺口
并发、乱序、丢失、重复、延迟	3.02.4、3.02.8	偏序、事件时间与到达时间、Watermark、去重边界
部分可观测状态推断	3.02.10、3.02.90-3.02.91；RQ-02-07	相容集合、HMM、POMDP基础已补；Agent观测模型及共同实验待做
运行、等待、失败、完成、未知	3.02.11；RQ-02-06	范围与终态协议反例；没有通用目标完成Oracle
不同重建方法的限制及显式性质检查	3.02.12-3.02.14；RQ-02-08	LTL3有限未来与过去漏采分开；自然语言目标形式化仍开放

9.2.3 领域03

原始调查主题	覆盖位置 / 问题	本轮证据与残余缺口
Grounding、Attribution、Provenance、Faithfulness	3.03.2-3.03.3	概念与证明对象分开；因果忠实性没有单一充分度量
事实、Agent自述、外部模型推测	3.03.4	来源模态、支持边界及原始/Agent可见输出差异
从活动记录生成准确解释	3.03.5-3.03.7	模板、抽取、检索生成、原子事实和引用验证
一句话是否得到证据支持	3.03.6-3.03.7	AIS、ALCE、FActScore、FEVER；任务迁移需验证
不完整、矛盾、过时证据与不确定性	3.03.8	拒绝、修订、版本对应、联合一致性；不能以流畅性填补
解释错误、引用评价和事实分解	3.03.6-3.03.9	定位、蕴含、遗漏分母、注入影响；评判器也有误差
可信度与可理解性的关系	3.03.10及领域04	忠实、合理感与理解不同；效应不是单调关系

9.2.4 领域04

原始调查主题	覆盖位置 / 问题	本轮证据与残余缺口
Mental Models、Situation Awareness、Trust Calibration	3.04.1	已建立构念地图；Lee/See和精确SAGAT全文待补
HAI理论与用户能力认知形成	3.04.2；RQ-04-05/06	指南、知识背景、问题导向解释；框架不是效果保证
时间线、任务结构、进度与解释卡	3.04.4；RQ-04-03/08	表示机制和错误暗示已比较；开放进度分母未解决
复杂度、认知负担、Progressive Disclosure	3.04.1.3、3.04.4.1	成本分解与假设；Sweller本轮仅摘要
可解释界面是否改善理解	3.04.3、3.04.5	正反实验及Agent原型；没有大范围第三方桌面实验
信任、满意度与实际理解区分	3.04.1.2、3.04.6；RQ-04-01/02/04	构念与行为测量分开；不同题型需独立真值
用户实验及适用范围	3.04.3、3.04.5-3.04.7	样本、任务、位置提示、主动控制和纵向限制均保留

9.2.5 领域06

原始调查主题	覆盖位置 / 问题	本轮证据与残余缺口
HITL、Mixed Initiative、Automation Levels	3.06.1、3.06.3	职责、控制转移、效用理论；人不是完美后备
参与模式与何时请求参与	3.06.1-3.06.3；RQ-06-01/04/07	明确请求、澄清、审阅、接管、审计的不同条件
异常、错误、风险与可行动性	3.06.2；RQ-06-02/05	规范性目标、合理探索、行为与后果分开
Intervention Policy与Decision Utility	3.06.3、3.06.7	MDP、转交学习、动态确认；真实参数和通用任务范围未验证
Alert Fatigue、FP、FN与基率	3.06.4、3.06.6；RQ-06-03/08	合成概率算例与跨域实证；忽略提醒的机制不可混同
时机、频率、中断成本	3.06.5、3.06.7.3；RQ-06-06/10	任务断点、净主任务时间与总成本区分；时间模型有假设
研究成果与未解问题	3.06.7-3.06.9；RQ-06-09	原型与理论均有；不存在本库已证明的通用偏题判断能力

9.2.6 领域07

原始调查主题	覆盖位置 / 问题	本轮证据与残余缺口
Agent Evaluation与Observer Evaluation	3.07.1-3.07.2	评价对象和真值层次分离；Actor基准不能替代观察真值
Ground Truth、数据集与标注	3.07.2、3.07.7	世界、来源契约、采集呈现；分歧、部分真值、数据说明
Precision、Recall、Calibration	3.07.3-3.07.5	匹配单位、区间指标、校准和选择性输出；分母需固定
事件、状态、解释评价	3.07.3-3.07.6	在线可用证据、Unknown、事实和联合关系分别评价
Trace Evaluation、Replay与模拟	3.07.8-3.07.9	回放、故障注入、重新运行不同；合成故障与自然故障不同
真实系统测试	3.07.8-3.07.9	Jepsen、FoundationDB和AgentTelemetry；本轮未现场复现
用户研究与理解测量	3.07.10及3.04.6	任务准确、信任、满意度、净价值独立
缺失、偏差、Judge局限	3.07.4-3.07.7	未来泄漏、相关样本、选择偏差、评判器元评价
可靠性与实际用户价值	3.07.10、3.06.8、第7章	需要联合与长期结果；不能把局部性能直接相乘

9.3 优先补齐的全文与证据缺口

来源 / 状态	本轮实际核查	续研需要完成什么
S-OT01 Åström / Murray，A1	教材档案与目录；章节下载受阻	取得可读章节；若补更多控制理论结论，核查对应证明。当前秩条件已由S-OT33独立支持

来源 / 状态	本轮实际核查	续研需要完成什么
S-OT21 Fidge，A1	机构/作者元数据与摘要线索	取得原文；核查并发时间戳假设及与Mattern的关系
S-OT23 Chandra / Toueg，A1	作者机构摘要	核查Completeness、Accuracy各变体及模型；不继承未读证明
S-GE14 AgentBench，A1	官方摘要与元数据	取得可读全文后审查环境、任务及指标；不把它默认用作Observer基准
S-GE33 AgentTelemetry论文，A1	正式会议摘要、发表信息	补完整论文和固定实验制品；核查结构上界与实际检测器，独立于S-GE34动态仓库
S-HI02 Lee / See，A1	原摘要及出版信息	核查完整信任/依赖理论和证据综述；不得把摘要逐次转写成全文验证
S-HI22 Skitka等，A1	原出版摘要	补参与者、任务、错误定义、实验细节和推广限制
S-HI27 Sweller，A1	原摘要	核查学习与问题解决条件；不能据此给Agent界面编造定量认知预算
S-HI28 Endsley测量论文，A1	摘要和出版入口	核查SAGAT测量流程、效度及干扰限制
S-OT27 XES，A2	官方标准概述	取得需使用的完整IEEE规范及对应版本；概述不足以证明完整符合性

此外，HMM/POMDP已有原始基础核查，但没有完成面向Agent Observer的系统方法实验比较；签名收据、可验证执行及主动查询的现代专门方法只保留研究位置。增加这些线索时需要解决已有ORQ，而不是扩展成无边界新领域。

9.4 需要重新核查的动态事实

对象	必须保留的版本上下文	重新核查触发条件
Claude Code Hooks与Monitoring	事件名、覆盖检查点、字段、开关、序号作用域；prompt等内容配置	客户端更新；采集模式改变；出现新的Hook或脱敏行为
Codex App Server与非交互CLI	CLI版本；schema生成版本；读取/订阅；事件命名空间	更换客户端/传输；试图观察其他现有会话
OpenTelemetry GenAI	专门仓库与Development状态	约定迁移、稳定性变化、SDK支持声明改变
MCP与Tasks扩展	核心2026-07-28与单独Tasks草案分开	规范发布；客户端仍采用旧版；任务终态语义改变
A2A	所引1.0.1生命期语义	对象/任务状态或制品规则变化；勿假定所有实现符合
OCEL	固定arXiv 2.0与动态PDF实际封面分开	原URL内容更新；从2.0迁移到2.1预版或正式版
Cocoa / AgentGUI	实际读到的arXiv版本和出版状态	新版本添加或更改用户研究；正式论文公布
AgentTelemetry	会议摘要与仓库当前README分别保存	benchmark行数、adapters、故障集合、模型种子或计分器变化
LLM评判与基准结果	模型版本、提示、采样、证据窗口、任务分布	更换Judge；内容风格或日志长度改变；部署数据漂移

这张表是研究资料的新鲜度检查，不是Yukio升级或实施清单。接口文档不同时包含哪些保证，应由独立能力调查确认。

9.5 延续检索的方向与已有排除经验

概念族与英文检索入口	本轮获得的有效路线	后续检索注意
observability, instrumentation, distributed tracing coverage	OTel、Dapper、X-Trace、Magpie、系统事件官方资料	不要把vendor的“full visibility”直接当覆盖结果
event correlation, logical time, consistent cut, uncertain event logs	Lamport、Mattern、Chandy-Lamport、OCEL、不确定符合性	区分完整前缀、过去漏采、多个相容Trace
evidence attribution, citation recall, factual precision, faithfulness	AIS、ALCE、FActScore、CoT干预与反证	检索同文附录中的评价器误差，不只读摘要最高数值
mental models, transparency, appropriate reliance, agent interfaces	HAI指南、透明度反例、AgentGUI、AGDebugger、Cocoa	查看受试者、问题提示、实际修复结果和较新版本
mixed initiative, learning to defer, confirmation frequency, interruptions	Horvitz、Adjustable Autonomy、转交学习、断点提醒	不要把分类任务或时间成本最优直接扩展成通用安全保证
observer evaluation, fault injection, replay, judge reliability	AgentTelemetry、Jepsen、FoundationDB、JudgeBench、PPI	区分观测能力上界、实际适配器、mock seeds和真实自然故障
hidden Markov model, belief update, POMDP state estimation	Rabiner、Kaelbling等原始论文	基础已读；优先查Agent特定的模型辨识与迁移校准
agent trace self-report, procedural traces oversight	2026年两篇直接相关预印本	独立重复不足；新颖性和大规模数字不代替真实观察任务效度

检索日志中的部分早期查询已按主题归一化，不能当作可逐字重演的完整请求记录。因此本库不提供未经审计的PRISMA流图或论文总召回率。续研若要求正式系统综述，应另行预注册数据库、日期、布尔式、去重、筛选与双人裁决流程。

9.6 新证据进入知识库的研究记录

每项新增或修订结论应保存下列信息。它们描述研究证据，而非产品实现任务。

字段	记录要求
Claim ID / RQ ID	它回答什么问题，替代或修订哪条旧结论
精确命题	限定对象、范围、时间、比较项和结果，不只写“效果更好”
归属	来源直接结果、作者解释，或本研究综合
证据类型	K/E/P/M/H/O；必要时按不同命题拆分
来源与版本	作者、机构、题名、发表时间、URL/DOI、版本或commit、核查日期
核查深度	真正读到哪些章节/表格；全文是否可得；有无独立复现
设计和条件	任务、参与者/模型、样本单位、数据来源、对照、假设和信息可用时点
结果与统计	分母、单位、效应与不确定性；不能以无显著差异证明等效
限制与反例	哪些替代解释未排除，哪些环境不适用，是否共享数据或模型
知识变化	支持、削弱、推翻或仅细化现有结论；什么还需要验证

发现矛盾资料时，应首先检查命题是否一致：比较的是同一任务、同一终点、同一接口版本和同一评价单位吗？若相同条件仍产生冲突，应保留冲突并分析复现或测量问题；不要靠选择有利来源消除矛盾。

9.7 下一轮可直接开始的研究单元

若后续目标是扩展专业知识而非Application Analysis，可以从三类单元继续：

- 理论与语义补查： 补齐9.3的全文；深入研究观测契约、不可辨识性和过去漏采下的保守监测，优先服务ORQ-01/02/03。
- 评价方法调查： 查找独立Observer数据和自然故障样本，验证Claim、关系、状态和介入标签的内容效度，优先服务ORQ-04/05/08。
- 人因证据调查： 比较信息相同条件下的理解、信任和介入实验，以及长程真实使用研究，优先服务ORQ-09/10/11/14。

开始前先引用本库已有来源和边界，不必重复从“什么是Observability”检索起。结束时提交的是新增知识、反例和更新后的证据记录，而不只是更长的论文名单。

10 Technical Glossary 专业术语表

本表采用本文需要的精确定义；标明“本库操作性定义”的词不被冒称为统一行业标准。同一英文词在具体协议中可能有更窄或不同含义，实际使用以相应版本定义为准。

10.1 观察与遥测

术语	定义与边界	主要来源
Actor / Observer	分别指执行任务的系统与观察、解释它的系统；本库分析角色，不要求物理分离	本库操作性定义
Observability	在数学模型中涉及内部状态可区分性；软件工程中指借可获得信息调查系统行为的能力	S-OT02、S-OT33
Instrumentation	在应用、库、运行时或系统边界产生观测信息的机制	S-OT02、S-OT03
Telemetry	被生成并传输以反映行为、状态或资源的测量信息总称	S-OT02
Log Record	表达某项活动或状态的信息记录；记录不是所指发生本身	S-OT18、S-OT26
Metric	数值测量及聚合；按维度和时间组织，通常不保存逐操作全部语义	S-OT03
Trace	通过Trace Context关联的Spans集合；不自动等于一个用户任务	S-OT03、S-OT05
Span	带身份、起止和属性等信息的操作区间；结束与应用标注状态有规范含义	S-OT03、S-OT04
Span Event	附属于Span的时间点记录，不自动成为独立操作	S-OT03
Span Link	与另一个Span的关系，可表达跨Trace、多来源连接	S-OT03
Trace Context	在组件间传播Trace身份及有关状态的信息；其存在不保证完整采集	S-OT05
Head / Tail Sampling	在较早阶段或收集到更多Trace信息后决定保留；二者有不同时间与成本前提	S-OT17
ObservedTimestamp	观察组件收到记录时的时间，与源头记录的Timestamp不同	S-OT18
Coverage Contract	说明活动类型、范围、生成和采集保证及盲区的研究用概念；本轮尚无统一实现	本库H/O；ORQ-01
Observer Effect	观察机制对被观察执行造成的时序、资源或行为变化	S-OT11、S-IF01
Hook	客户端在定义的生命周期位置调用的扩展机制；可能参与控制，覆盖需逐项核查	S-IF01
System Provenance	由系统活动构建对象及信息流沿革；边可能为保守潜在依赖	S-OT13
Artifact / Version	可识别产物及其内容或状态版本；路径相同不保证版本相同	S-GE01、S-OT28

10.2 事件、关系与状态

术语	定义与边界	主要来源
Occurrence / Event	前者是发生，后者是表达发生及上下文的数据；一次发生可对应多条事件	S-OT26
State	相对于模型、范围和时刻的状态；观察者可能只能保留候选状态集合	本库分析词汇；S-OT31
Execution	在所定义语义下的运行过程，可以只具有偏序	S-OT19
Task / Session / Run / Turn	目标工作、上下文容器、运行尝试或交互轮等不同对象；没有统一跨厂商等价映射	S-IF03、S-IF09、S-IF10
Tool Call	一次具体工具调用请求及其执行和响应生命周期，不等于上层目标	S-IF01、S-IF03
Attempt / Retry	一次尝试与再次尝试；不能把重复投递与实际重复执行混同	本库分析词汇；S-OT26
Correlation	按已知身份、Schema或推断关联记录；应标明关系证据强度	S-OT08
Happens-before	由进程内顺序、消息发送接收及传递性定义的偏序	S-OT19
Logical Clock	若a happens-before b，则C(a)小于C(b)；逆命题一般不成立	S-OT19
Vector Clock	在相应传播模型中用向量偏序表示因果历史；完整前提很重要	S-OT20
Consistent Cut	与因果关系相容的执行切面；不能包含接收却遗漏相应发送	S-OT22
Event Time / Processing Time	事件在源头的时间与在处理组件中处理的时间；不能混作真实顺序	S-OT25
Watermark	依赖来源与策略的事件时间进度估计或保证；需检查它属于哪一种	S-OT25
Event Sourcing	将领域状态变化事件作为权威历史并据以形成投影；不是任意日志回放	S-OT24
State Machine	状态集合、事件与转移规则构成的模型；准确性依赖模型与输入覆盖	S-OT32；本库综合
Petri Net / Marking	以Place、Transition、Token描述状态、启用和并发；Marking是Token分布	S-OT29
Process Discovery	从执行记录推导流程模型；输出不是未经假设的真实过程	S-OT29、S-OT30
Conformance Checking	检查日志与给定模型之间的符合或偏离；不等于目标正确性	S-OT30、S-OT31
Case Notion	将哪些事件视作同一执行实例的分析选择	S-OT27、S-OT28
Object-centric Event Log	允许事件关联多个对象及其类型/关系的记录模型	S-OT28
Runtime Verification	对被观察运行的显式性质作监测；不同于证明所有运行正确	S-OT32

术语	定义与边界	主要来源
Inconclusive / Unknown	前者可指有限未来延伸下尚不可判；Unknown也可能来自过去缺失、冲突或过时	S-OT32；本库综合
Belief State	在正确模型条件下由历史形成的状态概率分布，不等于最可能单一状态	S-MT01
Hidden Markov Model	隐藏状态按转移模型变化、观测由状态概率生成的模型；基础版本有Markov、齐次等假设	S-MT02
Viterbi / Forward-Backward	前者求联合最优状态路径；后者可求逐时刻边缘后验，两种目标不同	S-MT02
POMDP	部分可观测的决策过程，在状态信念上考虑行动、信息与收益	S-MT01

10.3 证据与解释

术语	定义与边界	主要来源
Evidence Grounding	将陈述限制在可识别证据能够支持的范围；支持不保证来源真实	S-GE03
Attribution	在NLG评价中指向支持陈述的来源；在PROV中也有实体责任归属的专门含义	S-GE01、S-GE03
Provenance	描述实体、活动、责任者及产生、使用、衍生等沿革的信息	S-GE01
Faithfulness	解释与所声称描述的机制或证据关系一致；必须说明具体评价定义	S-GE02、S-GE05
Plausibility	解释对人而言合理或有说服力；不能代替机制忠实性	S-GE02
Factuality	陈述是否符合所定义的事实依据或世界真值；与可读性不同	S-GE08
Agent Self-report	Agent发表的计划、状态或理由声明；其发表可观察，内容需另外核对	S-GE04；本库综合
Atomic Claim / Fact	用于独立支持检查的较小事实单元；分解后仍需检查联合关系	S-GE08、S-GE29
Entailment	在给定语言与上下文中，证据是否足以支持陈述；自动NLI判断仍有误差	S-GE07、S-GE30
Contradiction	证据与主张在同一对象、时间、范围下不相容；不同版本不必构成矛盾	S-GE03、S-GE30
AIS	Attributable to Identified Sources；在上下文中判断陈述能否归于指定来源的框架	S-GE03
Citation Precision	对提供的引用是否实际有关并支持相应陈述的评价，具体聚合按方法定义	S-GE07
Citation Recall	ALCE中主要针对已生成陈述的引用支持覆盖，不是全部重要事实召回率	S-GE07
Important-fact Coverage	解释涵盖独立定义的重要事实的程度；分母需在解释之外确定	本库操作性定义

术语	定义与边界	主要来源
Evidence Staleness	证据与当前目标、对象版本或时间条件不再对应	本库综合；S-GE01
Provenance of Provenance	关于来源记录自身如何产生、由谁记录的沿革信息	S-GE01
Prompt Injection	不可信材料中的内容试图改变处理系统的指令行为；Observer也可能面对这种材料	S-GE12
Abstention	在证据或风险条件不满足时不作某项断言；不等于停止所有有用解释	S-GE21

10.4 人类理解与参与

术语	定义与边界	主要来源
Mental Model	人对系统结构和运作的内部表征，可不完整或错误	S-HI01
Situation Awareness	相对于目标对当前要素、意义及可能演变的认识	S-HI01
Trust / Reliance	信任态度与实际采纳、委托或核查行为；二者需要分别测量	S-HI02；本库操作化
Trust Calibration	使依赖与系统实际能力及使用条件相称；目标不是信任分数越高越好	S-HI02、S-HI07
Comprehension	能支持正确回答、推理与边界判断的理解能力；与自感易懂分开	S-HI07、S-GE26
Simulatability	人预测模型输出的能力；不自动说明能发现错误	S-HI07
Progressive Disclosure	按关注与交互逐步呈现细节；是否有效取决于用户能否发现并核查关键证据	S-HI09；本库综合
Foil	对比性解释中作为替代的事件、结果或预期	S-HI06
Steerability	人把系统带向期望行为的能力；主观感受、入口与实际效果不同	S-HI12、S-HI13
Human-in-the-Loop	人参与自动化过程的总体称呼；必须具体说明环节和控制权限	S-HI15
Mixed Initiative	人和系统按情境发起与调整共同活动的模式	S-HI16
Adjustable Autonomy	随情境改变决策控制分配，包括转交、等待和进一步调整	S-HI17
Levels of Automation	某一功能的人机分工程度；不同功能可有不同等级	S-HI15
Automation Bias	错误接受自动提示或因缺少提示而遗漏问题等依赖失误	S-HI22
Anomaly / Error / Risk	异常是偏离基线；错误相对于明确规范；风险涉及可能后果；三者不等价	S-HI25；本库操作化
Actionability	特定人或系统在特定时机可采取行动改善结果的关系性条件	本库综合；S-HI16
Intervention Policy	依据证据和约束选择是否、何时、如何支持人类参与的规则	S-HI16、S-HI17

术语	定义与边界	主要来源
Value of Information	信息改变后续决策带来的预期价值，不等于不确定性或信息数量	S-HI16、S-MT01
Interruption Cost	中断带来的时间、认知、质量、情绪或机会成本	S-HI18、S-HI19、S-HI29
Alert Fatigue / Habituation	前者概括频繁提醒下处理下降；后者是重复刺激反应减弱的一种机制	S-HI20、S-HI21
Learning to Defer	学习何时由模型预测、何时转给专家；必须定义专家表现和损失	S-HI23
Episode	围绕同一问题或过程的事件片段；其边界不同于单条日志	本库操作性定义

10.5 评价与可靠性

术语	定义与边界	主要来源
Ground Truth	为特定评价问题建立的参考真值；可能部分可得，并需说明独立性	S-GE25、S-GE28；本库分层
Precision / Recall	预测为正中正确部分的比例，与真实正例中检出部分的比例；需先确定匹配规则	S-GE27
False Positive / False Negative	相对于明确定义的判定单位、真值及阈值的误报与漏报	领域07操作化
Calibration	预测概率与相应事件经验发生频率的一致程度，不等于排序或总体准确率	S-GE20
Brier Score / Log Loss	概率预测的评分；适当评分规则鼓励报告真实信念，仍需满足评价前提	S-GE31
ECE	按预测置信度分箱比较置信与正确率的经验校准误差；受分箱及样本影响	S-GE20
Selective Prediction	允许只回答部分输入；需共同报告风险与覆盖	S-GE21
Risk-Coverage Curve	随着回答范围改变，已回答部分风险如何变化的关系	S-GE21
Range-based Precision/Recall	面向时间区间事件定义的检测指标，需规定重叠、位置与碎片权重	S-GE27
Replay Testing	以保留证据重放观察逻辑；不自动再现源头采集或外部世界	S-OT24
Fault Injection	有控制地引入故障，检验指定失败条件；故障代表性需另证	S-GE22、S-GE23
Deterministic Simulation	固定随机与调度等输入以重演被模型覆盖的执行；现实遗漏仍可能存在	S-GE23
LLM-as-a-Judge	用模型评价输出或轨迹的测量方法；Judge自身需元评价	S-GE16、S-GE18、S-GE19
Inter-annotator Agreement	标注者的一致程度；一致不直接证明内容效度或真值	S-GE25

术语	定义与边界	主要来源
Prediction-powered Inference	结合预测与有限真实标签，校正总体统计估计的推断框架	S-GE24
Construct / External Validity	测量是否对应目标构念，以及结论能推广到哪些条件	S-HI10、S-GE28；本库综合
Data Leakage	评价时使用部署中不可得或属于未来的信息等不当信息路径	领域07研究约束
Evaluation Oracle	给出参考判定的机制，可以是程序、人工或模型；本身可能有误差或只覆盖部分性质	领域07研究约束
Ecological Validity	研究设置对实际使用环境的代表性；与控制程度和真值可得性不同	S-GE28；本库综合
Counterfactual Evaluation	比较不同策略本可产生的结果；未发生结果的识别需要额外设计或假设	S-HI16；本库综合
pass@k / pass^k	在相应定义下分别偏向多次尝试至少一次成功与多次一致成功；不得混同	S-GE15
End-to-end Utility	把任务质量、避免损失、人的成本及持续负担放在共同结果中评价	本库综合；领域06/07

10.6 使用本术语表的规则

同一个词在不同领域可能对应不同对象。例如PROV中的Agent表示某种责任者，不特指LLM Agent；“Task completed”在协议中可能只说明结果已返回；“faithfulness”在RAG评测与机制解释论文中也不一定相同。跨资料比较时应先写出该文的操作定义，再决定是否可以合并结论。精确的概念边界比统一使用一个顺口译名更重要。